Code

Analiza skupa podataka Marketing & Sales

Autori: Danilo Novaković 101/2018, Luka Jevtić 64/2017

1 Uvod

Analiza i predviđanje prihoda od prodaje danas predstavljaju ključni deo uspešnog poslovanja, jer omogućavaju kompanijama da pametnije raspodele marketinške budžete i donose bolje finansijske odluke. Umesto oslanjanja na subjektivne procene i staru praksu, savremeni pristupi koriste podatke i napredne algoritme kako bi se tačno predvideli budući rezultati na osnovu ulaganja, ponašanja kupaca i kanala prodaje.

Za potrebe ovog projekta korišćen je R programski jezik, koji se pokazao kao izvanredan alat za statističku obradu, kreiranje modela mašinskog učenja i vizuelnu analizu podataka, što nam omogućava da na jasan i efikasan način izvedemo ključne poslovne zaključke.

2 Opis podataka

U ovom projektu analizira se skup podataka Marketing & Sales koji obuhvata 60.000 instanci prikupljenih iz poslovanja u MENA regionu (Alexandria,Amman,Cairo,Casablanca,Dubai,Kuwait,Riyadh). Skup sadrži sveobuhvatne informacije o marketinškim budžetima, troškovima online i offline oglašavanja, kanalima prodaje, segmentima kupaca.

Skup podataka preuzet je sa platforme Kaggle:

Izvor: Marketing i Sales Dataset (https://www.kaggle.com/datasets/abdelfattahibrahim/marketing-sales-dataset)

Cilj rada nam je detaljna analiza faktora koji utiču na ostvareni prihod od prodaje (sales_revenue_usd) i razvoj regresionih modela mašinskog učenja za preciznu predikciju prihoda na osnovu marketinških investicija i parametara ponašanja kupaca.

2.1 Učitavanje i dimenzije skupa podataka

Na početku ćemo učitati set podataka

Hide

```
dataset=read.csv("marketing_sales_dataset.csv",header = T)
```

Hide

```
print(paste("Broj kolona je:", ncol(dataset)))
```

```
[1] "Broj kolona je: 23"
```

Hide

```
print(paste("Broj redova je:", nrow(dataset)))
```

```
[1] "Broj redova je: 60000"
```

2.2 Pregled nekoliko redova,naziva feature-a, i njihova

Processing math: 100%

struktura

Nakon što smo učitali podatke možemo da proverimo kojih je dimenzija set podataka, vidimo da imamo 60 000 redova i 23 kolone

U nastavku smo pomoću funkcije head koja izlistava prvih nekoliko vrsta našeg seta podataka a funkcija names prikazuje nazive feature-a.

Hide

```
head(dataset)
```

	id <int>	date <chr>	region <chr>	sales_channel <chr>	product_category <chr>	customer_segment <chr>	season <chr>
1	1	2020-11-12	Riyadh	Retail Store	Cosmetics	Regular	Q4
2	2	2022-07-05	Dubai	Online	Cosmetics	New	Q3
3	3	2020-11-11	Riyadh	Online	Electronics	Regular	Q4
4	4	2022-10-01	Cairo	Online	Electronics	Regular	Q4
5	5	2023-12-12	Cairo	Retail Store	Food & Beverage	Corporate	Q4
6	6	2022-11-28	Cairo	Retail Store	Food & Beverage	New	Q4

6 rows | 1-8 of 23 columns

Hide

```
names(dataset)
```

```
 [1] "id"                          "date"                        "region"                      "sa
les_channel"               "product_category"
 [6] "customer_segment"            "season"                      "marketing_budget_usd"        "ad
_spend_online_usd"         "ad_spend_offline_usd"
[11] "num_promotions"              "discount_percentage"         "num_sales_representatives"   "cu
stomer_age"                "customer_satisfaction_score"
[16] "competitor_price_index"      "website_traffic"             "conversion_rate"             "em
ail_open_rate"             "social_media_followers"
[21] "days_since_last_purchase"    "num_previous_purchases"      "sales_revenue_usd"
```

Funkcijom str možemo da proverimo kog su tipa naši feature-i i vidimo da ih imamo 23 od čega su 7 numerički (integer - int),10 decimalnih (numeric - num) i 6 karakternih (chr)

Hide

```
str(dataset)
```

Processing math: 100%

```
'data.frame':   60000 obs. of  23 variables:
 $ id                          : int  1 2 3 4 5 6 7 8 9 10 ...
 $ date                        : chr  "2020-11-12" "2022-07-05" "2020-11-11" "2022-10-01" ...
 $ region                      : chr  "Riyadh" "Dubai" "Riyadh" "Cairo" ...
 $ sales_channel               : chr  "Retail Store" "Online" "Online" "Online" ...
 $ product_category            : chr  "Cosmetics" "Cosmetics" "Electronics" "Electronics" ...
 $ customer_segment            : chr  "Regular" "New" "Regular" "Regular" ...
 $ season                      : chr  "Q4" "Q3" "Q4" "Q4" ...
 $ marketing_budget_usd        : num  1665 2452 1026 1103 2518 ...
 $ ad_spend_online_usd         : num  952 1014 328 628 777 ...
 $ ad_spend_offline_usd        : num  327 415 243 205 818 ...
 $ num_promotions              : int  5 4 8 1 6 7 1 1 4 2 ...
 $ discount_percentage         : num  23.4 6 11.5 26.7 38.8 39.7 34 28.4 10.5 25.4 ...
 $ num_sales_representatives   : int  24 48 12 32 35 31 44 40 49 4 ...
 $ customer_age                : int  42 24 32 62 23 44 56 74 30 47 ...
 $ customer_satisfaction_score: num  4.5 3.7 2 2.6 3 2.7 3.5 2.6 2.9 4.7 ...
 $ competitor_price_index      : num  0.76 1.07 1.18 0.86 1.01 0.81 1.19 0.96 1.18 1.1 ...
 $ website_traffic             : int  1952 3185 1304 1609 366639 7947 51772 28601 6177 23614 ...
 $ conversion_rate             : num  0.1193 0.0404 0.1459 0.046 0.167 ...
 $ email_open_rate             : num  0.041 0.317 0.303 0.114 0.183 ...
 $ social_media_followers      : int  2034 2058 417 20618 57116 60085 4772 222 639396 2512 ...
 $ days_since_last_purchase    : num  25 187 139 308 97 202 65 209 256 108 ...
 $ num_previous_purchases      : int  6 7 3 6 6 2 9 7 4 9 ...
 $ sales_revenue_usd           : num  3773 2091 6201 4911 7706 ...
```

Sada nakon što smo videli koji sve feature-i postoje u setu podataka možemo da napišemo kratak opis o njima i da lepo to predstavimo tabelarno,za to nam treba da učitamo paket knitr i iskoristimo funkciju kable.

2.3 Pregled i opis svih feature-a

Hide

Processing math: 100%

```
opis_kolona=data.frame(
  Kolona= c(
    "id", "date", "region", "sales_channel", "product_category",
    "customer_segment", "season", "marketing_budget_usd", "ad_spend_online_usd",
    "ad_spend_offline_usd", "num_promotions", "discount_percentage",
    "num_sales_representatives", "customer_age", "customer_satisfaction_score",
    "competitor_price_index", "website_traffic", "conversion_rate",
    "email_open_rate", "social_media_followers", "days_since_last_purchase",
    "num_previous_purchases", "sales_revenue_usd"
  ),
  Opis = c(
    "Jedinstveni identifikacioni broj transakcije.",
    "Datum izvršene transakcije.",
    "Geografski region u okviru MENA tržišta (Alexandria, Amman, Cairo, Casablanca, Dubai, Kuwait,
Riyadh).",
    "Kanal preko kojeg je obavljena prodaja (npr. Online, Retail Store).",
    "Kategorija proizvoda (Cosmetics, Electronics, Food & Beverage, itd.).",
    "Tip ili segment kupca (Regular, New, Corporate, VIP).",
    "Sezonski period / kvartal u godini (Q1, Q2, Q3, Q4).",
    "Ukupan opredeljeni marketinški budžet u dolarima.",
    "Finansijska sredstva uložena u online oglašavanje.",
    "Finansijska sredstva uložena u offline marketinške kampanje.",
    "Broj aktivnih promotivnih ponuda ili akcija tokom transakcije.",
    "Procenat odobrenog popusta .",
    "Broj angažovanih prodajnih predstavnika.",
    "Starost kupca u godinama.",
    "Ocena zadovoljstva kupca na skali od 1 do 5.",
    "Indeks cene konkurencije u odnosu na naš proizvod.",
    "Saobraćaj / posete veb-sajtu.",
    "Stopa konverzije posetilaca u kupce.",
    "Procenat otvaranja promotivnih mejlova .",
    "Broj pratilaca brenda na društvenim mrežama.",
    "Broj proteklih dana od poslednje kupovine istog kupca.",
    "Ukupan broj prethodnih kupovina koje je kupac ostvario.",
    "Ostvareni prihod od prodaje u dolarima (ciljna promenljiva)."
  )
)

knitr::kable(opis_kolona, col.names = c("Naziv kolone", "Opis promenljive"))
```

Naziv kolone	Opis promenljive
id	Jedinstveni identifikacioni broj transakcije.
date	Datum izvršene transakcije.
region	Geografski region u okviru MENA tržišta (Alexandria, Amman, Cairo, Casablanca, Dubai, Kuwait, Riyadh).
sales_channel	Kanal preko kojeg je obavljena prodaja (npr. Online, Retail Store).
product_category	Kategorija proizvoda (Cosmetics, Electronics, Food & Beverage, itd.).
customer_segment	Tip ili segment kupca (Regular, New, Corporate, VIP).
season	Sezonski period / kvartal u godini (Q1, Q2, Q3, Q4).
marketing_budget_usd	Ukupan opredeljeni marketinški budžet u dolarima.

Processing math: 100%

Naziv kolone	Opis promenljive
ad_spend_online_usd	Finansijska sredstva uložena u online oglašavanje.
ad_spend_offline_usd	Finansijska sredstva uložena u offline marketinške kampanje.
num_promotions	Broj aktivnih promotivnih ponuda ili akcija tokom transakcije.
discount_percentage	Procenat odobrenog popusta .
num_sales_representatives	Broj angažovanih prodajnih predstavnika.
customer_age	Starost kupca u godinama.
customer_satisfaction_score	Ocena zadovoljstva kupca na skali od 1 do 5.
competitor_price_index	Indeks cene konkurencije u odnosu na naš proizvod.
website_traffic	Saobraćaj / posete veb-sajtu.
conversion_rate	Stopa konverzije posetilaca u kupce.
email_open_rate	Procenat otvaranja promotivnih mejlova .
social_media_followers	Broj pratilaca brenda na društvenim mrežama.
days_since_last_purchase	Broj proteklih dana od poslednje kupovine istog kupca.
num_previous_purchases	Ukupan broj prethodnih kupovina koje je kupac ostvario.
sales_revenue_usd	Ostvareni prihod od prodaje u dolarima (ciljna promenljiva).

2.4 Deskriptivna statistika i analiza ciljne promenljive

Nakon što smo definisali šta nam predstavlja svaki feature u skupu podataka, možemo da koristimo funkciju summary() kako bismo dobili osnovne statističke pokazatelje za sve naše promenljive,ali posebnu pažnju moramo da posvetimo našoj ciljnoj promenljivoj (sales_revenue_usd) koja predstavlja ostvareni prihod od prodaje u američkim dolarima.Njena distribucija je ključna za kasnije modelovanje.

Hide

```
summary(dataset)
```

Processing math: 100%

```
       id            date              region          sales_channel      product_category   custo
mer_segment      season          marketing_budget_usd
 Min.   :    1   Length:60000       Length:60000       Length:60000       Length:60000       Lengt
h:60000       Length:60000       Min.   :   500
 1st Qu.:15001   Class :character   Class :character   Class :character   Class :character   Class
:character   Class :character   1st Qu.:  2184
 Median :30001   Mode  :character   Mode  :character   Mode  :character   Mode  :character   Mode
:character   Mode  :character   Median :  4922
 Mean   :30001
Mean   : 10032
 3rd Qu.:45000
3rd Qu.: 11040
 Max.   :60000
Max.   :500000

 ad_spend_online_usd ad_spend_offline_usd num_promotions  discount_percentage num_sales_representa
tives  customer_age  customer_satisfaction_score
 Min.   :   100.1    Min.   :    50.03    Min.   :0.000   Min.   : 0.00       Min.   : 1.00
Min.   :18.0   Min.   :2.000
 1st Qu.:   816.8    1st Qu.:   486.86    1st Qu.:2.000   1st Qu.:10.10       1st Qu.:13.00
1st Qu.:31.0   1st Qu.:2.700
 Median :  1876.4    Median :  1152.39    Median :4.000   Median :20.00       Median :25.00
Median :46.0   Median :3.500
 Mean   :  4018.4    Mean   :  2508.81    Mean   :4.493   Mean   :20.05       Mean   :24.93
Mean   :45.8   Mean   :3.496
 3rd Qu.:  4336.9    3rd Qu.:  2676.80    3rd Qu.:7.000   3rd Qu.:30.00       3rd Qu.:37.00
3rd Qu.:60.0   3rd Qu.:4.200
 Max.   :235211.8    Max.   :138327.25    Max.   :9.000   Max.   :40.00       Max.   :49.00
Max.   :74.0   Max.   :5.000
                                                         NA's   :1808
NA's   :1844
 competitor_price_index website_traffic   conversion_rate   email_open_rate  social_media_follower
s days_since_last_purchase num_previous_purchases sales_revenue_usd
 Min.   :0.70           Min.   :    100   Min.   :0.00000   Min.   :0.0024   Min.   :    100
Min.   :  0.0            Min.   : 0.000         Min.   :   481.1
 1st Qu.:0.85           1st Qu.:   2961   1st Qu.:0.04580   1st Qu.:0.1458   1st Qu.:    771
1st Qu.: 89.0            1st Qu.: 3.000         1st Qu.:  2744.2
 Median :1.00           Median :   8065   Median :0.07890   Median :0.2166   Median :   2971
Median :182.0            Median : 5.000         Median :  4340.1
 Mean   :1.00           Mean   :  24426   Mean   :0.09093   Mean   :0.2308   Mean   :  22198
Mean   :181.5            Mean   : 4.985         Mean   :  5911.1
 3rd Qu.:1.15           3rd Qu.:  22057   3rd Qu.:0.12323   3rd Qu.:0.3009   3rd Qu.:  11387
3rd Qu.:273.0            3rd Qu.: 6.000         3rd Qu.:  7091.6
 Max.   :1.30           Max.   :2000000   Max.   :0.53470   Max.   :0.7537   Max.   :5000000
Max.   :364.0            Max.   :17.000         Max.   :190377.4
                                                          NA's   :1790
NA's   :1836
```

Što se tiče naše ciljne promenljive (sales_revenue_usd), iz priloženih statistika se lepo vidi da je prosečna vrednost od oko 5.911 dolara viša od medijane koja iznosi 4.340 dolara. To nam odmah govori da imamo nekoliko transakcija sa prilično velikim prihodima koje vuku prosek nagore. Većina prodaja se vrti oko nižih i srednjih iznosa (pa nam se tako 75% podataka nalazi ispod 7.091 dolara), dok samo manji broj transakcija ide u neke ekstremnije visine, sve do maksimalnih 190.377 dolara.

Processing math: 100%

2.5 Provera nedostajućih vrednosti

Radi identifikovanja nedostajućih vrednosti možemo primeniti funkciju colSums i vidimo da email_open_rate ima 1790,discount_percentage ima 1808 ,customer_satisfaction_score ima 1844 i days_since_last_purchase ima 1836 nedostajućih vrednosti.

Hide

```
colSums(is.na(dataset))
```

```
                        id                       date                     region
sales_channel            product_category
                         0                          0                          0
0                          0
           customer_segment                     season        marketing_budget_usd         ad_spe
nd_online_usd        ad_spend_offline_usd
                         0                          0                          0
0                          0
             num_promotions         discount_percentage   num_sales_representatives
customer_age customer_satisfaction_score
                         0                       1808                          0
0                       1844
     competitor_price_index             website_traffic             conversion_rate             em
ail_open_rate      social_media_followers
                         0                          0                          0
1790                            0
   days_since_last_purchase      num_previous_purchases           sales_revenue_usd
                       1836                          0                          0
```

2.6 Provera duplikata i unikatnih vrednosti

U ovom koraku ćemo proveriti da li u našem setu podataka postoje duplikati, odnosno da li se neki redovi u potpunosti ponavljaju. I vidimo na osnovu rezultata da ih nema i da je svaka od 60.000 instanci jedinstvena.

Hide

```
total_duplicate_rows = sum(duplicated(dataset))
print(paste("Ukupan broj dupliranih redova u dataset-u:", total_duplicate_rows))
```

```
[1] "Ukupan broj dupliranih redova u dataset-u: 0"
```

Sada ćemo proveriti koje sve unikatne vrednosti imamo u našim kategorijskim kolonama, da vidimo da li tu ima nekih čudnih unosa ili slovnih grešaka. Za to možemo da pregledamo unikatne vrednosti za ključne tekstualne promenljive:

Hide

```
sapply(dataset[sapply(dataset, is.character)], function(x) length(unique(x)))
```

```
           date           region    sales_channel product_category customer_segment           sea
son
           1461                7                5                5                4
4
```

Processing math: 100%

Vidimo da date ima 1461,region ima 7 ,sales_channel ima 5,product_category ima 5,customer_segment ima 4 i season ima 4 jedinstvene vrednosti

U ovom koraku ćemo proveriti kako su podaci raspoređeni po kategorijama, odnosno kolika je frekvencija opservacija u ključnim kategorijskim kolonama:

Hide

```
table(dataset$region)
```

```
Alexandria      Amman      Cairo Casablanca      Dubai     Kuwait     Riyadh 
      9027       4206      14984       4183      10890       4739      11971 
```

Hide

```
table(dataset$sales_channel)
```

```
Direct Sales       Online Retail Store Social Media    Wholesale 
        9209        18010        14954         5840        11987 
```

Hide

```
table(dataset$product_category)
```

```
      Clothing       Cosmetics     Electronics Food & Beverage Home Appliances 
         12016            9068           13118           15023           10775 
```

Hide

```
table(dataset$customer_segment)
```

```
Corporate       New   Regular       VIP 
     9113     18011     23906      8970 
```

Hide

```
table(dataset$season)
```

```
   Q1    Q2    Q3    Q4 
14898 14954 15124 15024 
```

Kao što vidimo iz tabela frekvencija, opservacije su prilično ravnomerno raspoređene po različitim regionima, kanalima prodaje, kategorijama proizvoda i sezonama, što nam govori da nemamo ekstremne disbalanse u uzorku.

Processing math: 100%

2.7 Provera validnosti opsega i logičkih pravila

U ovom koraku ćemo proveriti opsege minimalnih i maksimalnih vrednosti za sve numeričke promenljive, kako bismo utvrdili osnovne granice u kojima se podaci kreću:

Hide

```
sapply(dataset[sapply(dataset, is.numeric)], function(x) c(Min = min(x, na.rm = TRUE), Max = max
(x, na.rm = TRUE)))
```

```
       id marketing_budget_usd ad_spend_online_usd ad_spend_offline_usd num_promotions discount_pe
rcentage num_sales_representatives customer_age
Min     1                5e+02              100.14                50.03              0
0                         1           18
Max 60000                5e+05           235211.83            138327.25              9
40                         49           74
    customer_satisfaction_score competitor_price_index website_traffic conversion_rate email_open_
rate social_media_followers days_since_last_purchase
Min                            2                    0.7           1e+02          0.0000          0.
0024                  1e+02                         0
Max                            5                    1.3           2e+06          0.5347          0.
7537                  5e+06                       364
    num_previous_purchases sales_revenue_usd
Min                      0            481.08
Max                     17          190377.35
```

Nakon provere opsega, analizirane su minimalne i maksimalne vrednosti da se utvrdi da li ima nekih nelogičnosti. Uočeno je da se svi podaci kreću u normalnim granicama: godine kupaca su od 18 do 74, ocene zadovoljstva su između 2 i 5, a maksimalni popust je 40%. Budžeti i troškovi jesu visoki, ali su u skladu sa realnim poslovanjem i nema negativnih cena niti nelogičnih unosa. Samim tim, numerički opsezi su potpuno ispravni.

U ovom koraku ćemo proveriti da li u setu podataka postoje logičke nepravilnosti:

Provera da li popust izlazi van očekivanog opsega [0%, 100%]

Hide

```
sum(dataset$discount_percentage < 0 | dataset$discount_percentage > 100, na.rm = TRUE)
```

```
[1] 0
```

Provera da li ocene zadovoljstva izlaze van opsega [1, 5]

Hide

```
sum(dataset$customer_satisfaction_score < 1 | dataset$customer_satisfaction_score > 5, na.rm = TRU
E)
```

```
[1] 0
```

Provera da li broj dana od poslednje kupovine prelazi 365

Hide

```
sum(dataset$days_since_last_purchase < 0 | dataset$days_since_last_purchase > 365, na.rm = TRUE)
```

Processing math: 100%

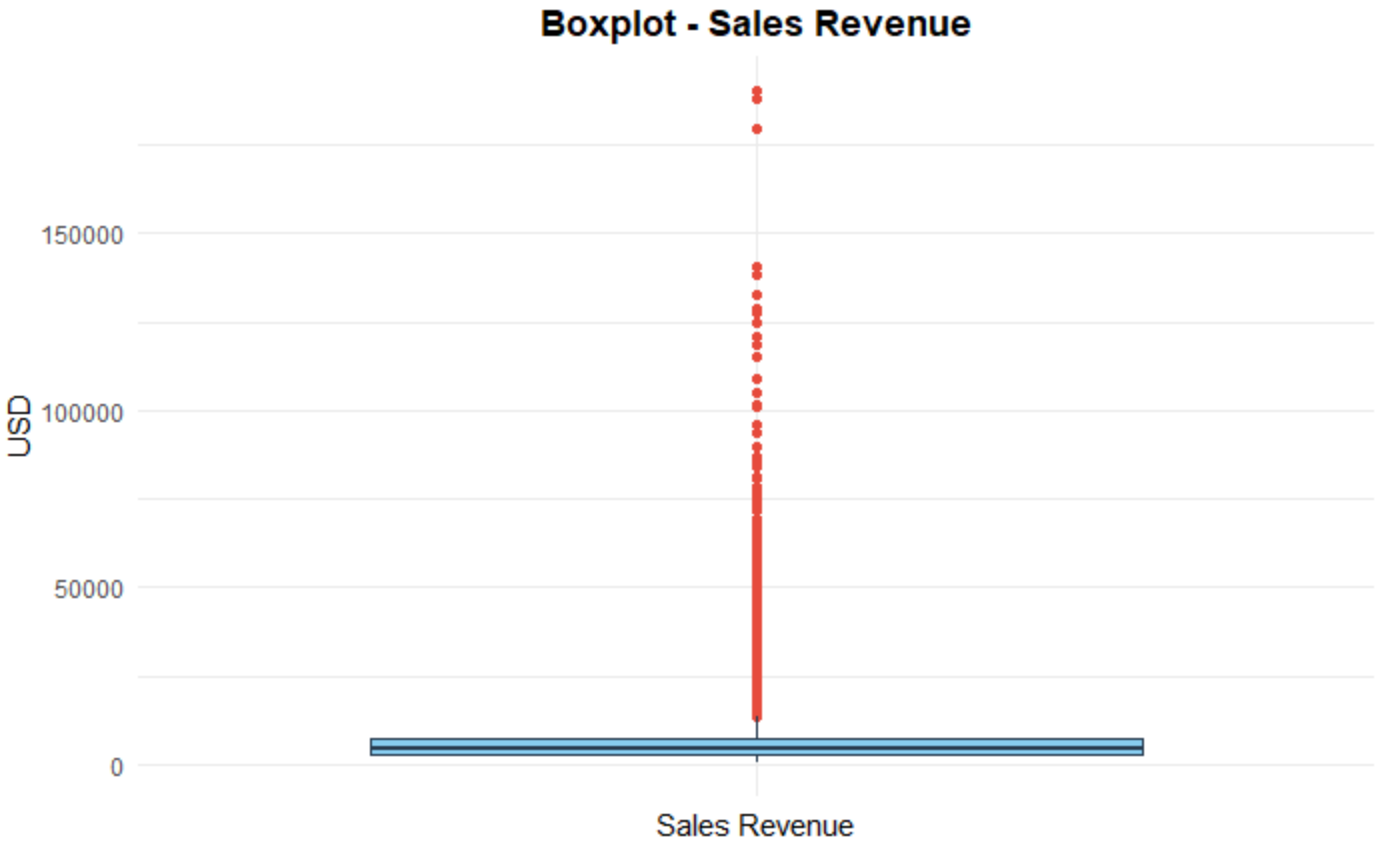
```
[1] 0
```

2.8 Analiza outlier-a

U ovom koraku ćemo identifikovati potencijalne outlier-e za ključne numeričke promenljive u setu podataka (prihode, marketing budžet, web saobraćaj i društvene mreže) pomoću importovanja tidyverse paketa i njegovog korišćenja za iscrtavanja grafika:

Hide

```
ggplot(dataset, aes(x = "", y = sales_revenue_usd)) +
  geom_boxplot(fill = "#89CFF0", color = "#2C3E50", outlier.color = "#E74C3C", outlier.size = 1.5,
outlier.shape = 16) +
  theme_minimal() +
  labs(title = "Boxplot - Sales Revenue", x = "Sales Revenue", y = "USD") +
  theme(plot.title = element_text(hjust = 0.5, face = "bold"),
        axis.text.x = element_blank(), axis.ticks.x = element_blank())
```

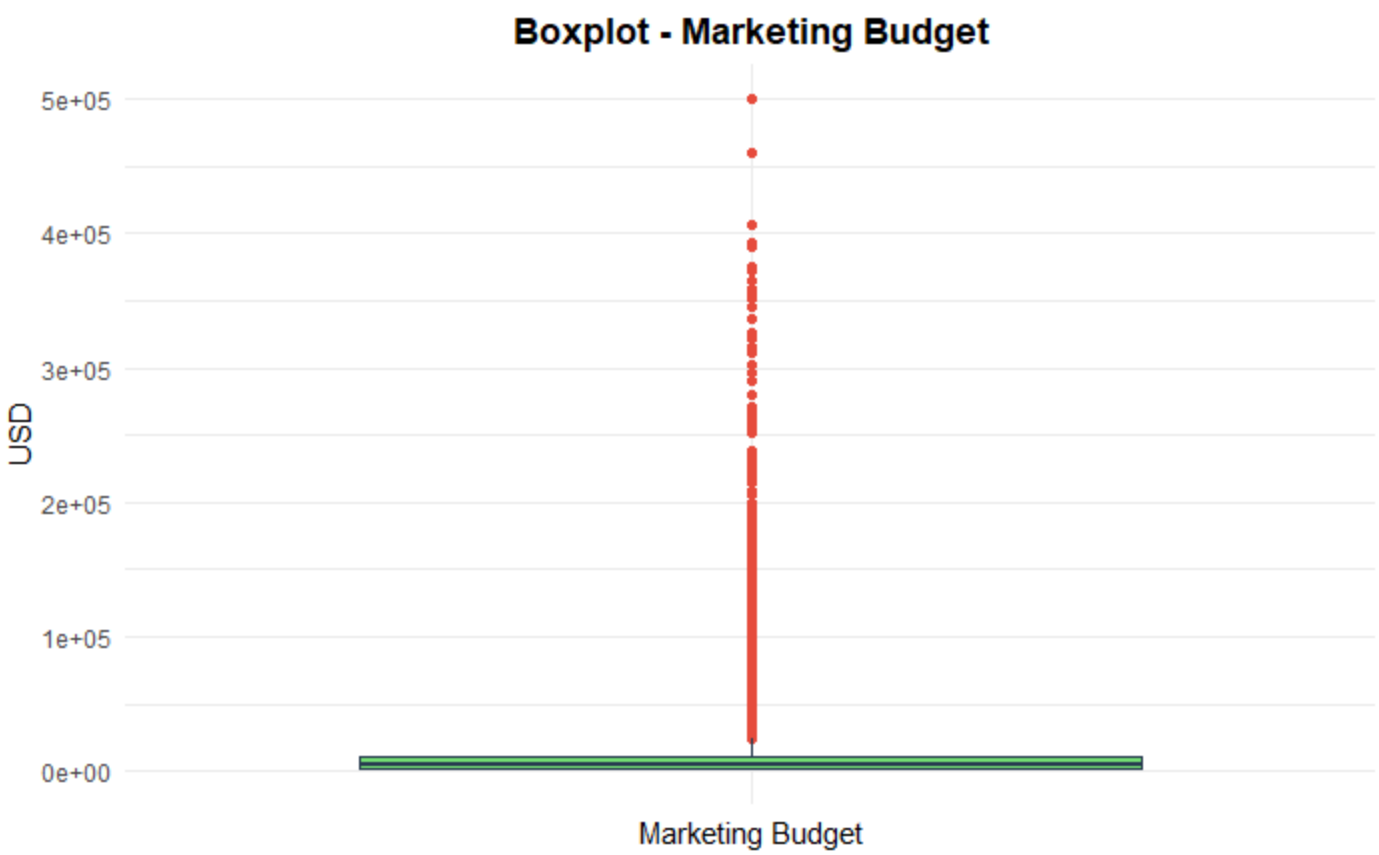


Kod prihoda od prodaje (sales_revenue_usd), Boxplot dijagram prikazuje znatnu koncentraciju tačaka iznad gornje granice dijagrama. Ove vrednosti predstavljaju legitimne visoke transakcije ostvarene na uspešnijim tržištima i ne predstavljaju greške u unosu, te se zadržavaju u analizi.

Hide

```
ggplot(dataset, aes(x = "", y = marketing_budget_usd)) +
  geom_boxplot(fill = "#77DD77", color = "#2C3E50", outlier.color = "#E74C3C", outlier.size = 1.5,
outlier.shape = 16) +
  theme_minimal() +
  labs(title = "Boxplot - Marketing Budget", x = "Marketing Budget", y = "USD") +
  theme(plot.title = element_text(hjust = 0.5, face = "bold"),
        axis.text.x = element_blank(), axis.ticks.x = element_blank())
```

Processing math: 100%

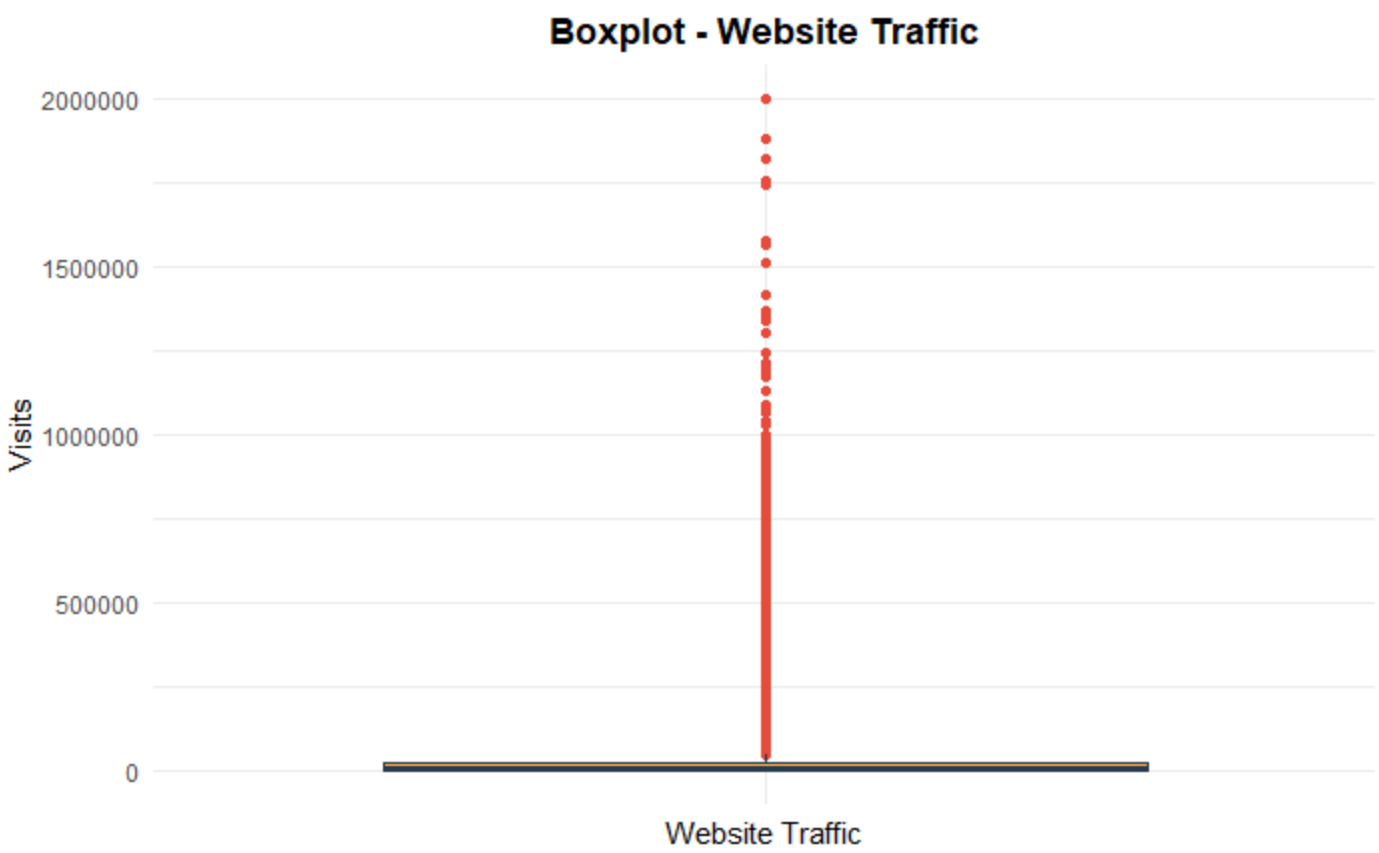


Slična situacija je i kod marketing budžeta (marketing_budget_usd), gde se uočava gust skup vrednosti iznad gornjeg kvartila. Reč je o realnim poslovnim odlukama za obimnije reklamne kampanje, pa se ove opservacije takođe zadržavaju u skupu.

Hide

```
ggplot(dataset, aes(x = "", y = website_traffic)) +
  geom_boxplot(fill = "#FFB347", color = "#2C3E50", outlier.color = "#E74C3C", outlier.size = 1.5,
outlier.shape = 16) +
  theme_minimal() +
  labs(title = "Boxplot - Website Traffic", x = "Website Traffic", y = "Visits") +
  theme(plot.title = element_text(hjust = 0.5, face = "bold"),
        axis.text.x = element_blank(), axis.ticks.x = element_blank())
```

Processing math: 100%

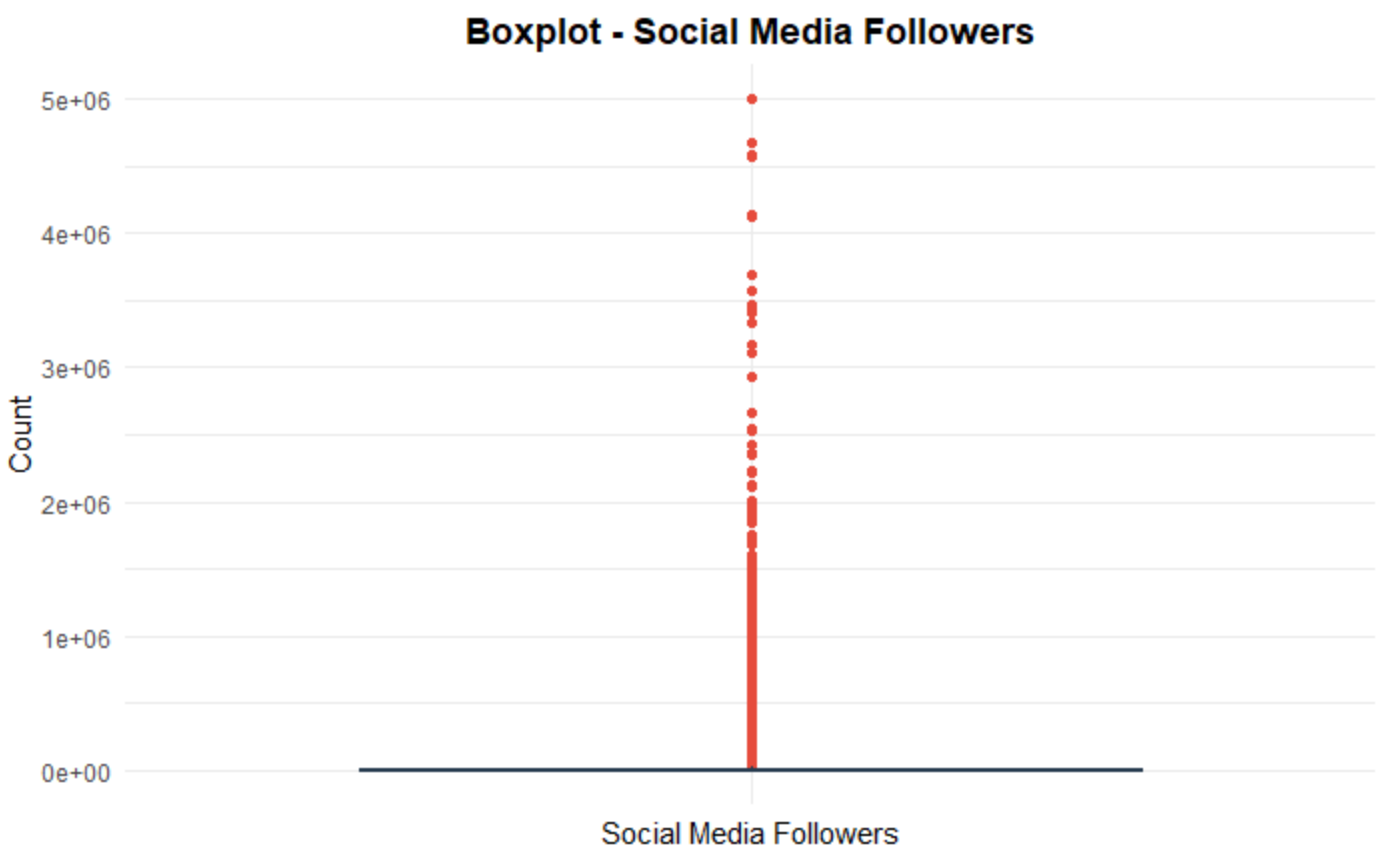


Grafik web saobraćaja (website_traffic) prikazuje značajan broj ekstremnijih vrednosti usmerenih ka gornjoj granici. One odražavaju periode izuzetno visoke posete sajtu tokom uspešnih kampanja i predstavljaju stvarne podatke bez potrebe za uklanjanjem.

Hide

```
ggplot(dataset, aes(x = "", y = social_media_followers)) +
  geom_boxplot(fill = "#CCCCFF", color = "#2C3E50", outlier.color = "#E74C3C", outlier.size = 1.5,
outlier.shape = 16) +
  theme_minimal() +
  labs(title = "Boxplot - Social Media Followers", x = "Social Media Followers", y = "Count") +
  theme(plot.title = element_text(hjust = 0.5, face = "bold"),
        axis.text.x = element_blank(), axis.ticks.x = element_blank())
```

Processing math: 100%



Kod broja pratilaca na društvenim mrežama (social_media_followers) prisutne su vertikalno raspršene tačke ka samom vrhu skale, što je sasvim očekivano u praksi za brendove koji ostvaruju veći organski domet ili viralne objave.

Zaključak: Za sve posmatrane promenljive je da prisutni outlieri ne predstavljaju greške u merenju, već su prirodan odraz varijacija u realnom poslovnom okruženju, te se zadržavaju za dalju obradu.

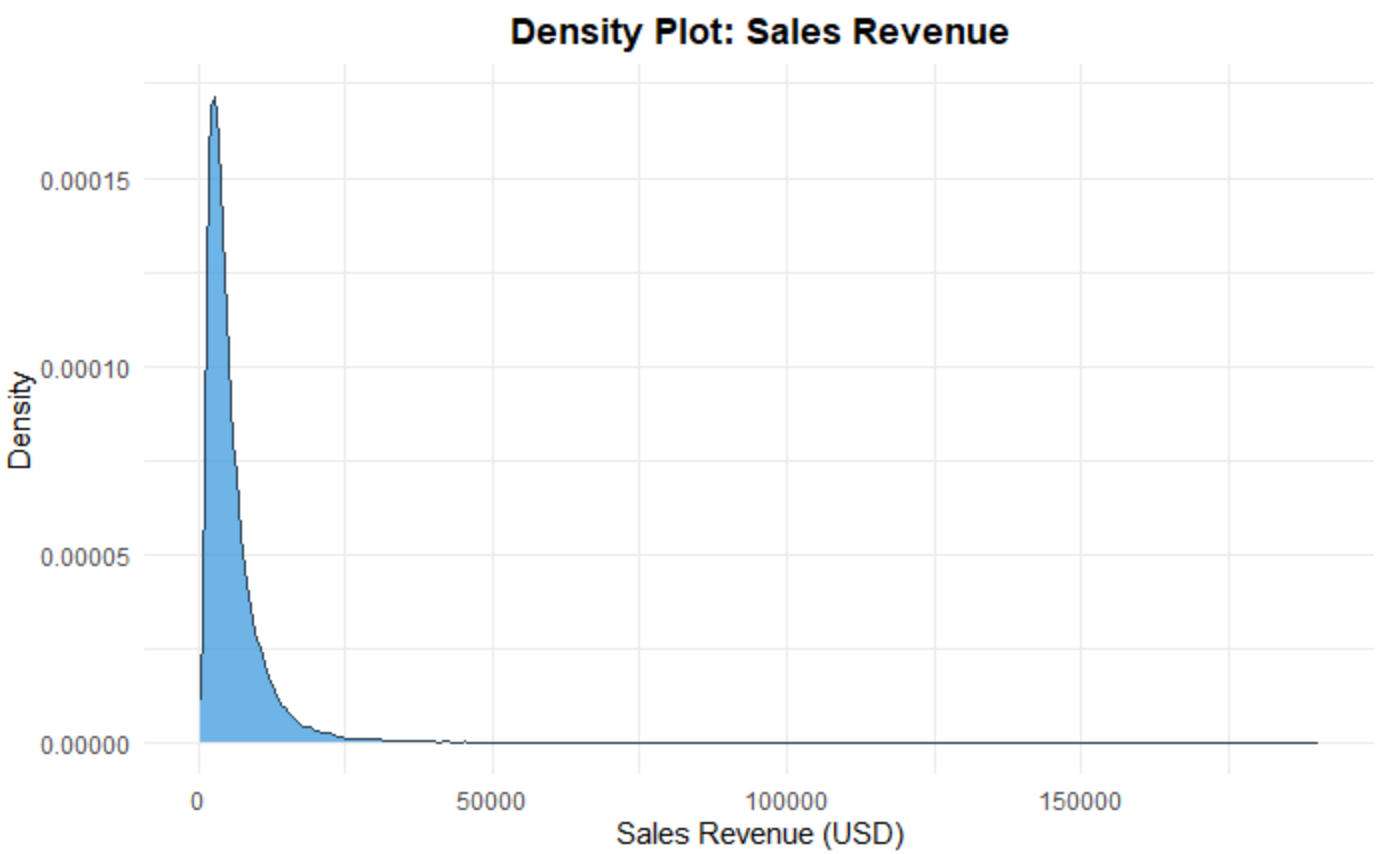
2.9 Analiza gustine distribucije

U ovom koraku ćemo proveriti distribuciju ključnih numeričkih promenljivih pomoću grafika gustine (density plot) kako bismo utvrdili da li podaci prate prirodne obrasce ili pokazuju znakove veštačkog generisanja:

Hide

```
ggplot(dataset, aes(x = sales_revenue_usd)) +
  geom_density(fill = "#3498DB", color = "#2C3E50", alpha = 0.7) +
  theme_minimal() +
  labs(title = "Density Plot: Sales Revenue", x = "Sales Revenue (USD)", y = "Density") +
  theme(plot.title = element_text(hjust = 0.5, face = "bold"))
```

Processing math: 100%

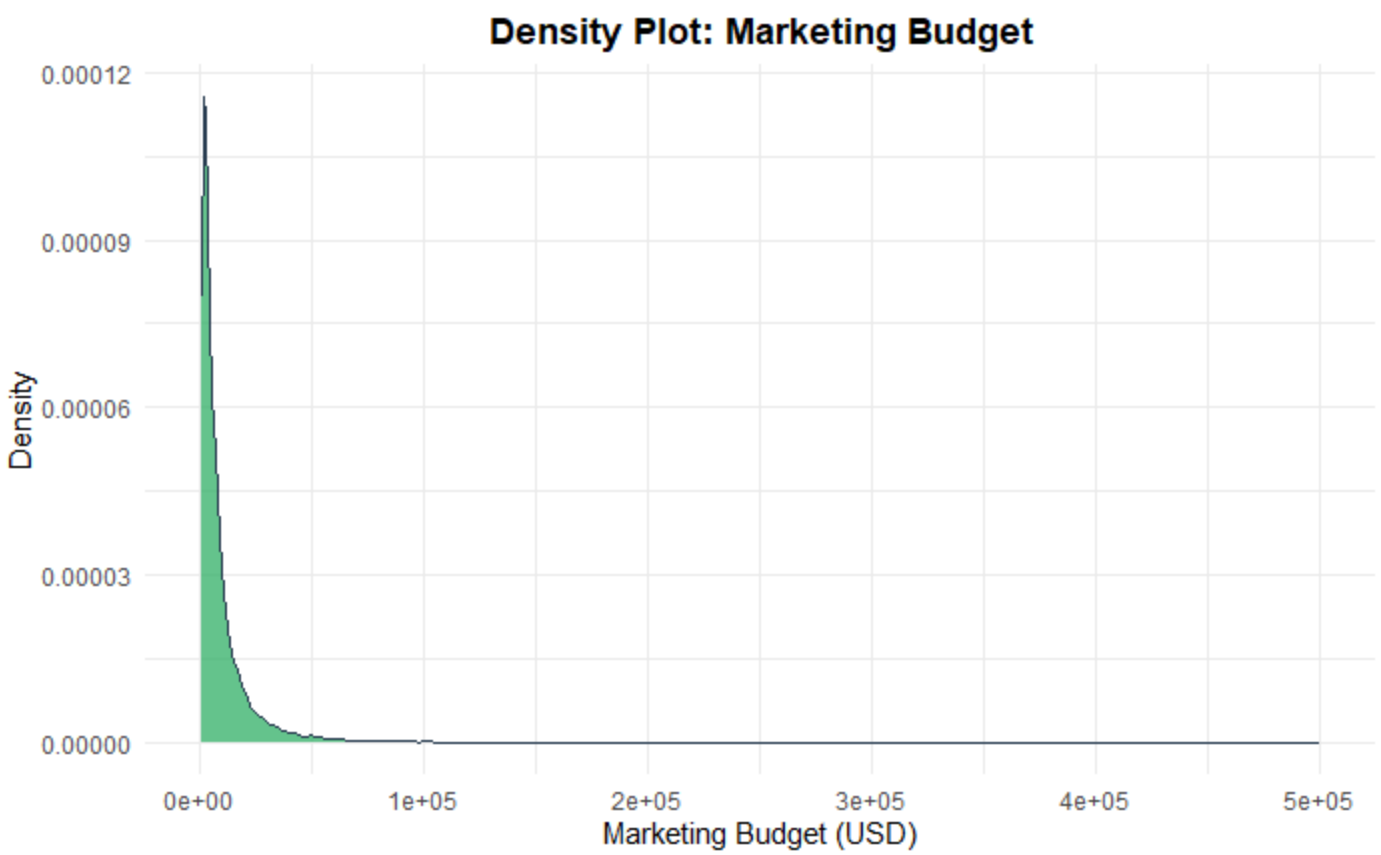


Distribucija prihoda od prodaje jasno pokazuje izraženu desnu asimetriju sa dugim desnim repom. Ogromna većina transakcija donosi niže i umerene iznose prihoda, dok se tek manji broj velikih prodaja pruža ka desnom kraju skale. Kriva je glatka i kontinuirana, što je sasvim očekivano za realne finansijske podatke i jasno nam ukazuje na potrebu za logaritamskom transformacijom u nastavku rada.

Hide

```
ggplot(dataset, aes(x = marketing_budget_usd)) +
  geom_density(fill = "#27AE60", color = "#2C3E50", alpha = 0.7) +
  theme_minimal() +
  labs(title = "Density Plot: Marketing Budget", x = "Marketing Budget (USD)", y = "Density") +
  theme(plot.title = element_text(hjust = 0.5, face = "bold"))
```

Processing math: 100%

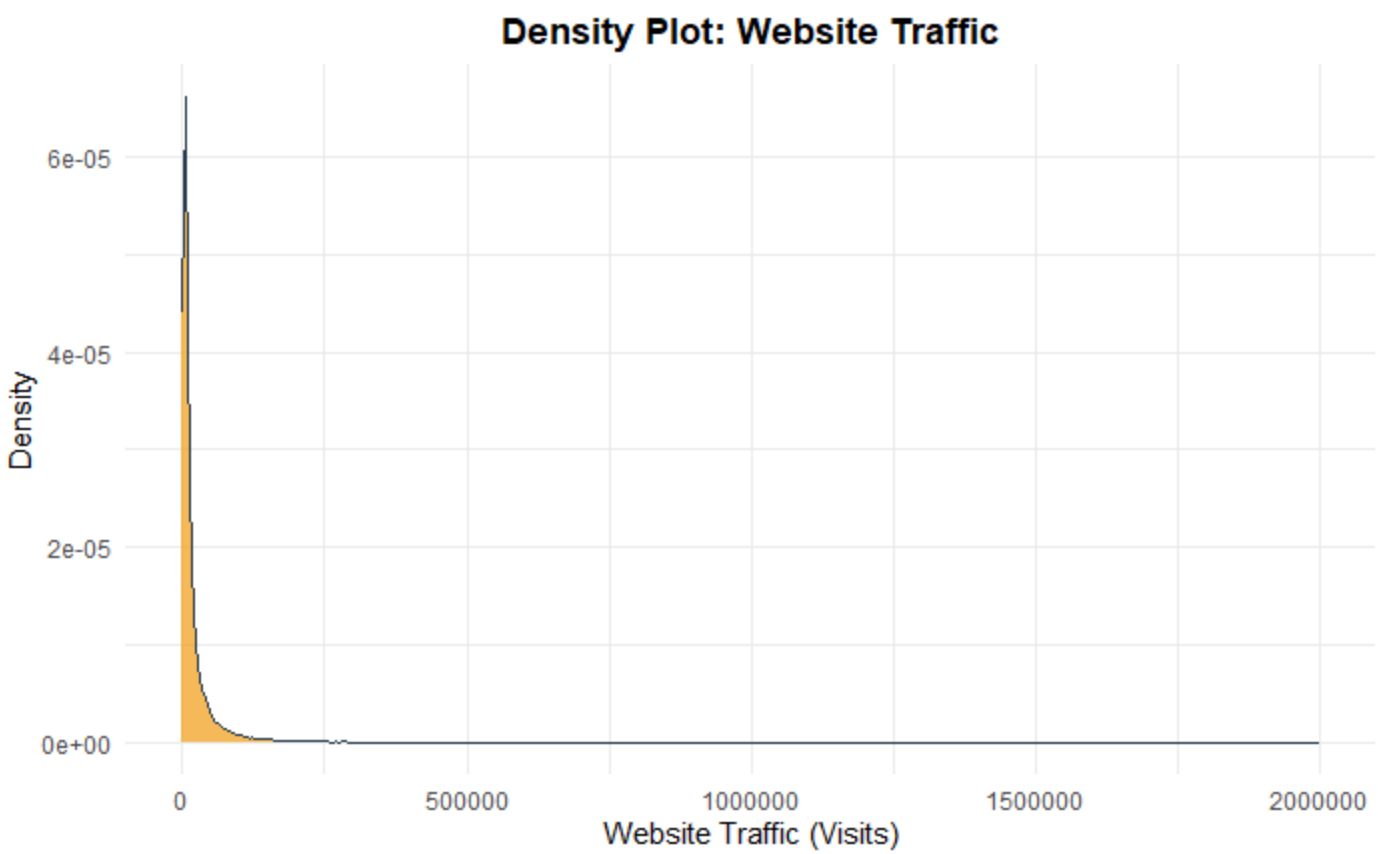


Kod marketing budžeta vidimo veoma sličan šablon. Kriva ima jedan dominantan pik na manjim iznosima i postepeno opada kako budžeti rastu. Ovakav raspored odslikava uobičajenu praksu gde se većina kampanja finansira umerenim sredstvima, dok se znatno ređe odobravaju izuzetno visoki budžeti.

Hide

```
ggplot(dataset, aes(x = website_traffic)) +
  geom_density(fill = "#F39C12", color = "#2C3E50", alpha = 0.7) +
  theme_minimal() +
  labs(title = "Density Plot: Website Traffic", x = "Website Traffic (Visits)", y = "Density") +
  theme(plot.title = element_text(hjust = 0.5, face = "bold"))
```

Processing math: 100%

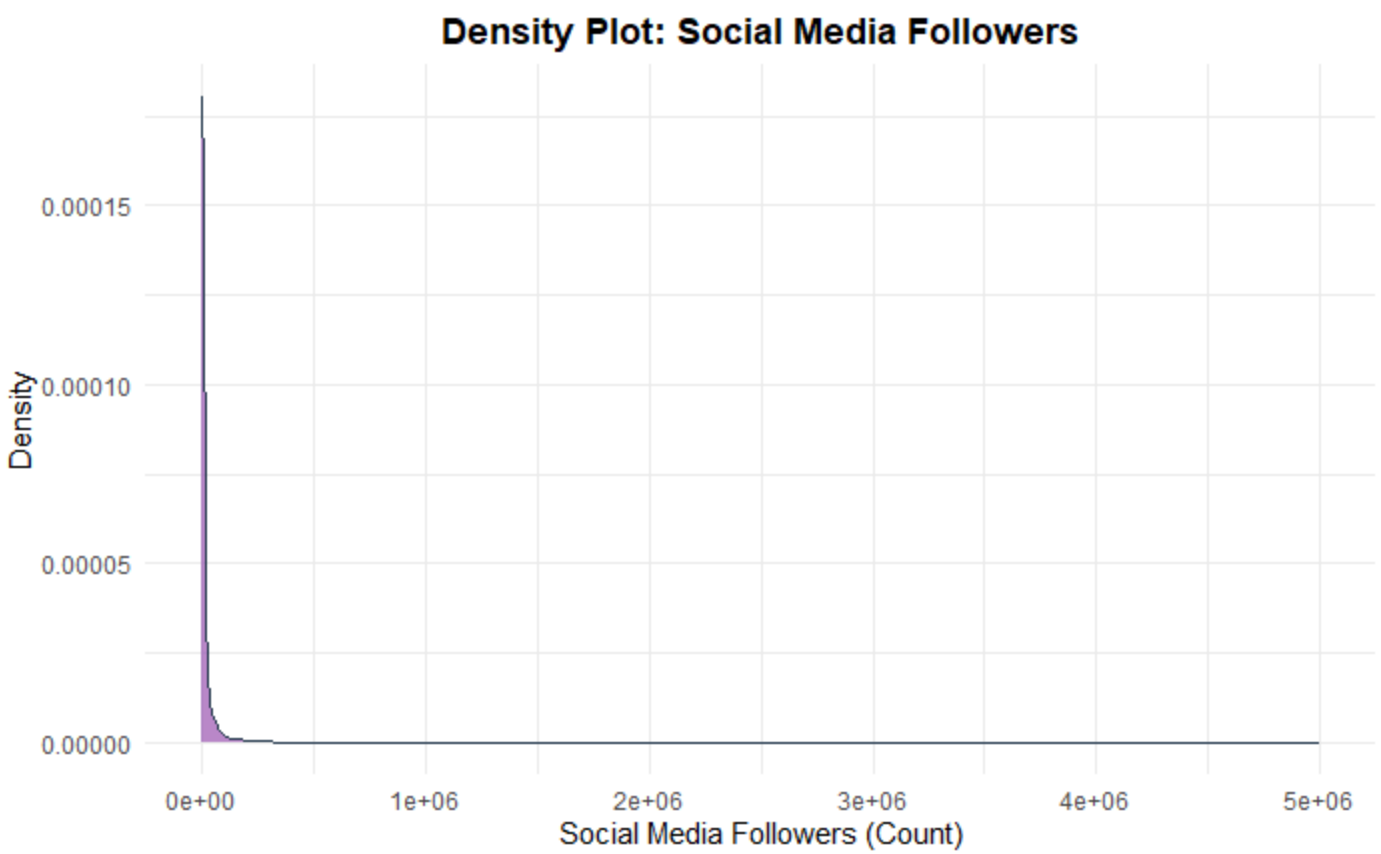


Kriva saobraćaja na sajtu je takođe pozitivno asimetrična, ali potpuno glatka. Većina dana beleži standardnu posećenost, dok manji broj uspešnih promocija ili kampanja generiše veliku posetu. Na grafiku nema neprirodnih skokova ili rupa, što potvrđuje stabilnost podataka.

Hide

```
ggplot(dataset, aes(x = social_media_followers)) +
  geom_density(fill = "#9B59B6", color = "#2C3E50", alpha = 0.7) +
  theme_minimal() +
  labs(title = "Density Plot: Social Media Followers", x = "Social Media Followers (Count)", y =
"Density") +
  theme(plot.title = element_text(hjust = 0.5, face = "bold"))
```

Processing math: 100%



Broj pratilaca na društvenim mrežama očekivano pokazuje najveću koncentraciju pri dnu skale. Većina brendova ili naloga ima umerenu publiku, dok manji broj uspeva da privuče stotine hiljada ili milione pratilaca.

Sve posmatrane numeričke promenljive imaju prirodne, glatke krive sa izraženom desnom asimetrijom. Podaci deluju konzistentno i spremni su za naredne korake preprocesiranja i transformacije.

3 Analiza nedostajućih vrednosti

3.1 Uvod u analizu nedostajućih vrednosti

U ovoj fazi analiziraju se nedostajuće vrednosti u skupu podataka. Cilj je utvrditi u kojim kolonama postoje nedostajuće vrednosti, koliki je njihov procenat, da li se nedostajuće vrednosti pojavljuju u više kolona istovremeno i da li postoji obrazac njihovog pojavljivanja. Takođe se ispituje povezanost nedostajućih vrednosti sa drugim posmatranim promenljivama i ciljnom promenljivom `sales_revenue_usd` .

Na osnovu sprovedene analize proceniće se da li je pretpostavka MCAR (*Missing Completely At Random*) prihvatljiva. Nakon toga biće razmotreno nekoliko strategija za rešavanje nedostajućih vrednosti: imputacija medianom i modom, višestruka imputacija pomoću MICE algoritma sa *Predictive Mean Matching* (PMM) metodom.

3.2 Broj nedostajućih vrednosti po kolonama

Prvi korak predstavlja određivanje broja nedostajućih vrednosti u svakoj koloni. Na ovaj način možemo identifikovati promenljive koje zahtevaju dodatnu obradu i utvrditi obim problema sa nedostajućim podacima.

Hide

Processing math: 100%

```
missing_counts = colSums(is.na(dataset))
missing_summary = data.frame(
  Kolona = names(missing_counts),
  Broj_missing = as.numeric(missing_counts)
)
missing_summary = missing_summary[missing_summary$Broj_missing > 0, ]
missing_summary
```

	Kolona <chr>	Broj_missing <dbl>
12	discount_percentage	1808
15	customer_satisfaction_score	1844
19	email_open_rate	1790
21	days_since_last_purchase	1836

4 rows

3.3 Procenat nedostajućih vrednosti

Pored apsolutnog broja nedostajućih vrednosti, izračunat je i njihov procenat u odnosu na ukupan broj redova.

Hide

```
missing_summary$Procenat_missing = round(
  (missing_summary$Broj_missing / nrow(dataset)) * 100,
  2
)
missing_summary
```

	Kolona <chr>	Broj_missing <dbl>	Procenat_missing <dbl>
12	discount_percentage	1808	3.01
15	customer_satisfaction_score	1844	3.07
19	email_open_rate	1790	2.98
21	days_since_last_purchase	1836	3.06

4 rows

U posmatranom skupu podataka nedostajuće vrednosti se pojavljuju u nekoliko numeričkih promenljivih, sa udelom od približno 3% po promenljivoj.

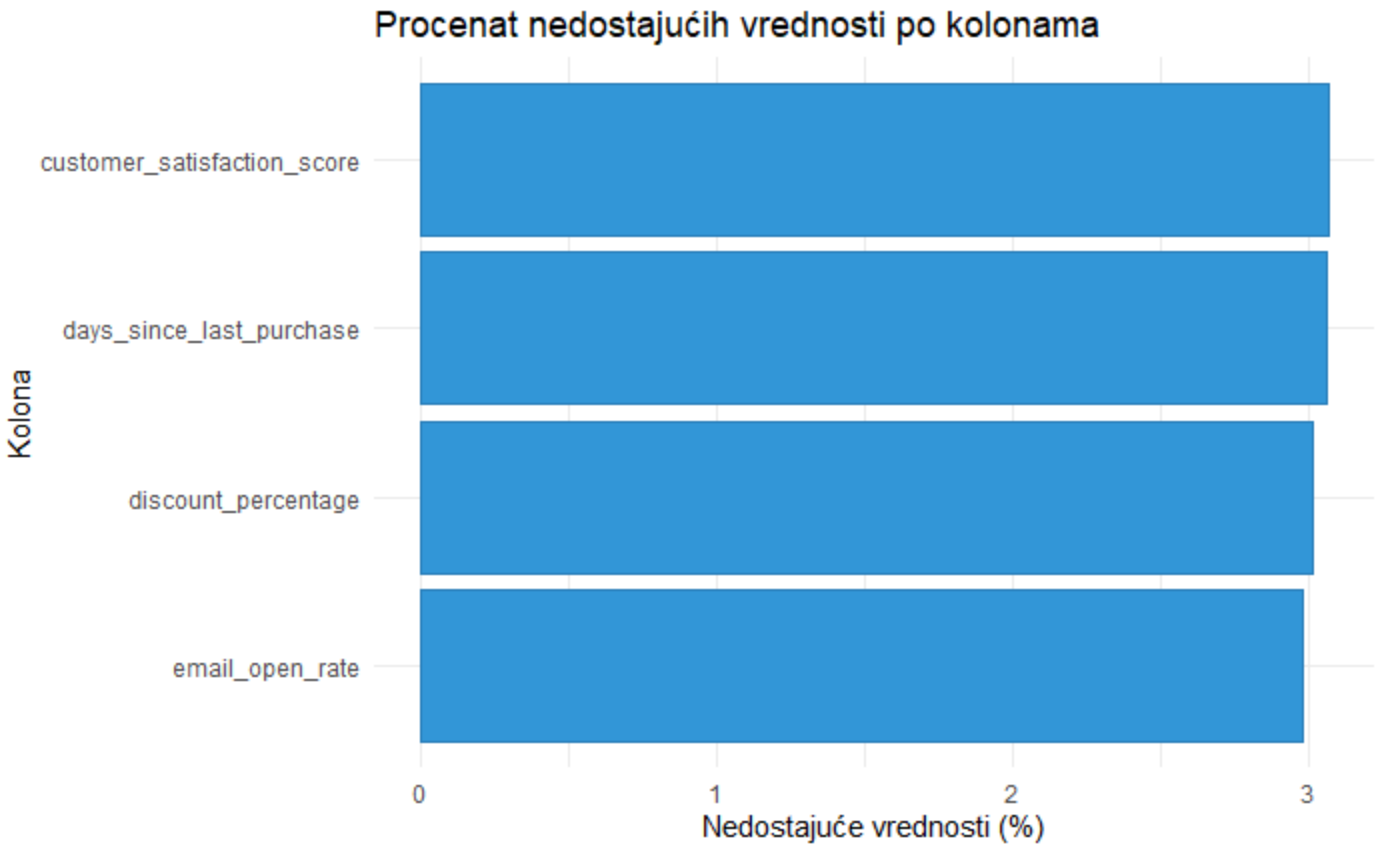
3.4 Vizuelizacija nedostajućih vrednosti

Radi lakšeg uočavanja razlika između promenljivih, procenat nedostajućih vrednosti prikazan je grafički.

Hide

Processing math: 100%

```
ggplot(missing_summary, aes(x = reorder(Kolona, Procenat_missing), y = Procenat_missing)) +
  geom_col(fill = "#3498db", color = "#2980b9") +
  coord_flip() +
  labs(
    title = "Procenat nedostajućih vrednosti po kolonama",
    x = "Kolona",
    y = "Nedostajuće vrednosti (%)"
  ) +
  theme_minimal()
```



3.5 Identifikovanje redova sa više nedostajućih vrednosti

Sledeći korak je analiza raspodele nedostajućih vrednosti po redovima. Posebno je važno utvrditi da li se nedostajuće vrednosti uglavnom pojavljuju pojedinačno ili postoji veći broj redova u kojima nedostaje više atributa istovremeno.

Hide

```
missing_per_row = rowSums(is.na(dataset))
table(missing_per_row)
```

```
missing_per_row
    0     1     2     3
53040  6650   302     8
```

Hide

Processing math: 100%

```
rows_multiple_missing = dataset[missing_per_row >= 2, ]
num_multiple = nrow(rows_multiple_missing)
pct_multiple = round(mean(missing_per_row >= 2) * 100, 2)

print(paste("Broj redova sa najmanje dve missing vrednosti:", num_multiple))
```

```
[1] "Broj redova sa najmanje dve missing vrednosti: 310"
```

Hide

```
print(paste("Procenat redova sa najmanje dve missing vrednosti:", pct_multiple, "%"))
```

```
[1] "Procenat redova sa najmanje dve missing vrednosti: 0.52 %"
```

Dobijeni rezultati pokazuju koliko se često više nedostajućih vrednosti pojavljuje u okviru istog reda. Ova analiza je značajna prilikom izbora strategije imputacije, jer veći broj istovremeno nedostajućih vrednosti može smanjiti količinu informacija dostupnih za pouzdanu imputaciju.

3.6 Analiza obrazaca nedostajućih vrednosti

Pored broja nedostajućih vrednosti, analiziran je i njihov obrazac pojavljivanja. Cilj je utvrditi koje promenljive najčešće imaju nedostajuće vrednosti zajedno.

Hide

```
missing_variables = c(
  "discount_percentage",
  "customer_satisfaction_score",
  "email_open_rate",
  "days_since_last_purchase"
)

op = par(mar = c(6, 5, 10, 4), cex = 0.45)

mice::md.pattern(
  dataset[, missing_variables],
  plot = TRUE,
  rotate.names = TRUE
)
```

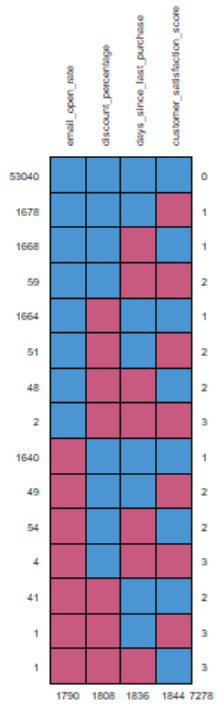
Processing math: 100%

```
      email_open_rate discount_percentage days_since_last_purchase customer_satisfaction_score
53040               1                   1                         1                           1
0
1678                1                   1                         1                           0
1
1668                1                   1                         0                           1
1
59                  1                   1                         0                           0
2
1664                1                   0                         1                           1
1
51                  1                   0                         1                           0
2
48                  1                   0                         0                           1
2
2                   1                   0                         0                           0
3
1640                0                   1                         1                           1
1
49                  0                   1                         1                           0
2
54                  0                   1                         0                           1
2
4                   0                   1                         0                           0
3
41                  0                   0                         1                           1
2
1                   0                   0                         1                           0
3
1                   0                   0                         0                           1
3
              1790                1808                      1836                        1844 727
8
```

Hide

```
par(op)
```

Processing math: 100%



Na osnovu prikazanog obrasca može se uočiti da se nedostajuće vrednosti u analiziranim promenljivama pojavljuju uglavnom pojedinačno. Ovaj rezultat će biti uzet u obzir prilikom izbora metode imputacije.

3.7 Indikatori nedostajućih vrednosti

Kako bi originalni skup podataka ostao nepromenjen, za dalju analizu nedostajućih vrednosti kreirana je posebna kopija skupa podataka pod nazivom missingness_data. U ovoj kopiji kreiraju se pomoćne binarne promenljive koje označavaju da li određena vrednost nedostaje. Vrednost 1 označava da podatak nedostaje, dok vrednost 0 označava da je podatak dostupan. Originalni dataset se ne menja, čime se omogućava njegovo kasnije korišćenje za različite strategije obrade podataka.

Hide

Processing math: 100%

```
missingness_data = dataset %>%
  mutate(
    missing_discount = as.integer(
      is.na(discount_percentage)
    ),

    missing_satisfaction = as.integer(
      is.na(customer_satisfaction_score)
    ),

    missing_email = as.integer(
      is.na(email_open_rate)
    ),

    missing_days = as.integer(
      is.na(days_since_last_purchase)
    )
  )
```

3.8 Test nezavisnosti missingness-a

U nastavku se ispituje da li je pojavljivanje nedostajućih vrednosti povezano sa kategorijskim promenljivama. Analizirane su promenljive region, sales_channel, product_category, customer_segment i season. Za ispitivanje povezanosti koristi se χ^2 test nezavisnosti.

Nulta hipoteza testa je da su pojavljivanje nedostajuće vrednosti i posmatrana kategorijska promenljiva nezavisni. Kao nivo statističke značajnosti koristi se $\alpha = 0,05$.

Hide

Processing math: 100%

```
categorical_variables = c(
  "region",
  "sales_channel",
  "product_category",
  "customer_segment",
  "season"
)

missing_indicators = c(
  "missing_discount",
  "missing_satisfaction",
  "missing_email",
  "missing_days"
)

missing_names = c(
  "discount_percentage",
  "customer_satisfaction_score",
  "email_open_rate",
  "days_since_last_purchase"
)

chi_results = data.frame(
  Missing_variable = character(),
  Categorical_variable = character(),
  Chi_squared = numeric(),
  p_value = numeric(),
  Zakljucak = character()
)

for (i in seq_along(missing_indicators)) {

  for (categorical_variable in categorical_variables) {

    tabela = table(
      missingness_data[[missing_indicators[i]]],
      missingness_data[[categorical_variable]]
    )

    test = chisq.test(tabela)

    zakljucak = ifelse(
      test$p.value < 0.05,
      "Statistički značajna povezanost",
      "Nema statistički značajne povezanosti"
    )

    chi_results = rbind(
      chi_results,
      data.frame(
        Missing_variable = missing_names[i],
        Categorical_variable = categorical_variable,
        Chi_squared = as.numeric(test$statistic),
        p_value = test$p.value
      )
    )
```

Processing math: 100%

```
  }
}

chi_results
```

Missing_variable <chr>	Categorical_variable <chr>	Chi_squared <dbl>	p_value <dbl>
discount_percentage	region	1.79215919	0.9377871
discount_percentage	sales_channel	3.30841045	0.5076008
discount_percentage	product_category	0.19207264	0.9956734
discount_percentage	customer_segment	3.80518683	0.2832834
discount_percentage	season	2.04339554	0.5634488
customer_satisfaction_score	region	1.74287264	0.9417637
customer_satisfaction_score	sales_channel	0.64007503	0.9585080
customer_satisfaction_score	product_category	0.41143949	0.9815296
customer_satisfaction_score	customer_segment	1.59982334	0.6594299
customer_satisfaction_score	season	2.99618651	0.3922135

1-10 of 20 rows Previous **1** 2 Next

Pošto je p-vrednost veća ili jednaka nivou značajnosti α = 0,05, nema dovoljno statističkih dokaza za odbacivanje nulte hipoteze. Nije utvrđena statistički značajna povezanost između pojavljivanja nedostajućih vrednosti i posmatrane kategorijske promenljive.

3.9 Poređenje ciljne promenljive

Kako bi se proverilo da li se prihod od prodaje razlikuje između redova sa i bez nedostajućih vrednosti, analizirana je ciljna promenljiva sales_revenue_usd. Za svaku promenljivu izračunate su srednja i medijalna vrednost prihoda za slučajeve kod kojih podatak nedostaje i slučajeve kod kojih je dostupan.

Hide

Processing math: 100%

```
target_comparison = data.frame(
  Missing_variable = character(),
  Status = character(),
  Number_of_rows = integer(),
  Mean_revenue = numeric(),
  Median_revenue = numeric()
)

for (variable in missing_variables) {

  indicator_name = switch(
    variable,
    discount_percentage = "missing_discount",
    customer_satisfaction_score = "missing_satisfaction",
    email_open_rate = "missing_email",
    days_since_last_purchase = "missing_days"
  )

  status =ifelse(
    missingness_data[[indicator_name]] == 1,
    "Missing",
    "Available"
  )

  temp = data.frame(
    Status = status,
    Revenue = missingness_data$sales_revenue_usd
  )

  summary_temp = temp %>%
    group_by(Status) %>%
    summarise(
      Number_of_rows = n(),
      Mean_revenue = mean(Revenue),
      Median_revenue = median(Revenue)
    )

  summary_temp$Missing_variable = variable

  target_comparison = rbind(
    target_comparison,
    summary_temp[, c(
      "Missing_variable",
      "Status",
      "Number_of_rows",
      "Mean_revenue",
      "Median_revenue"
    )]
  )
}

target_comparison
```

Processing math: 100%

Missing_variable <chr>	Status <chr>	Number_of_rows <int>	Mean_revenue <dbl>	Median_revenue <dbl>
discount_percentage	Available	58192	5903.764	4336.580
discount_percentage	Missing	1808	6147.840	4476.000
customer_satisfaction_score	Available	58156	5912.033	4340.335
customer_satisfaction_score	Missing	1844	5882.294	4325.560
email_open_rate	Available	58210	5909.166	4338.110
email_open_rate	Missing	1790	5974.633	4383.730
days_since_last_purchase	Available	58164	5905.933	4339.435
days_since_last_purchase	Missing	1836	6075.412	4390.890

8 rows

3.10 Boxplot poređenje targeta

Pored numeričkog poređenja, distribucije prihoda za redove sa i bez nedostajućih vrednosti prikazane su pomoću boxplot grafika. Pošto ciljna promenljiva sales_revenue_usd ima izraženu desnu asimetriju i ekstremne vrednosti, koristi se logaritamska skala radi preglednijeg prikaza.

Hide

Processing math: 100%

```
target_plot_data = data.frame(
  sales_revenue_usd = missingness_data$sales_revenue_usd
)

for (variable in missing_variables) {

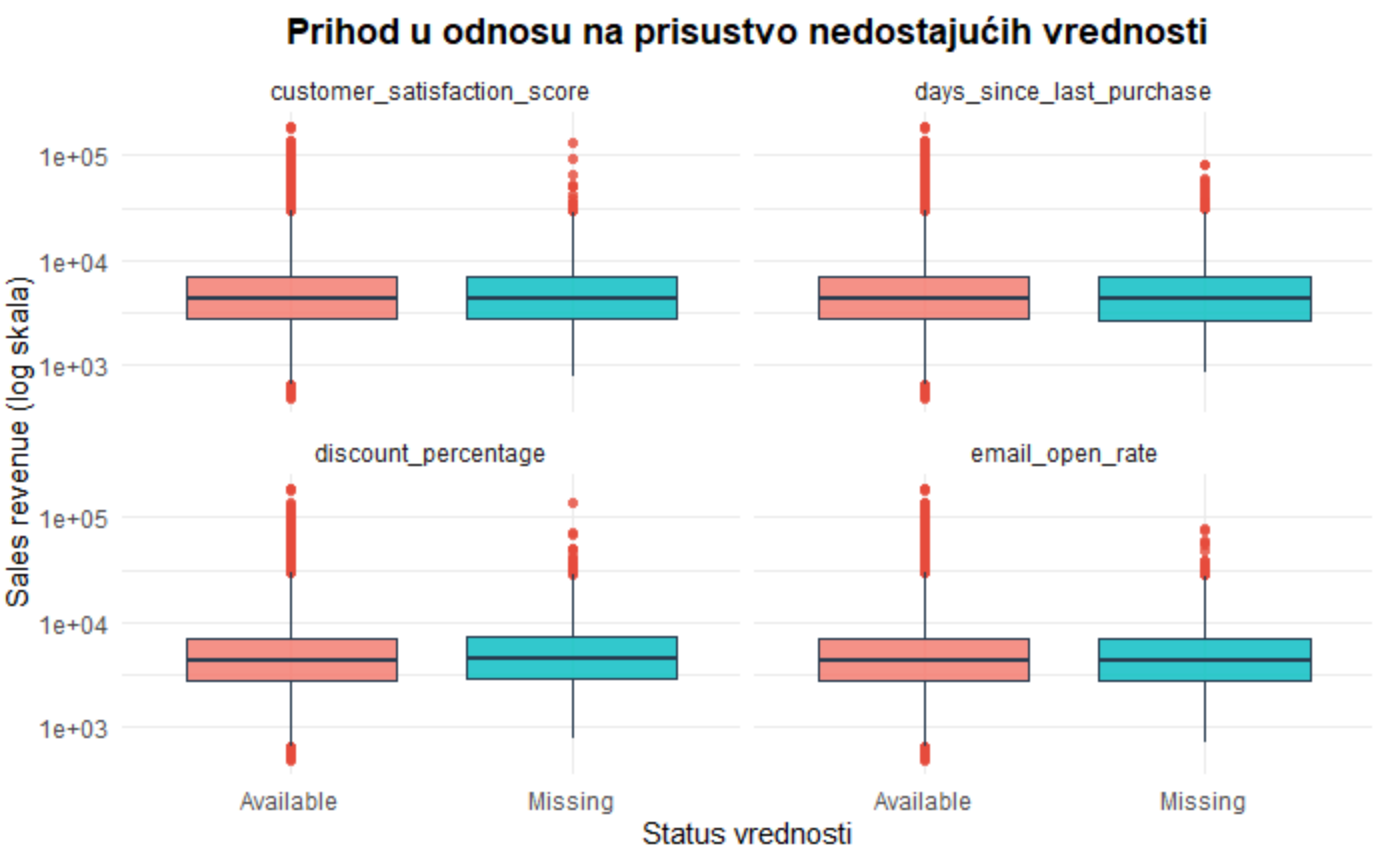
  indicator_name = switch(
    variable,
    discount_percentage = "missing_discount",
    customer_satisfaction_score = "missing_satisfaction",
    email_open_rate = "missing_email",
    days_since_last_purchase = "missing_days"
  )

  target_plot_data[[variable]] = ifelse(
    missingness_data[[indicator_name]] == 1,
    "Missing",
    "Available"
  )
}

target_plot_data_long = target_plot_data %>%
  pivot_longer(
    cols = all_of(missing_variables),
    names_to = "Missing_variable",
    values_to = "Status"
  )

ggplot(
  target_plot_data_long,
  aes(
    x = Status,
    y = sales_revenue_usd,
    fill = Status
  )
) +
  geom_boxplot(
    color = "#2C3E50",
    outlier.color = "#E74C3C",
    outlier.size = 1.5,
    outlier.shape = 16,
    alpha = 0.8
  ) +
  scale_y_log10() +
  facet_wrap(~ Missing_variable) +
  labs(
    title = "Prihod u odnosu na prisustvo nedostajućih vrednosti",
    x = "Status vrednosti",
    y = "Sales revenue (log skala)"
  ) +
  theme_minimal() +
  theme(
    plot.title = element_text(hjust = 0.5, face = "bold"),
    legend.position = "none" # Uklanja legendu ako koristiš fill = Status, pošto su labele već na
x-osi
  )
```

Processing math: 100%



Analizom boxplot dijagrama za sva četiri posmatrana feature-a (customer_satisfaction_score, days_since_last_purchase, discount_percentage i email_open_rate) uočava se da ne postoji značajna razlika u distribuciji prihoda (Sales revenue) između grupa sa prisutnim (Available) i nedostajućim (Missing) vrednostima. Medijane i interkvartilni rasponi prihoda su gotovo identični u obe grupe za svaki feature. Veći broj ekstremnih vrednosti u kategoriji Available posledica je znatno većeg uzorka. Ovi rezultati ukazuju na to da prisustvo nedostajućih vrednosti nije uslovljeno visinom ostvarenog prihoda.

3.11 MCAR analiza

Na osnovu prethodno sprovedenih analiza ispituje se da li je razumno pretpostaviti da nedostajuće vrednosti nastaju potpuno nasumično, odnosno da li je MCAR (Missing Completely At Random) pretpostavka prihvatljiva. Pri tome se ne oslanjamo samo na jedan rezultat, već kombinujemo analizu obrazaca nedostajućih vrednosti, testove nezavisnosti i poređenje ciljne promenljive.Za dodatnu formalnu proveru koristi se MCAR test iz paketa MICE.

Hide

Processing math: 100%

```
# 1. Filtriramo samo numeričke kolone i uklanjamo 'id' ako je ostao
mcar_data = dataset %>%
  select(where(is.numeric)) %>%
  select(-any_of("id"))

# 2. Uzimamo reprezentativni uzorak od 5000 redova radi uštede memorije
set.seed(123)
mcar_data_sample = mcar_data %>%
  slice_sample(n = 5000)

# 3. Pokretanje brze MICE imputacije za test
mcar_imp = mice(
  mcar_data_sample,
  m = 3,
  method = "pmm",
  maxit = 3,
  printFlag = FALSE,
  seed = 123
)

# 4. Pokretanje MCAR testa
mcar_result = mice::mcar(
  mcar_data_sample,
  imputed = mcar_imp,
  replications = 200,
  alpha = 0.05
)

# Prikaz rezultata
mcar_result
```

```
Missing data patterns: 6 used, 7 removed.
Cases used: 4982

Hawkins' test: median chi^2 (12) = 443.9613, median p = 1.808305e-87

Anderson-Darling rank test: median T = 4.550491, median p = 0.4954958

Interpretation of results:
 Hawkins' test is significant; if multivariate normality can be assumed, then reject the assumptio
n that missingness is MCAR.
 Anderson-Darling test is not significant. There is thus evidence against multivariate normality,
but not against MCAR.
```

Formalni Hawkins test je pokazao statističku značajnost usled narušene višedimenzionalne normalnosti podataka. Međutim, Anderson-Darling rank test, koji ne zavisi od pretpostavke normalnosti, nije pokazao statističku značajnost ($p = 0.495$). Kako prethodni χ^2 testovi i poređenja distribucije ciljne promenljive takođe ne ukazuju na povezanost nedostajanja sa posmatranim promenljivama, MCAR (Missing Completely At Random) se prihvata kao razumna radna pretpostavka. Pored toga, primenjena MICE/PMM metoda ostaje u potpunosti metodološki opravdana i u slučaju šireg MAR (Missing At Random) mehanizma.

Processing math: 100%

3.12 Strategija imputacije nedostajućih vrednosti (MICE / PMM)

Nakon analize nedostajućih vrednosti, kao jedinstvena strategija za obradu izabrana je napredna metoda MICE sa PMM (Predictive Mean Matching) algoritmom. Jednostavnije strategije unapred su odbačene iz metodoloških razloga:

Complete-case analiza (uklanjanje redova): dovela bi do nepotrebnog gubitka značajnog dela skupa podataka.

Imputacija medijanom ili srednjom vrednošću: veštački bi smanjila varijansu i narušila prirodne korelacije između atributa.

Hide

```
# Uklanjamo identifikatore i ne-numeričke atribute koji nisu pogodni za PMM
mice_data = dataset %>%
  select(
    -id,
    -date
  )
set.seed(123)
mice_model = mice(
  mice_data,
  m = 5,
  method = "pmm",
  maxit = 5,
  printFlag = FALSE,
  seed = 123
)
```

```
Warning: Number of logged events: 5
```

Hide

```
#data set bez missing values
dataset_clean=complete(mice_model, 1)

#vracanje id i date
dataset_clean$id = dataset$id
dataset_clean$date = dataset$date

#Reorganizacija kolona da budu u originalnom redosledu
dataset_clean = dataset_clean %>%
  select(colnames(dataset))

#Provera: Potvrda da nema preostalih NA vrednosti
colSums(is.na(dataset_clean))
```

Processing math: 100%

```
                        id                       date                     region
sales_channel            product_category
                         0                          0                          0
0                          0
           customer_segment                     season        marketing_budget_usd         ad_spe
nd_online_usd        ad_spend_offline_usd
                         0                          0                          0
0                          0
             num_promotions         discount_percentage   num_sales_representatives
customer_age customer_satisfaction_score
                         0                          0                          0
0                          0
     competitor_price_index             website_traffic             conversion_rate             em
ail_open_rate      social_media_followers
                         0                          0                          0
0                          0
   days_since_last_purchase      num_previous_purchases           sales_revenue_usd
                         0                          0                          0
```

4 Feature engineering

U ovom poglavlju kreiramo nove feature na osnovu postojećih podataka kako bismo modelima mašinskog učenja pružili dodatne ulazne informacije.

Kreirani su sledeći feature-i:

4.1 Kreiranje finansijskih i marketinških pokazatelja

total_ad_spend: Predstavlja koliko je novca ukupno otišlo na reklame, kada saberemo online i offline troškove.

Hide

```
dataset_clean$total_ad_spend = dataset_clean$ad_spend_online_usd + dataset_clean$ad_spend_offline_
usd
```

online_share: Pokazuje koliki udeo u ukupnom budžetu za reklame zauzima baš online oglašavanje, što nam otkriva koliko je neka kampanja digitalno orijentisana.

Hide

```
dataset_clean$online_share = ifelse(dataset_clean$total_ad_spend > 0, dataset_clean$ad_spend_onlin
e_usd / dataset_clean$total_ad_spend, 0)
```

budget_utilization: Pokazuje nam koliki deo ukupno namenjenog budžeta je stvarno potrošen na reklame.

Hide

```
dataset_clean$budget_utilization = ifelse(dataset_clean$marketing_budget_usd > 0, dataset_clean$to
tal_ad_spend / dataset_clean$marketing_budget_usd, 0)
```

unspent_budget: Predstavlja ostatak novca koji je bio planiran u budžetu, ali na kraju nije potrošen na oglašavanje.

Hide

```
dataset_clean$unspent_budget = dataset_clean$marketing_budget_usd - dataset_clean$total_ad_spend
```

Processing math: 100%

spend_per_rep: Predstavlja koliko je novca za reklame potrošeno po jednom prodajnom predstavniku, što nam pomaže da vidimo opterećenje i efikasnost tima na terenu.

Hide

```
dataset_clean$spend_per_rep = dataset_clean$total_ad_spend / dataset_clean$num_sales_representativ
es
```

spend_per_promotion: Predstavlja koliko je novca uloženo po jednoj aktivnoj akciji ili popustu.

Hide

```
dataset_clean$spend_per_promotion =ifelse(dataset_clean$num_promotions > 0, dataset_clean$total_ad
_spend / dataset_clean$num_promotions, dataset_clean$total_ad_spend)
```

budget_per_traffic: Predstavlja odnos između ukupnog budžeta i broja ljudi koji su posetili sajt.

Hide

```
dataset_clean$budget_per_traffic = dataset_clean$marketing_budget_usd / dataset_clean$website_traf
fic
```

4.2 Logaritamske transformacije i analiza distribucija

log_budget, log_traffic, log_followers logaritamski transformisane vrednosti budžeta, poseta sajtu i broja pratilaca,čijom se primenom smanjuje visoka asimetrija podataka i ublažava uticaj ekstremnih vrednosti na modele.

Hide

```
dataset_clean$log_budget = log(dataset_clean$marketing_budget_usd)
dataset_clean$log_traffic = log(dataset_clean$website_traffic)
dataset_clean$log_followers = log(dataset_clean$social_media_followers + 1)
```

4.2.1 Analiza distribucija pre i posle transformacije

Hide

```
summary(dataset_clean[, c("marketing_budget_usd", "log_budget",
                    "website_traffic", "log_traffic",
                    "social_media_followers", "log_followers")])
```

```
 marketing_budget_usd   log_budget     website_traffic    log_traffic     social_media_followers l
og_followers
 Min.   :   500       Min.   : 6.215   Min.   :    100   Min.   : 4.605   Min.   :    100        M
in.   : 4.615
 1st Qu.:  2184       1st Qu.: 7.689   1st Qu.:   2961   1st Qu.: 7.993   1st Qu.:    771        1
st Qu.: 6.649
 Median :  4922       Median : 8.501   Median :   8065   Median : 8.995   Median :   2971        M
edian : 7.997
 Mean   : 10032       Mean   : 8.511   Mean   :  24426   Mean   : 8.995   Mean   :  22198        M
ean   : 8.035
 3rd Qu.: 11040       3rd Qu.: 9.309   3rd Qu.:  22057   3rd Qu.:10.001   3rd Qu.:  11387        3
rd Qu.: 9.340
 Max.   :500000       Max.   :13.122   Max.   :2000000   Max.   :14.509   Max.   :5000000        M
ax.   :15.425
```

Processing math: 100%

Pogled na statistiku pre i posle transformacije odlično ilustruje problem koji smo imali sa originalnim podacima. Kod početnih vrednosti za budžet, posete i pratioce vidimo ogroman raskorak između medijane i proseka (recimo, kod saobraćaja je medijana oko 8.000, a prosek skače na preko 24.000 zbog nekoliko drastično velikih vrednosti na desnom kraju). To znači da su podaci bili prilično razvučeni i asimetrični. Kada smo primenili logaritam prosek i medijana su se praktično poklopili, a ekstremni rasponi su svedeni na normalnu meru. Time smo eliminisali raspon velikih brojeva, pa će modeli moći znatno stabilnije i preciznije da uče na ovim podacima.

4.3 Vremenske karakteristike (Time Features)

month i quarter oznake meseca i kvartala u godini, korisne za praćenje periodičnih skokova u prodaji (poput prazničnih kupovina).

Hide

```
dataset_clean$date = as.Date(dataset_clean$date)
dataset_clean$month = format(dataset_clean$date, "%m")
dataset_clean$quarter = quarters(dataset_clean$date)
```

day_of_week: Dan u nedelji kada je transakcija zabeležena.

Hide

```
dataset_clean$day_of_week = weekdays(dataset_clean$date)
```

is_weekend: Indikator (0 ili 1) koji govori da li je kupovina obavljena tokom vikenda.

Hide

```
dataset_clean$is_weekend =ifelse(dataset_clean$day_of_week %in% c("Saturday", "Sunday"), 1, 0)
```

is_year_end: Pokazuje da li transakcija pada u decembar, period pojačanih prazničnih aktivnosti.

Hide

```
dataset_clean$is_year_end=ifelse(format(dataset_clean$date, "%m") == "12", 1, 0)
```

days_since_start: Linearni trend koji meri koliko je dana prošlo od prvog zabeleženog datuma u setu, hvatajući dugoročni rast ili pad.

Hide

```
dataset_clean$days_since_start = as.numeric(dataset_clean$date - min(dataset_clean$date, na.rm = T
RUE))
```

season: Definiše meteorološku sezonu u kojoj je ostvarena prodaja.

Hide

```
dataset_clean$season = case_when(
  dataset_clean$month %in% c("12", "01", "02") ~ "Zima",
  dataset_clean$month %in% c("03", "04", "05") ~ "Proleće",
  dataset_clean$month %in% c("06", "07", "08") ~ "Leto",
  dataset_clean$month %in% c("09", "10", "11") ~ "Jesen",
  TRUE ~ "Nepoznato"
)
```

Processing math: 100%

4.4 Karakteristike kupaca (Customer Features)

purchase_frequency: Predstavlja intenzitet kupovine, odnosno prosečnu učestalost kojom kupac obavlja transakcije tokom svog aktivnog staža. Računa se stavljanjem u odnos ukupnog broja prethodnih kupovina i efektivnog perioda aktivnosti, čime dobijamo realniju sliku o vernosti kupca nego da posmatramo samo grubu sumu.

Hide

```
dataset_clean$purchase_frequency = ifelse(
  !is.na(dataset_clean$days_since_last_purchase) & dataset_clean$days_since_last_purchase > 0,
  dataset_clean$num_previous_purchases / dataset_clean$days_since_last_purchase,
  dataset_clean$num_previous_purchases
)
```

is_returning: Logički indikator (0 ili 1) koji jasno razdvaja nove kupce od onih stalnih koji se redovno vraćaju.

Hide

```
dataset_clean$is_returning = ifelse(dataset_clean$customer_segment == "Regular" | dataset_clean$nu
m_previous_purchases > 1, 1, 0)
```

customer_age_group: Pretvara numeričku promenljivu godina u kategorijalnu, što modelima mašinskog učenja olakšava prepoznavanje nelinearnih šablona po generacijama.

Hide

```
dataset_clean$customer_age_group = cut(
  dataset_clean$customer_age,
  breaks = c(0, 25, 40, 60, 100),
  labels = c("Mladi (do 25)", "Srednje doba (26-40)", "Stariji (41-60)", "Veterani (60+)"),
  include.lowest = TRUE
)
```

4.5 Tržišne i digitalne karakteristike (Market & Digital Features)

price_advantage: Prikazuje našu cenovnu prednost u odnosu na konkurenciju, dobijenu preko indeksa cene konkurencije (competitor_price_index).

Hide

```
dataset_clean$price_advantage = ifelse(
  !is.na(dataset_clean$competitor_price_index),
  (1-dataset_clean$competitor_price_index ) * 100,
  NA
)
```

effective_discount: Kombinuje procenat odobrenog popusta i broj aktivnih promocija da vidimo ukupni efekat popusta na kupca.

Hide

```
dataset_clean$effective_discount = dataset_clean$discount_percentage * dataset_clean$num_promotion
s
```

estimated_conversions: Daje procenu broja ostvarenih kupovina na osnovu poseta sajtu i stope konverzije.

Processing math: 100%

Hide

```
dataset_clean$estimated_conversions = dataset_clean$website_traffic * dataset_clean$conversion_rat
e
```

traffic_per_follower: Meri odnos poseta sajtu i broja pratilaca na društvenim mrežama.

Hide

```
dataset_clean$traffic_per_follower = dataset_clean$website_traffic / (dataset_clean$social_media_f
ollowers + 1)
```

4.6 Interakcije feature-a (Feature Interactions)

segment_product: Kombinuje segment kupaca i kategoriju proizvoda, da vidimo koji tipovi kupaca preferiraju koje proizvode.

Hide

```
dataset_clean$segment_product = as.factor(paste(dataset_clean$customer_segment, dataset_clean$prod
uct_category, sep = "_"))
```

season_product: Spaja sezonu i kategoriju proizvoda radi praćenja sezonskih promena u potražnji.

Hide

```
dataset_clean$season_product = as.factor(paste(dataset_clean$season, dataset_clean$product_categor
y, sep = "_"))
```

channel_segment: Povezuje kanal prodaje sa segmentom kupaca, otkrivajući preko kog kanala koji kupci najčešće trguju.

Hide

```
dataset_clean$channel_segment = as.factor(paste(dataset_clean$sales_channel, dataset_clean$custome
r_segment, sep = "_"))
```

4.7 Provera i verifikacija novih feature-a

Proveravamo sve nove feature kako bismo utvrdili osnovnu statistiku, potvrdili ispravnost formula i osigurali da u njima nema neočekivanih anomalija.

Hide

```
engineered_cols = c(
  "total_ad_spend", "online_share", "budget_utilization", "unspent_budget",
  "spend_per_rep", "spend_per_promotion", "budget_per_traffic", "log_budget",
  "log_traffic", "log_followers", "purchase_frequency", "price_advantage",
  "effective_discount", "estimated_conversions", "traffic_per_follower"
)

summary(dataset_clean[, engineered_cols])
```

Processing math: 100%

```
 total_ad_spend      online_share    budget_utilization unspent_budget      spend_per_rep       sp
end_per_promotion budget_per_traffic    log_budget
 Min.   :   153.9   Min.   :0.3339   Min.   :0.3045     Min.   :     1.31   Min.   :     3.42   Mi
n.   :    18.1    Min.   :   0.0004   Min.   : 6.215
 1st Qu.:  1366.2   1st Qu.:0.5365   1st Qu.:0.5450     1st Qu.:   645.42   1st Qu.:    58.16   1s
t Qu.:   322.8    1st Qu.:   0.1686   1st Qu.: 7.689
 Median :  3106.8   Median :0.6158   Median :0.6492     Median :  1567.84   Median :   153.09   Me
dian :   843.8    Median :   0.6127   Median : 8.501
 Mean   :  6527.3   Mean   :0.6145   Mean   :0.6497     Mean   :  3504.66   Mean   :   599.53   Me
an   :  2491.3    Mean   :   3.6987   Mean   : 8.511
 3rd Qu.:  7085.8   3rd Qu.:0.6970   3rd Qu.:0.7541     3rd Qu.:  3738.19   3rd Qu.:   426.83   3r
d Qu.:  2295.0    3rd Qu.:   2.1937   3rd Qu.: 9.309
 Max.   :373539.1   Max.   :0.8563   Max.   :0.9986     Max.   :269750.48   Max.   :248764.70   Ma
x.   :327448.9    Max.   :2091.6051   Max.   :13.122
  log_traffic     log_followers    purchase_frequency price_advantage     effective_discount estim
ated_conversions traffic_per_follower
 Min.   : 4.605   Min.   : 4.615   Min.   : 0.00000   Min.   :-30.00000   Min.   :  0.00     Min.
:     0.0      Min.   :    0.000
 1st Qu.: 7.993   1st Qu.: 6.649   1st Qu.: 0.01645   1st Qu.:-15.00000   1st Qu.: 21.40     1st Q
u.:   189.3      1st Qu.:    0.504
 Median : 8.995   Median : 7.997   Median : 0.02747   Median :  0.00000   Median : 66.00     Media
n :   586.1      Median :    2.705
 Mean   : 8.995   Mean   : 8.035   Mean   : 0.10485   Mean   : -0.03432   Mean   : 90.01     Mean
:  2228.9      Mean   :   35.198
 3rd Qu.:10.001   3rd Qu.: 9.340   3rd Qu.: 0.05556   3rd Qu.: 15.00000   3rd Qu.:140.55     3rd Q
u.:  1794.1      3rd Qu.:   14.315
 Max.   :14.509   Max.   :15.425   Max.   :12.00000   Max.   : 30.00000   Max.   :360.00     Max.
:447200.0      Max.   :19801.980
```

Hide

```
colSums(is.na(dataset_clean[, engineered_cols]))
```

```
       total_ad_spend          online_share    budget_utilization        unspent_budget         sp
end_per_rep   spend_per_promotion    budget_per_traffic
                   0                     0                     0                     0
0                     0                     0
           log_budget           log_traffic         log_followers    purchase_frequency       pric
e_advantage    effective_discount estimated_conversions
                   0                     0                     0                     0
0                     0                     0
 traffic_per_follower
                   0
```

Hide

```
sapply(dataset_clean[, engineered_cols], function(x) sum(is.infinite(x)))
```

Processing math: 100%

```
       total_ad_spend          online_share    budget_utilization        unspent_budget         sp
end_per_rep   spend_per_promotion    budget_per_traffic
                    0                     0                     0                     0
0                     0                     0
           log_budget           log_traffic         log_followers    purchase_frequency       pric
e_advantage    effective_discount estimated_conversions
                    0                     0                     0                     0
0                     0                     0
 traffic_per_follower
                    0
```

Nakon detaljnog pregleda statistike, potvrđeno je da su svi novi feature-i uspešno generisani i da se kreću u očekivanim i logičnim opsezima.

4.8 Prevencija curenja podataka (Target Leakage Prevention)

Treba programski osigurati i verifikovati da nijedan od novih feature-a u svom nazivu ili definiciji ne koristi našu ciljnu promenljivu (sales_revenue_usd), čime sprečavamo direktno curenje podataka.

Hide

```
target_variable = "sales_revenue_usd"
contains_target = any(grepl(target_variable, engineered_cols, fixed = TRUE))
stopifnot("GREŠKA: Curenje podataka! Novi feature-i koriste sales_revenue_usd!" = !contains_targe
t)
print("Verifikacija uspešna: Nijedan kreirani feature ne koristi ciljnu promenljivu (sales_revenue
```

```
[1] "Verifikacija uspešna: Nijedan kreirani feature ne koristi ciljnu promenljivu (sales_revenue_u
sd)."
```

Uspešno smo proverili da nijedan novi feature ne koristi ciljnu promenljivu sales_revenue_usd

U ovom koraku treba da analiziramo korelacije između novih numeričkih feature-a i ciljne promenljive (sales_revenue_usd) kako bismo otkrili da li neki od feature-a ima nerealno visoku ili sumnjivu povezanost koja bi ukazivala na indirektno curenje podataka (target leakage).

Hide

```
num_engineered = c(
  "total_ad_spend", "online_share", "budget_utilization", "unspent_budget",
  "spend_per_rep", "spend_per_promotion", "budget_per_traffic", "log_budget",
  "log_traffic", "log_followers", "purchase_frequency", "price_advantage",
  "effective_discount", "estimated_conversions", "traffic_per_follower"
)
target_correlations = cor(dataset_clean[, num_engineered], dataset_clean[[target_variable]], use =
"complete.obs")
print(target_correlations)
```

Processing math: 100%

```
                           [,1]
total_ad_spend        0.710056059
online_share          0.011667296
budget_utilization    0.017407035
unspent_budget        0.640161722
spend_per_rep         0.304261014
spend_per_promotion   0.494403718
budget_per_traffic    0.274839884
log_budget            0.510878556
log_traffic           0.007151737
log_followers         0.001440236
purchase_frequency    0.004273627
price_advantage       0.017223933
effective_discount    0.011457837
estimated_conversions 0.025215368
traffic_per_follower  0.010337753
```

Pregledom matrice korelacija vidimo da se sve vrednosti kreću u umerenim i očekivanim granicama.Nema sumnjivih korelacija bliskih 1.0, što potvrđuje da nijedan novokreirani atribut ne odaje informaciju o krajnjem prihodu unapred i da nema opasnosti od target leakage-a. Time smo i zvanično dokumentovali da su sve provere i mere zaštite od curenja podataka uspešno sprovedene.

5 Eksplorativna analiza podataka (EDA) i analize outlier-a

U ovom poglavlju sprovodimo univarijatnu analizu numeričkih i kategorijskih feature-a, analiziramo distribuciju i transformaciju ciljne promenljive (sales_revenue_usd), kao i detaljnu analizu outlier-a primenom IQR metode.

5.1 Univarijatna analiza numeričkih i kategorijskih feature-a

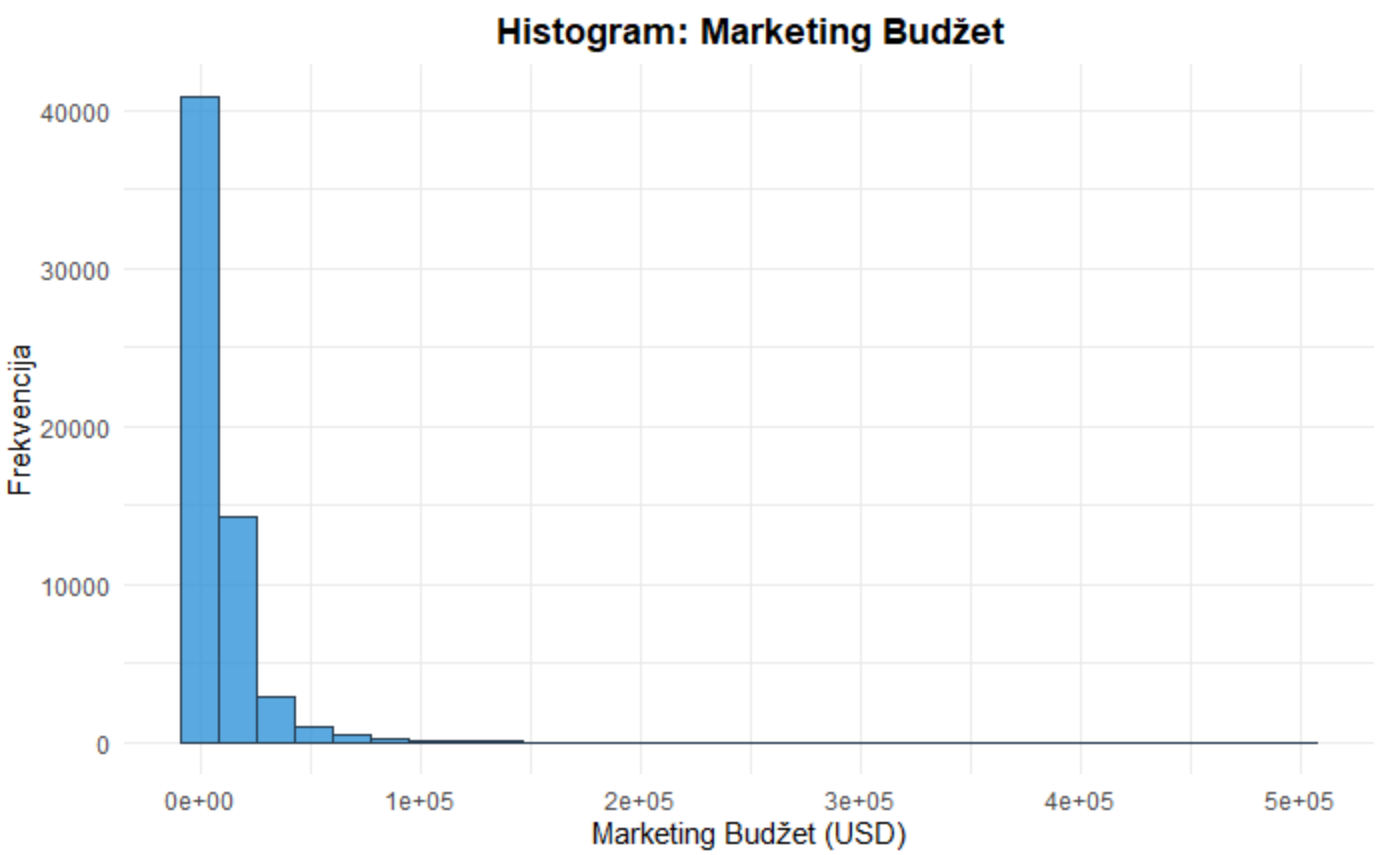
Univarijatna analiza nam omogućava da sagledamo distribuciju, oblike asimetrije i zastupljenost vrednosti kroz ključne numeričke i kategorijske atribute.

5.1.1 Analiza marketing budžeta (marketing_budget_usd)

Hide

```
ggplot(dataset_clean, aes(x = marketing_budget_usd)) +
  geom_histogram(bins = 30, fill = "#3498DB", color = "#2C3E50", alpha = 0.8) +
  theme_minimal() +
  labs(title = "Histogram: Marketing Budžet",
       x = "Marketing Budžet (USD)",
       y = "Frekvencija") +
  theme(plot.title = element_text(hjust = 0.5, face = "bold"))
```

Processing math: 100%



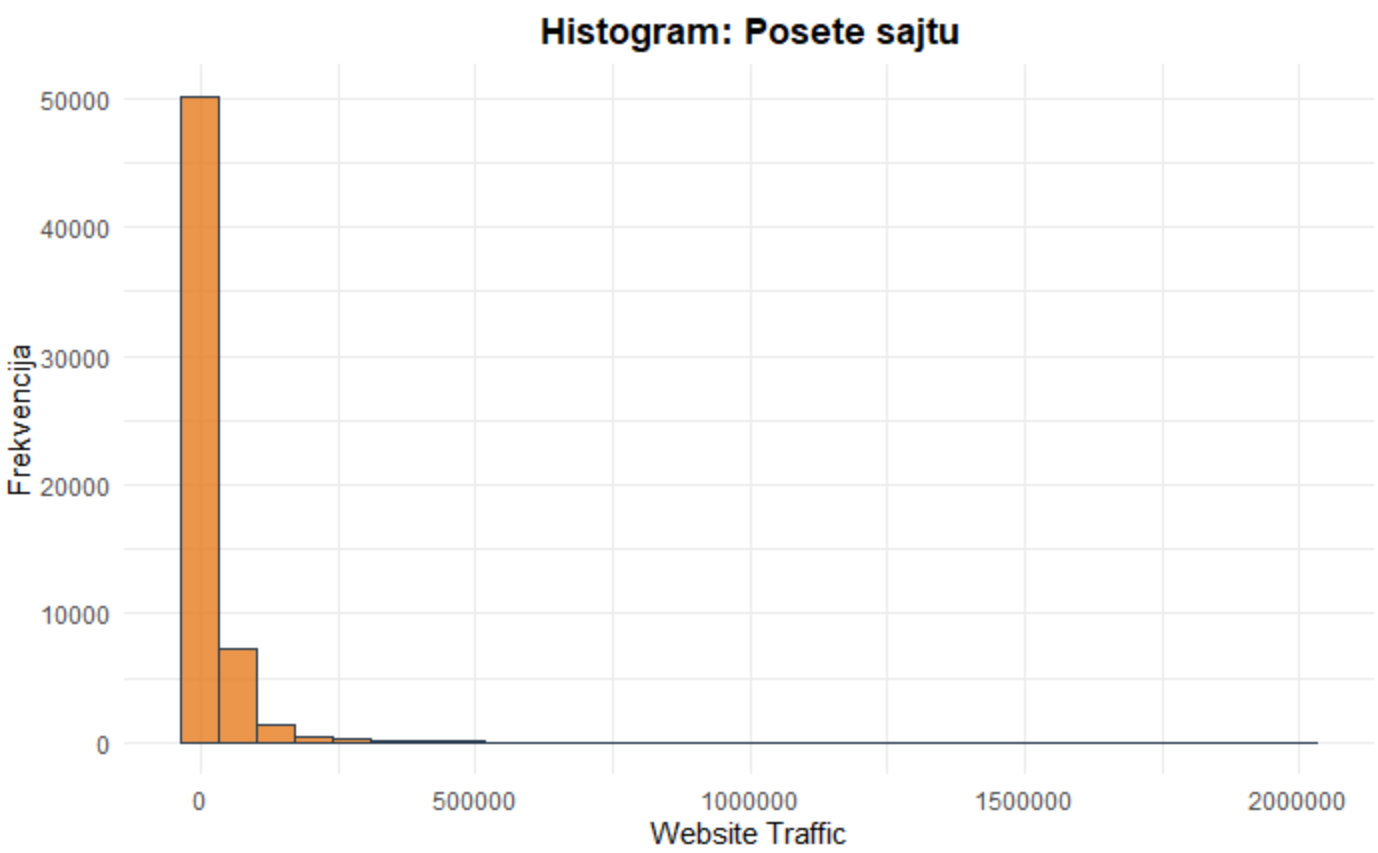
Histogram analiza marketing budžeta ukazuje na to da su iznosi većinski locirani u nižem i srednjem opsegu, dok se frekvencija postepeno smanjuje ka većim vrednostima. Ova desna asimetrija ukazuje na to da je većina kampanja imala umerena ulaganja, uz manji broj kampanja sa visokim budžetima.

5.1.2 Analiza poseta sajtu (website_traffic)

Hide

```
ggplot(dataset_clean, aes(x = website_traffic)) +
  geom_histogram(bins = 30, fill = "#E67E22", color = "#2C3E50", alpha = 0.8) +
  theme_minimal() +
  labs(title = "Histogram: Posete sajtu",
       x = "Website Traffic",
       y = "Frekvencija") +
  theme(plot.title = element_text(hjust = 0.5, face = "bold"))
```

Processing math: 100%



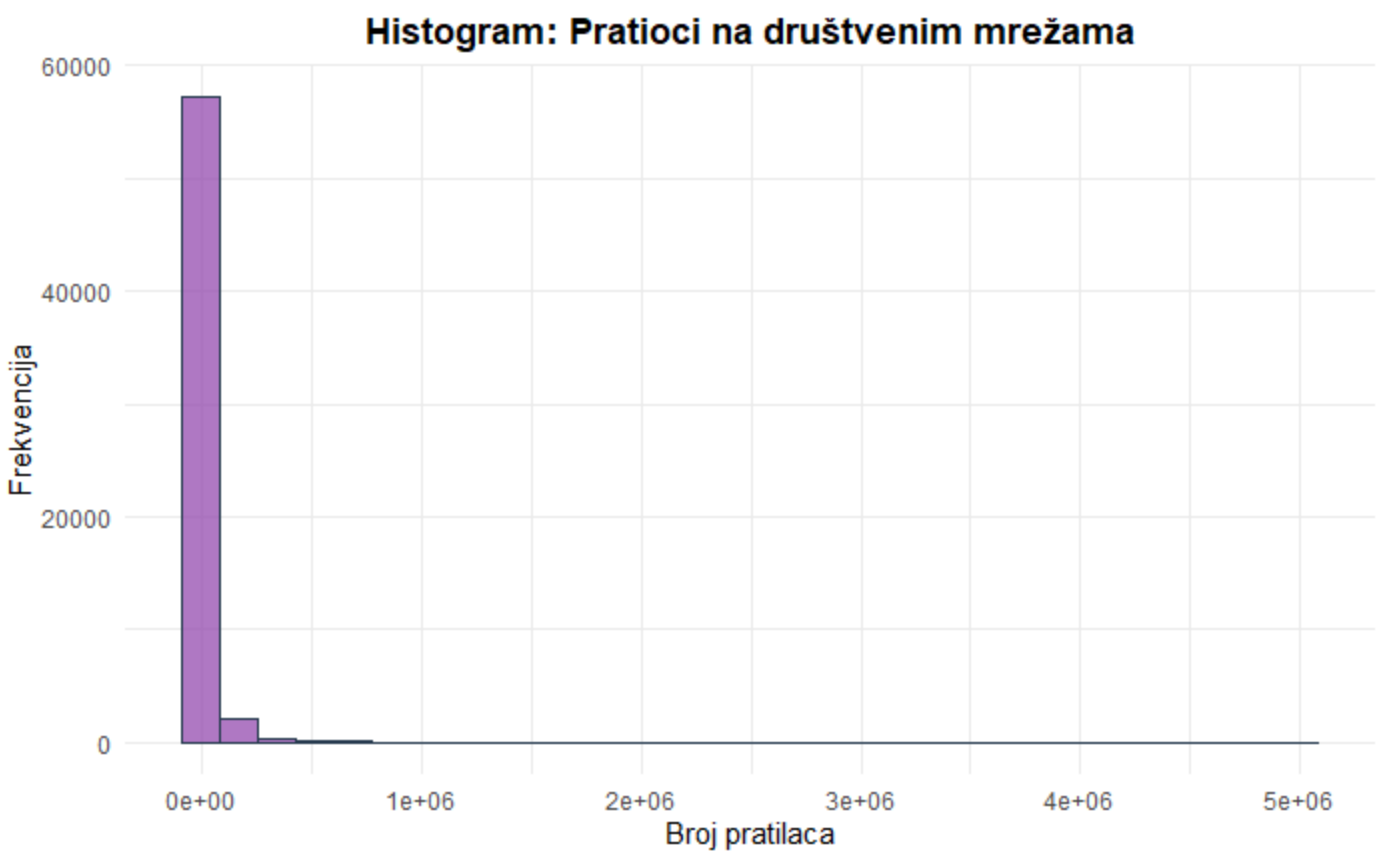
Histogram analiza poseta sajtu ukazuje na to da većina opservacija beleži niži nivo posećenosti, dok mali broj objava ili kampanja privlači izuzetno veliki saobraćaj, što stvara jaku pozitivnu asimetriju.

5.1.3 Analiza broja pratilaca na društvenim mrežama (social_media_followers)

Hide

```
ggplot(dataset_clean, aes(x = social_media_followers)) +
  geom_histogram(bins = 30, fill = "#9B59B6", color = "#2C3E50", alpha = 0.8) +
  theme_minimal() +
  labs(title = "Histogram: Pratioci na društvenim mrežama",
       x = "Broj pratilaca",
       y = "Frekvencija") +
  theme(plot.title = element_text(hjust = 0.5, face = "bold"))
```

Processing math: 100%



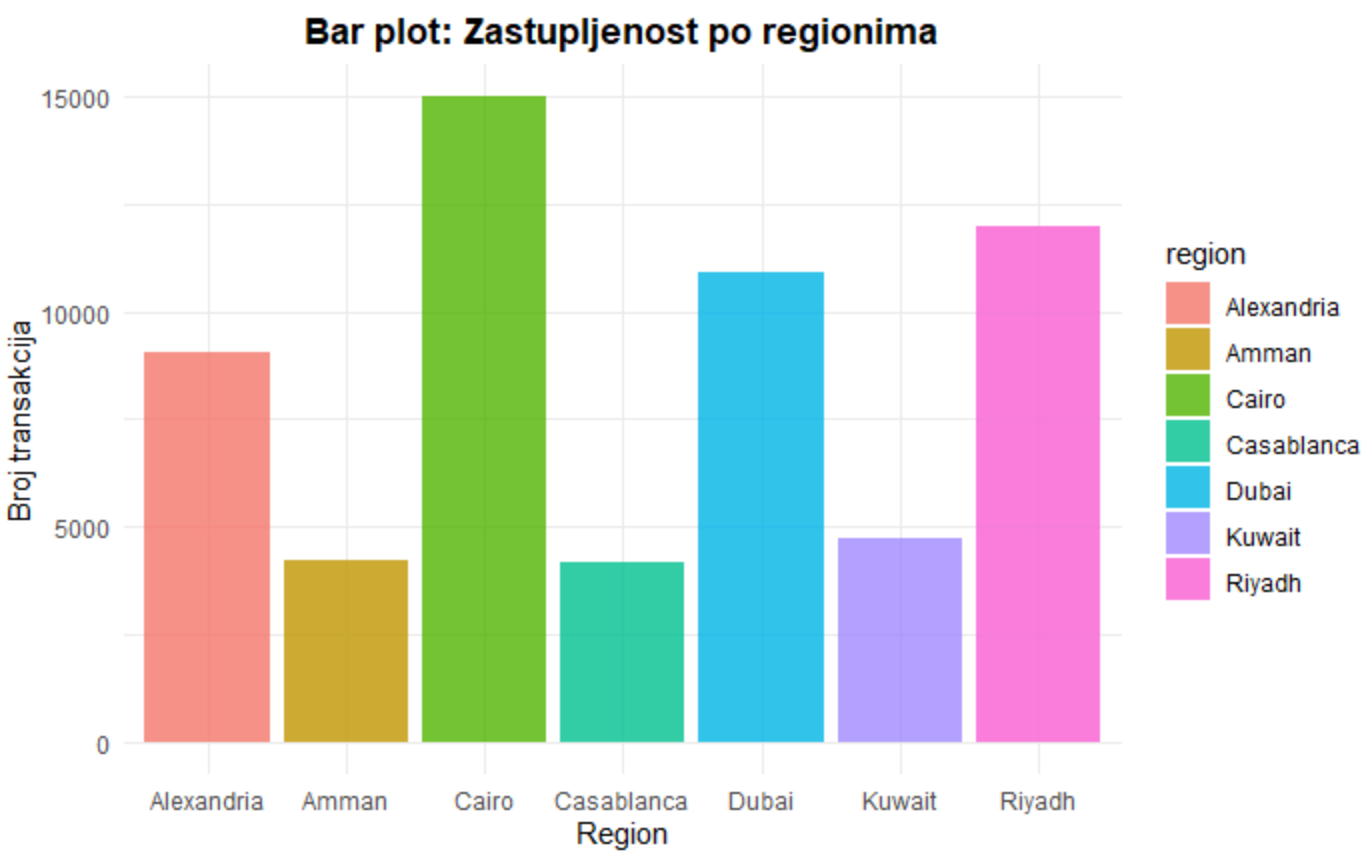
Histogram analiza pratioca na društvenim mrežama ukazuje na to da broj pratilaca pokazuje visoku koncentraciju vrednosti na početnom delu skale. I ovde je primetno odsustvo normalne raspodele, što opravdava ranije uvedenu logaritamsku transformaciju radi lakšeg modelovanja.

5.1.4 Transakcije po regionima (region)

Hide

```
ggplot(dataset_clean, aes(x = region, fill = region)) +
  geom_bar( alpha = 0.8, show.legend = TRUE) +
  theme_minimal() +
  labs(title = "Bar plot: Zastupljenost po regionima",
       x = "Region",
       y = "Broj transakcija") +
  theme(plot.title = element_text(hjust = 0.5, face = "bold"))
```

Processing math: 100%



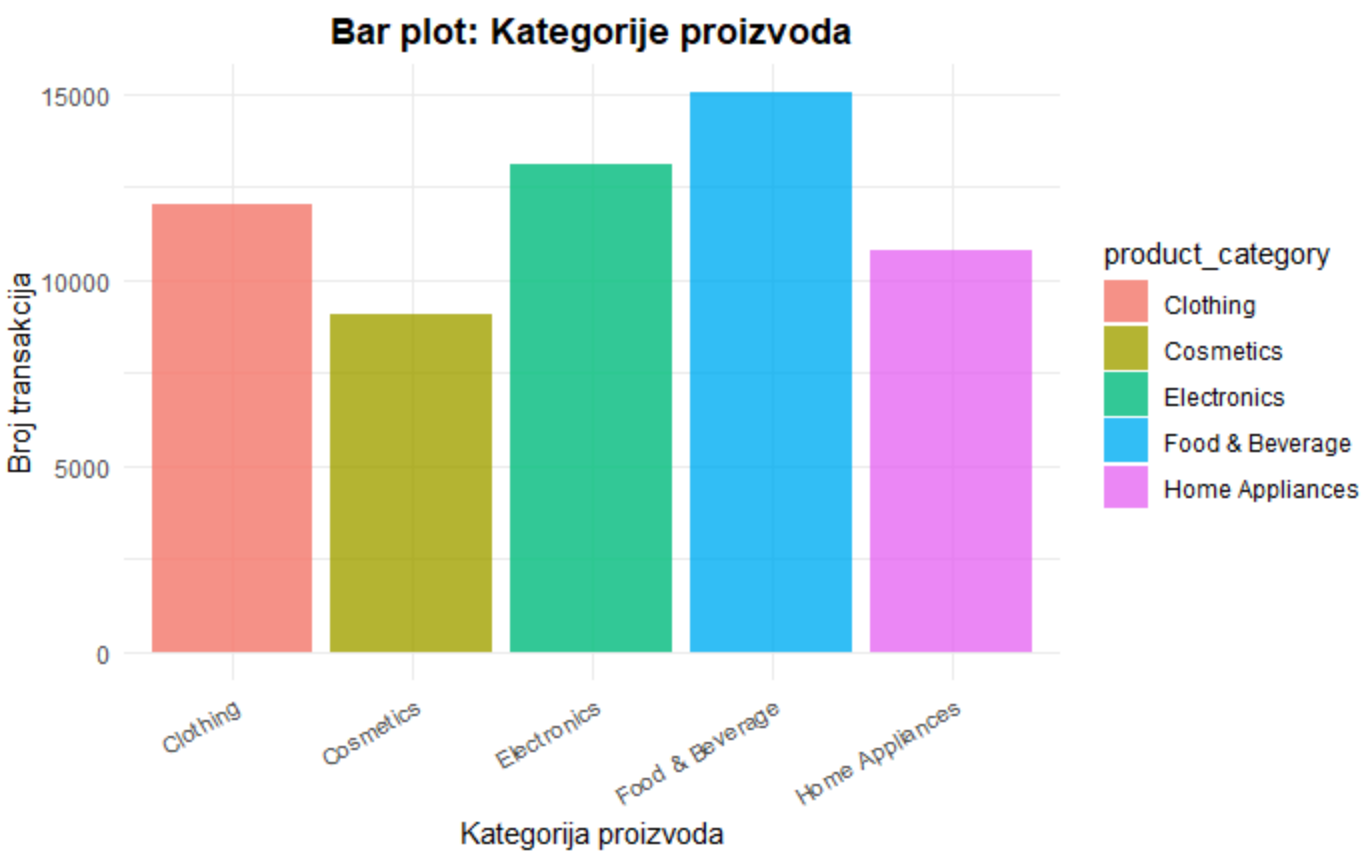
Grafik pokazuje značajne varijacije u ukupnom broju transakcija po regionima. Dok gradovi poput Kaira, Rijada i Aleksandrije beleže najveći obim transakcija, drugi regioni poput Amana, Kasablanke i Kuvajta imaju znatno manju zastupljenost u bazi.

5.1.5 Kategorije proizvoda (product_category)

Hide

```
ggplot(dataset_clean, aes(x = product_category, fill = product_category)) +
  geom_bar(alpha = 0.8, show.legend = TRUE) +
  theme_minimal() +
  labs(title = "Bar plot: Kategorije proizvoda",
       x = "Kategorija proizvoda",
       y = "Broj transakcija") +
  theme(plot.title = element_text(hjust = 0.5, face = "bold"),
        axis.text.x = element_text(angle = 30, hjust = 1))
```

Processing math: 100%



Kategorije proizvoda su ravnomerno zastupljene u uzorku. Nema ekstremnih oscilacija niti dominacije jedne kategorije nauštrb ostalih, što obezbeđuje kvalitetnu osnovu i stabilnost podataka za dalje modelovanje i analizu uticaja pojedinačnih kategorija na prihode.

5.2 Analiza i transformacija ciljne promenljive (sales_revenue_usd)

5.2.1 Izračunavanje asimetrije originalne ciljne promenljive

Hide

```
calculate_skewness = function(x) {
  n = length(x)
  sum((x - mean(x))^3) / (n * sd(x)^3)
}

original_skew = calculate_skewness(dataset_clean$sales_revenue_usd)
print(paste("Asimetrija (Skewness) originalnog prihoda:", round(original_skew, 4)))
```

```
[1] "Asimetrija (Skewness) originalnog prihoda: 6.6312"
```

To je izuzetno visoka pozitivna asimetrija, što znači da je prihod narušen malim brojem ogromnih vrednosti koje vuku prosek daleko udesno.

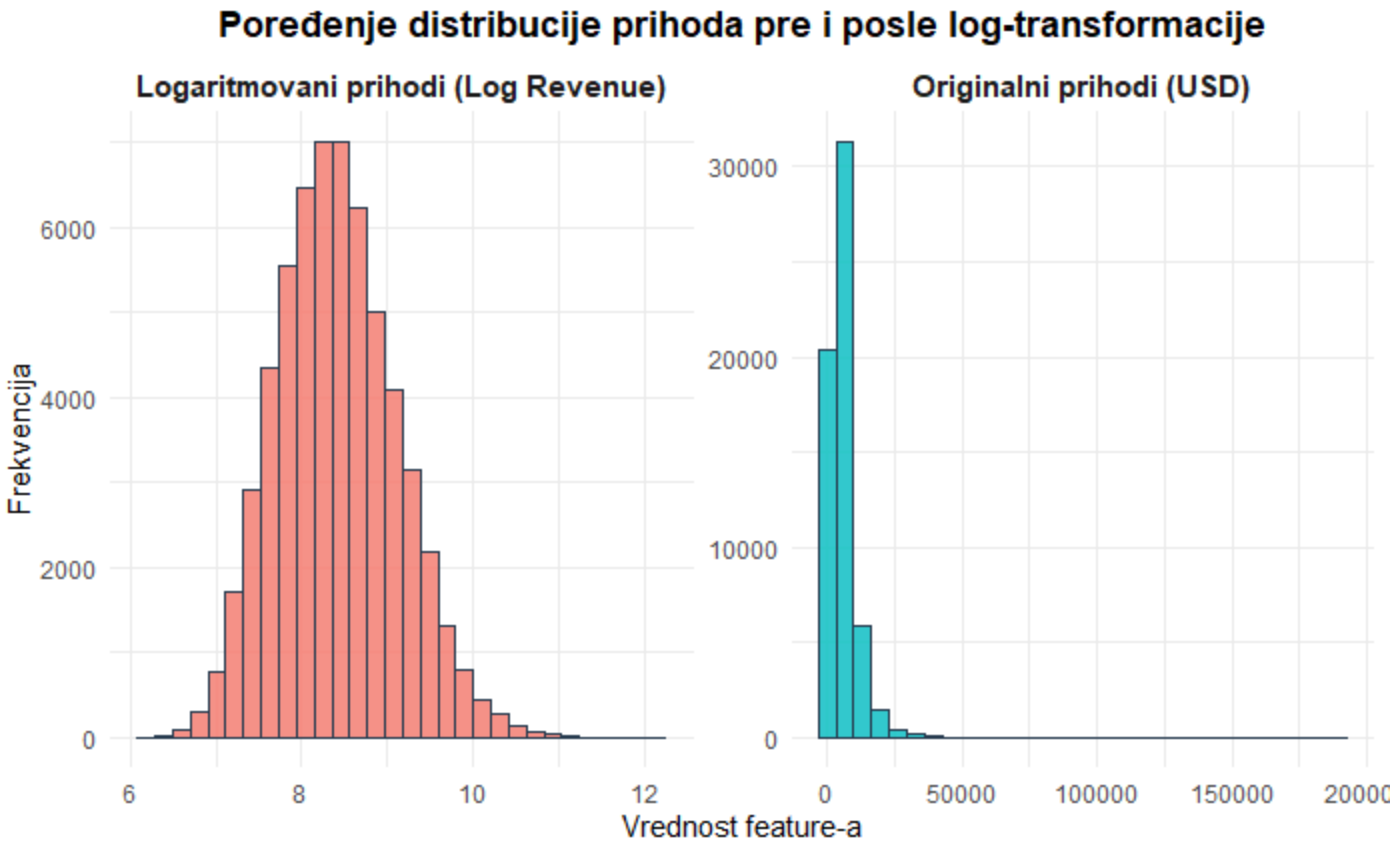
5.2.2 Poređenje originalne i logaritamske distribucije prihoda

Hide

Processing math: 100%

```
dataset_clean$log_revenue = log(dataset_clean$sales_revenue_usd)
revenue_comparison_df = dataset_clean %>%
  select(sales_revenue_usd, log_revenue) %>%
  pivot_longer(everything(), names_to = "Metric", values_to = "Value")

ggplot(revenue_comparison_df, aes(x = Value, fill = Metric)) +
  geom_histogram(bins = 30, color = "#2C3E50", alpha = 0.8, show.legend = FALSE) +
  facet_wrap(~ Metric, scales = "free", ncol = 2,
             labeller = labeller(Metric = c("sales_revenue_usd" = "Originalni prihodi (USD)",
                                            "log_revenue" = "Logaritmovani prihodi (Log Revenu
e)"))) +
  theme_minimal() +
  labs(title = "Poređenje distribucije prihoda pre i posle log-transformacije",
       x = "Vrednost feature-a", y = "Frekvencija") +
  theme(plot.title = element_text(hjust = 0.5, face = "bold"),
        strip.text = element_text(face = "bold", size = 11))
```



Matematička analiza potvrđuje izuzetno visoku pozitivnu asimetriju originalnog prihoda (skewness = 6.63). Sa desne strane grafikona prikazan je originalni prihod sa izraženim dugim desnim repom. Primena logaritamske transformacije (levo) uspešno svodi distribuciju na stabilan, približno normalan oblik

5.2.3 Q-Q plot za proveru normalnosti log-transformisanog prihoda

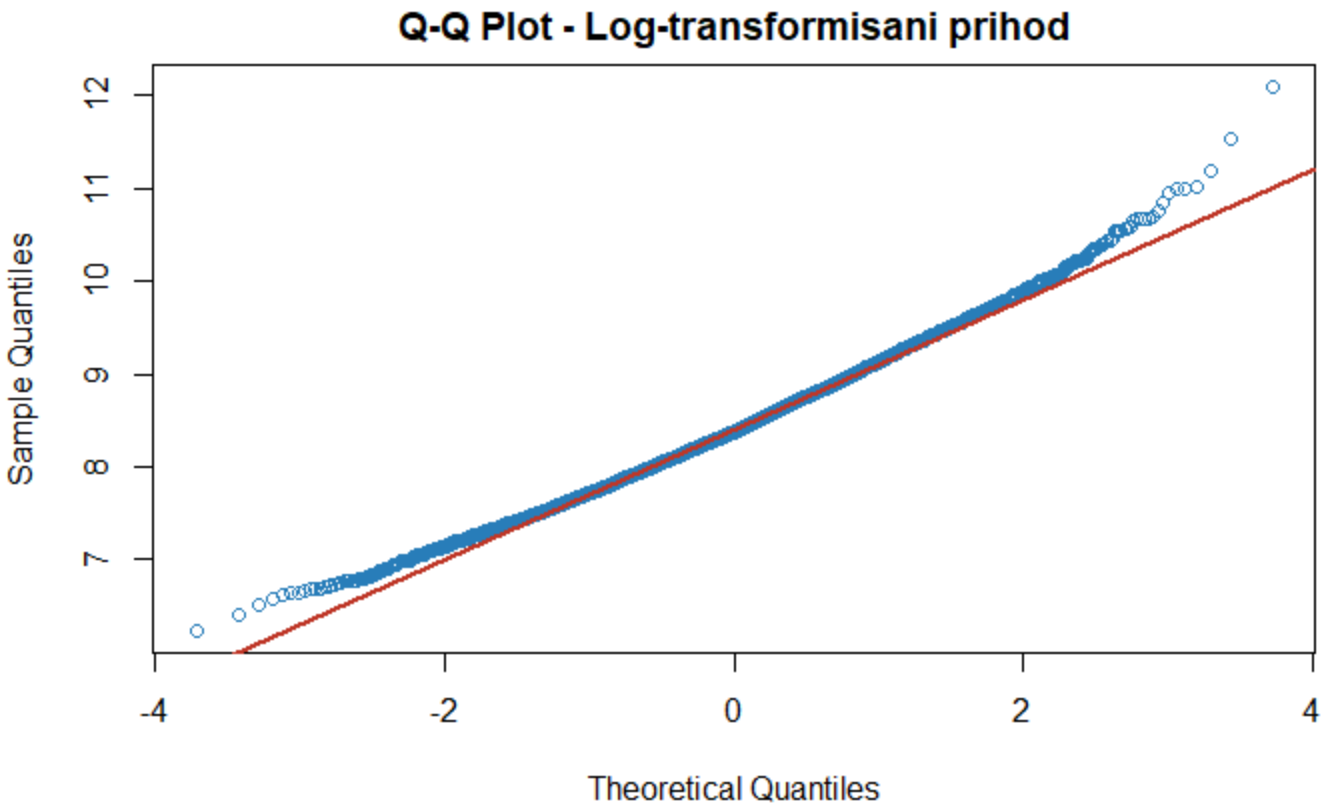
Hide

```
set.seed(123)

sample_revenue = sample(dataset_clean$log_revenue, min(5000, length(dataset_clean$log_revenue)))

qqnorm(sample_revenue, main = "Q-Q Plot - Log-transformisani prihod", col = "#2980B9")
qqline(sample_revenue, col = "#C0392B", lwd = 2)
```

Processing math: 100%



Q-Q plot nam pokazuje da se tačkice u sredini lepo drže linije, uz neka manja odstupanja na krajevima, ovo nam potvrđuje da je log-transformacija uspešno prilagodila podatke u formu koja je sasvim stabilna za dalje modelovanje.

5.3 Analiza outlier-a

Identifikujemo ekstremne opservacije za prihod primenom interkvartilnog opsega (IQR). Važna napomena: outlier-i se ne brišu automatski.

Hide

```
Q1 = quantile(dataset_clean$sales_revenue_usd, 0.25)
Q3 = quantile(dataset_clean$sales_revenue_usd, 0.75)
IQR_value = Q3 - Q1

lower_bound = Q1 - 1.5 * IQR_value
upper_bound = Q3 + 1.5 * IQR_value

outliers_revenue = dataset_clean$sales_revenue_usd[dataset_clean$sales_revenue_usd < lower_bound |
dataset_clean$sales_revenue_usd > upper_bound]

print(paste("Donja granica:", round(lower_bound, 2)))
```

```
[1] "Donja granica: -3777"
```

Hide

```
print(paste("Gornja granica:", round(upper_bound, 2)))
```

```
[1] "Gornja granica: 13612.81"
```

Processing math: 100%

Hide

```
print(paste("Broj identifikovanih outlier-a po IQR metodi:", length(outliers_revenue)))
```

```
[1] "Broj identifikovanih outlier-a po IQR metodi: 3816"
```

Hide

```
print(paste("Procenat outlier-a u ukupnom skupu:", round((length(outliers_revenue) / nrow(dataset_clean)) * 100, 2), "%"))
```

```
[1] "Procenat outlier-a u ukupnom skupu: 6.36 %"
```

Formula nam je izbacila gornju granicu na 13.612,81 USD, a sve preko toga je označila kao outlier. Tako smo dobili 3.816 takvih redova, što čini 6,36% ukupnog skupa podataka.

Iako deluje kao veliki procenat, u svetu prodaje i marketinga skroz je normalno da neke kampanje iskoče i ostvaruju znatno više prihode u odnosu na prosek. To nisu nikakve greške, već naši najuspešniji rezultati. Upravo zato ovi outlier-i nisu uklonjeni iz skupa podataka, kako se ne bi izgubile dragocene informacije i model ne bi imao na čemu da uči šta zapravo donosi najveći profit.

5.4 Korelaciona analiza feature-a

U ovom delu sprovodimo ispitivanje međusobne povezanosti numeričkih atributa. Pošto pojedine promenljive u našem skupu podataka pokazuju izraženu asimetriju i prisustvo ekstremnih vrednosti, koristimo Spearman-ov koeficijent korelacije, pošto on meri monotonu povezanost i otporniji je na outlier-e u odnosu na standardni Pearson-ov koeficijent.

5.4.1 Izračunavanje Spearmanove matrice korelacije

Hide

```
numeric_cols_for_corr = dataset_clean %>%
  select(
    sales_revenue_usd, marketing_budget_usd, ad_spend_online_usd,
    ad_spend_offline_usd, num_promotions, discount_percentage,
    num_sales_representatives, customer_age, customer_satisfaction_score,
    competitor_price_index, website_traffic, conversion_rate,
    email_open_rate, social_media_followers, days_since_last_purchase,
    num_previous_purchases, total_ad_spend, online_share,
    budget_utilization, unspent_budget, spend_per_rep,
    spend_per_promotion, budget_per_traffic, purchase_frequency,
    traffic_per_follower
  )


spearman_matrix = cor(numeric_cols_for_corr, method = "spearman", use = "complete.obs")

revenue_correlations = sort(spearman_matrix["sales_revenue_usd", ], decreasing = TRUE)
print("Spearman-ove korelacije sa ciljnom promenljivom (sales_revenue_usd):")
```

```
[1] "Spearman-ove korelacije sa ciljnom promenljivom (sales_revenue_usd):"
```

Hide

Processing math: 100%

```
print(round(revenue_correlations, 3))
```

```
          sales_revenue_usd        marketing_budget_usd              total_ad_spend          ad_spe
nd_online_usd        ad_spend_offline_usd
                      1.000                       0.517                       0.511
0.505                       0.492
             unspent_budget               spend_per_rep         spend_per_promotion          budge
t_per_traffic      num_previous_purchases
                      0.468                       0.423                       0.392
0.309                       0.092
customer_satisfaction_score             conversion_rate          purchase_frequency              n
um_promotions          budget_utilization
                      0.070                       0.070                       0.063
0.061                       0.019
            website_traffic                online_share        traffic_per_follower
customer_age             email_open_rate
                      0.014                       0.011                       0.010
0.007                       0.005
     social_media_followers   num_sales_representatives    days_since_last_purchase      competito
r_price_index         discount_percentage
                     -0.003                      -0.008                      -0.014
-0.025                      -0.045
```

Kada izdvojimo korelacije sa ciljnom promenljivom (sales_revenue_usd), vidimo da finansijska ulaganja (marketing_budget_usd, total_ad_spend) ostvaruju umerene pozitivne vrednosti (oko 0.5), dok feature poput poseta sajtu (website_traffic) i društvenih mreža pokazuju potpuno neutralnu korelaciju. To ukazuje na to da veći budžeti prate veći prihod, ali da sama masovna vidljivost ne garantuje profit bez efikasnih konverzija.

5.4.2 Vizuelni prikaz korelacije (Correlation matrix plot)

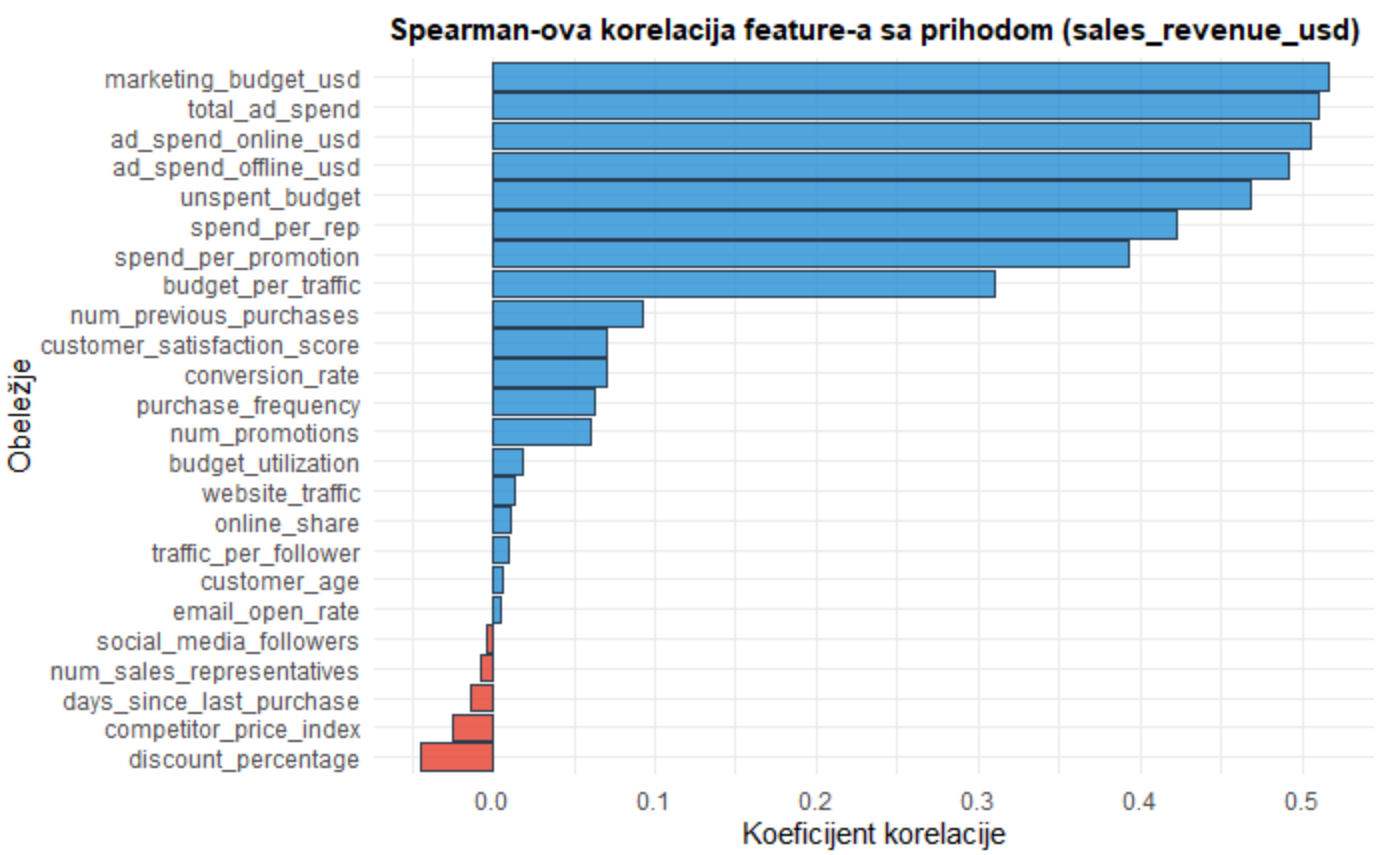
Umesto klasične velike matrice koja može biti nepregledna sa velikim brojem feature-a, korelacije direktno u odnosu na našu ciljnu promenljivom (sales_revenue_usd) prikazujemo preglednim horizontalnim stubastim dijagramom.

Hide

```
revenue_corr_df = data.frame(
  Feature = names(revenue_correlations),
  Correlation = as.numeric(revenue_correlations)
) %>%
  filter(Feature != "sales_revenue_usd") # Uklanjamo samopovezivanje (1.0)

ggplot(revenue_corr_df, aes(x = reorder(Feature, Correlation), y = Correlation, fill = Correlation
> 0)) +
  geom_col(alpha = 0.85, color = "#2C3E50") +
  coord_flip() +
  scale_fill_manual(values = c("#E74C3C", "#3498DB"), guide = "none") +
  theme_minimal() +
  labs(title = "Spearman-ova korelacija feature-a sa prihodom (sales_revenue_usd)",
       x = "Obeležje",
       y = "Koeficijent korelacije") +
  theme(plot.title = element_text(hjust = 0.5, face = "bold", size = 11),
        axis.text.y = element_text(size = 9))
```

Processing math: 100%



Sa grafika se jasno izdvajaju tri grupe feature-a u odnosu na prihod (sales_revenue_usd):

Snažne pozitivne veze: Finansijska ulaganja (marketing_budget_usd, total_ad_spend, onlajn/oflajn budžeti) imaju najveći uticaj sa korelacijama oko 0.5.

Neutralna zona: Većina ostalih feature-a (poput poseta sajtu i ocena zadovoljstva) ima korelaciju blisku nuli, što znači da nemaju direktan linearni uticaj na prihod.

Blage negativne veze: Indeks cena konkurencije i popusti (discount_percentage) nalaze se na dnu tabele sa blago negativnim koeficijentom korelacije, što ukazuje na to da visina odobrenog popusta u ovom skupu podataka nema direktnu pozitivnu povezanost sa ukupnim ostvarenim prihodom.

5.4.3 Identifikovanje snažnih veza i redundantnih feature-a

Hide

```
get_high_correlations = function(matrix, threshold = 0.75) {
  cor_df = as.data.frame(as.table(matrix))
  names(cor_df) = c("Var1", "Var2", "Correlation")
  cor_df = cor_df %>%
    filter(as.character(Var1) < as.character(Var2)) %>%
    filter(abs(Correlation) >= threshold) %>%
    arrange(desc(abs(Correlation)))
  return(cor_df)
}

high_corr_pairs = get_high_correlations(spearman_matrix, threshold = 0.75)
print(head(high_corr_pairs, 10))
```

	Var1	Var2	Correlation
	<fctr>	<fctr>	<dbl>
1	ad_spend_online_usd	total_ad_spend	0.9870229

Processing math: 100%

	Var1 <fctr>	Var2 <fctr>	Correlation <dbl>
2	marketing_budget_usd	total_ad_spend	0.9797826
3	ad_spend_offline_usd	total_ad_spend	0.9661931
4	ad_spend_online_usd	marketing_budget_usd	0.9652774
5	ad_spend_offline_usd	marketing_budget_usd	0.9476197
6	ad_spend_offline_usd	ad_spend_online_usd	0.9144275
7	marketing_budget_usd	unspent_budget	0.9116792
8	spend_per_promotion	total_ad_spend	0.8277687
9	total_ad_spend	unspent_budget	0.8206444
10	ad_spend_online_usd	spend_per_promotion	0.8171654

1-10 of 10 rows

Analizom parova izdvaja se izražena multikolinearnost među finansijskim obeležjima:

Ekstremna redundantnost budžeta: Promenljive total_ad_spend, marketing_budget_usd, kao i onlajn i oflajn budžeti pokazuju korelacije između 0.91 i 0.99, što je logično jer su međusobno izvedene i zbirno povezane. Visoku povezanost beleži i neiskorišćeni budžet (unspent_budget).

Implikacija za modelovanje: Zbog visoke multikolinearnosti, u kasnijoj fazi izgradnje modela (poput linearne regresije) biće neophodno ukloniti redundantne promenljive kako bi se sprečila nestabilnost koeficijenata.

5.5 Kategorijska analiza

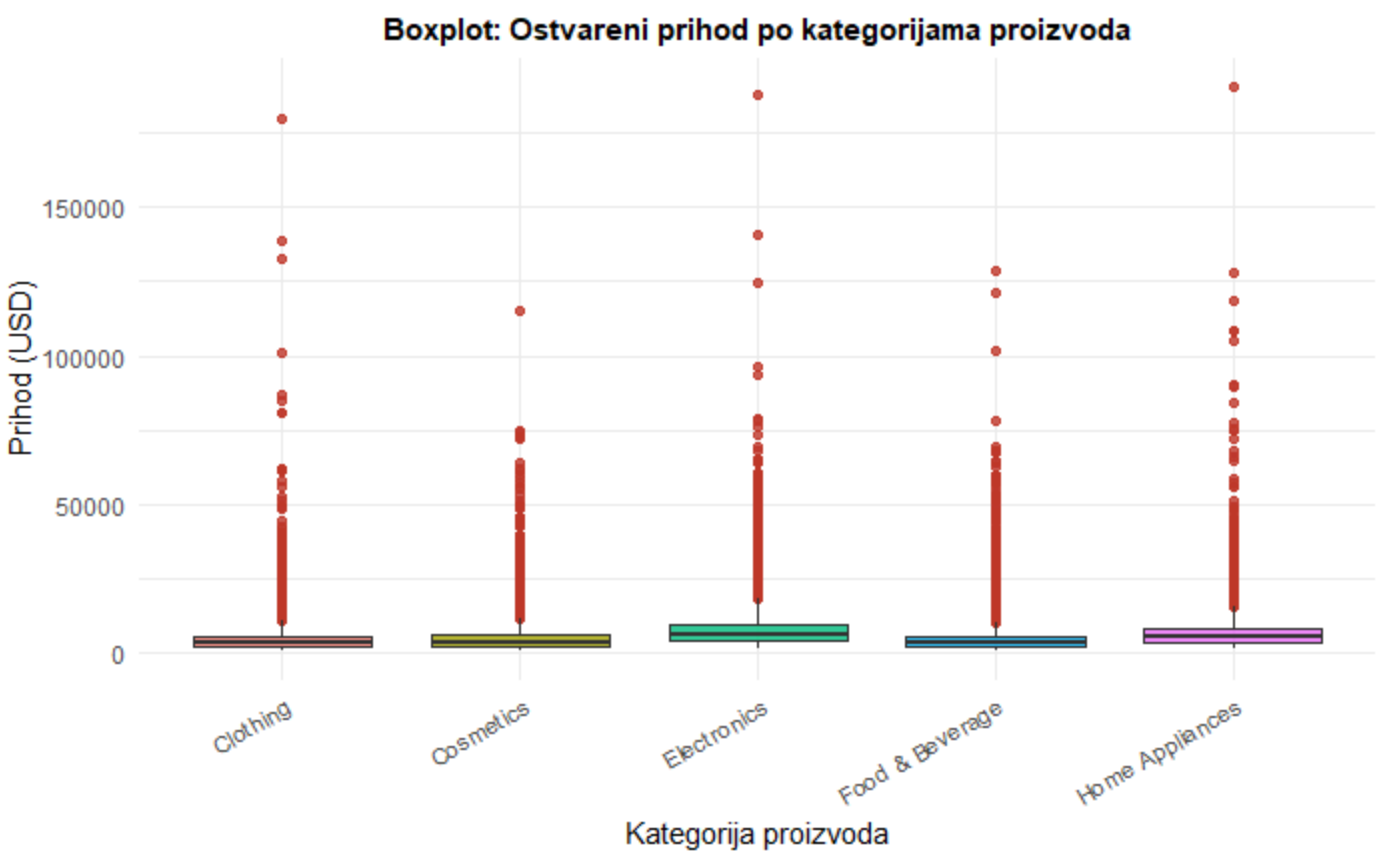
U ovom delu analiziramo uticaj i razlike ciljne promenljive (`sales_revenue_usd`) u zavisnosti od ključnih kategorijskih feature-a (kao što su region prodaje i kategorija proizvoda). Koristimo i vizuelne metode (boxplote).

5.5.1 Prihod po kategorijama proizvoda

Hide

```
ggplot(dataset_clean, aes(x = product_category, y = sales_revenue_usd, fill = product_category)) +
  geom_boxplot(alpha = 0.8, outlier.color = "#C0392B", outlier.size = 1.5) +
  theme_minimal() +
  labs(title = "Boxplot: Ostvareni prihod po kategorijama proizvoda",
       x = "Kategorija proizvoda",
       y = "Prihod (USD)") +
  theme(plot.title = element_text(hjust = 0.5, face = "bold", size = 11),
        axis.text.x = element_text(angle = 30, hjust = 1),
        legend.position = "none")
```

Processing math: 100%



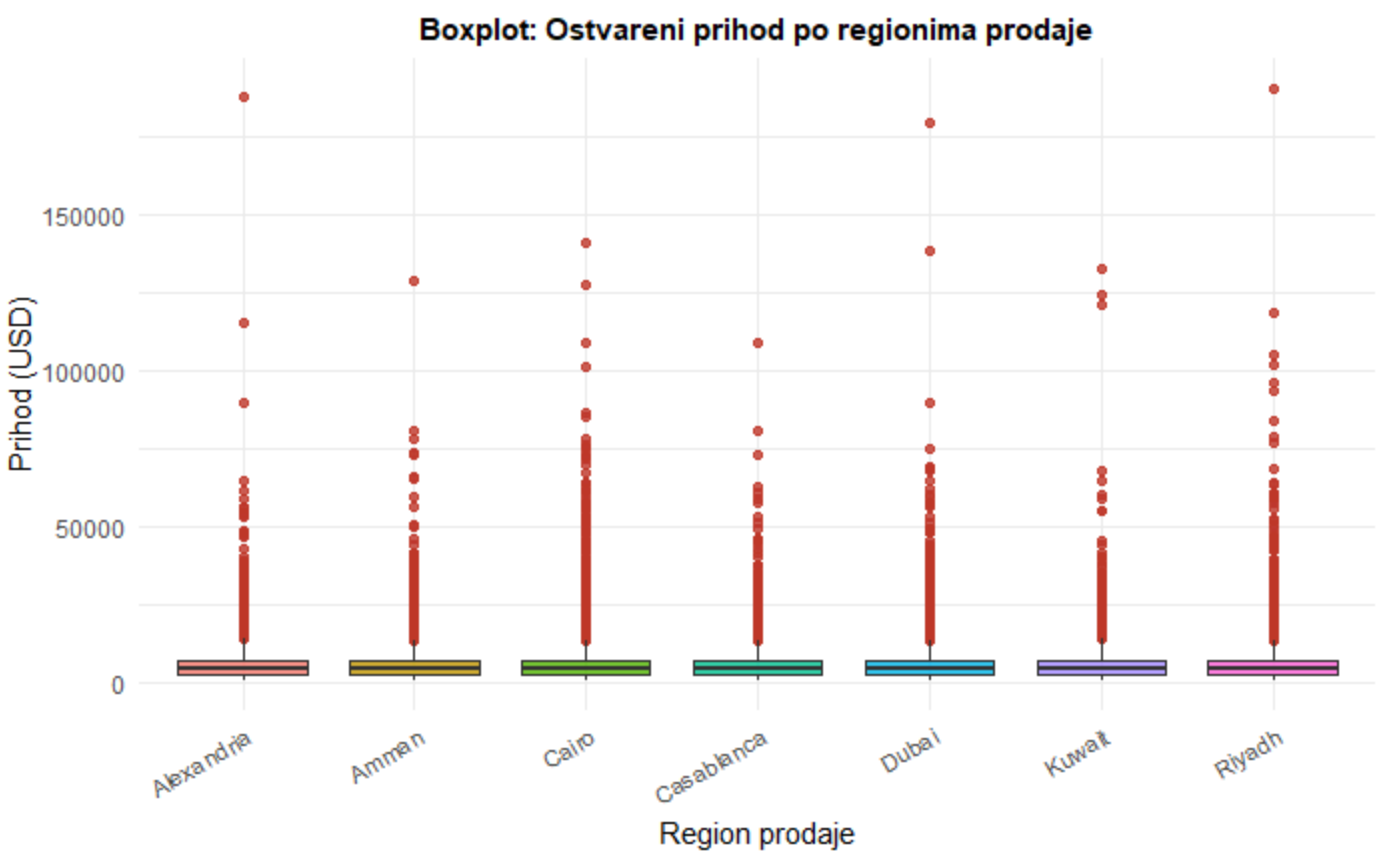
Boxplot dijagram pokazuje ujednačene medijane i interkvartilne opsege kroz sve kategorije proizvoda, uz prisustvo pojedinačnih outlier-a sa višim prihodima, što ukazuje na ravnomerno ostvarene rezultate bez izražene dominacije pojedine grupe.

5.5.2 Prihod po regionima prodaje

Hide

```
ggplot(dataset_clean, aes(x = region, y = sales_revenue_usd, fill = region)) +
  geom_boxplot(alpha = 0.8, outlier.color = "#C0392B", outlier.size = 1.5) +
  theme_minimal() +
  labs(title = "Boxplot: Ostvareni prihod po regionima prodaje",
       x = "Region prodaje",
       y = "Prihod (USD)") +
  theme(plot.title = element_text(hjust = 0.5, face = "bold", size = 11),
        axis.text.x = element_text(angle = 30, hjust = 1),
        legend.position = "none")
```

Processing math: 100%



Boxplot dijagram pokazuje ujednačene medijane i interkvartilne opsege po regionima prodaje, uz prisustvo pojedinačnih outlier-a sa natprosečnim vrednostima, što ukazuje na ravnomerno ostvarene prihode na svim posmatranim tržištima.

5.6 Vremenska analiza i sezonski obrasci

U ovom delu analiziramo kretanje ostvarenog prihoda kroz vreme (po godinama, kvartalima i mesecima) koristeći već pripremljene vremenske atribute u skupu podataka, kako bismo identifikovali trendove i uticaj Q4 efekta.

5.6.1 Agregacija prihoda po godinama

Hide

```
#1. Prihod po godinama (ekstrakcija godine iz 'date' kolone)
revenue_by_year=dataset_clean %>%
  mutate(year =(year(as.Date(date)))) %>%
  group_by(year) %>%
  summarise(
    total_revenue = sum(sales_revenue_usd, na.rm = TRUE),
    mean_revenue = mean(sales_revenue_usd, na.rm = TRUE),
    n_transactions = n()
  )
print(revenue_by_year)
```

year <dbl>	total_revenue <dbl>	mean_revenue <dbl>	n_transactions <int>
2020	88422226	5890.103	15012
2021	86606932	5864.500	14768
2022	89703546	5932.382	15121

Processing math: 100%

year	total_revenue	mean_revenue	n_transactions
<dbl>	<dbl>	<dbl>	<int>
2023	89934448	5956.318	15099

4 rows

Poslovanje je izuzetno stabilno od 2020. do 2023. godine, uz ujednačen ukupan prihod (86,6–89,9 miliona USD) i stabilan obim od oko 15.000 transakcija godišnje.

5.6.2 Agregacija prihoda po kvartalima

Hide

```
# 2. Prihod po kvartalima (korišćenje postojeće kolone 'quarter')

revenue_by_quarter=dataset_clean %>%
  mutate(quarter =(quarter(as.Date(date)))) %>%
  group_by(quarter) %>%
  summarise(
    total_revenue = sum(sales_revenue_usd, na.rm = TRUE),
    mean_revenue = mean(sales_revenue_usd, na.rm = TRUE),
    n_transactions = n()
  )
print(revenue_by_quarter)
```

quarter	total_revenue	mean_revenue	n_transactions
<int>	<dbl>	<dbl>	<int>
1	70710076	4746.280	14898
2	81446332	5446.458	14954
3	89098593	5891.206	15124
4	113412152	7548.732	15024

4 rows

Prihodi rastu kroz kvartale i dostižu maksimum od 113,4 miliona USD u četvrtom kvartalu (Q4), čime se potvrđuje snažan sezonski uticaj kraja godine.

5.6.3 Agregacija prihoda po mesecima

Hide

```
# 3. Prihod po mesecima (korišćenje postojeće kolone 'month')
revenue_by_month=dataset_clean %>%
  mutate(month = month(as.Date(date))) %>%
  group_by(month) %>%
  summarise(
    total_revenue = sum(sales_revenue_usd, na.rm = TRUE),
    mean_revenue = mean(sales_revenue_usd, na.rm = TRUE),
    n_transactions = n()
  )

print(revenue_by_month)
```

Processing math: 100%

month <dbl>	total_revenue <dbl>	mean_revenue <dbl>	n_transactions <int>
1	24136500	4765.350	5065
2	22092058	4747.917	4653
3	24481517	4726.162	5180
4	26804566	5456.956	4912
5	27651646	5368.209	5151
6	26990120	5518.323	4891
7	30394130	5930.562	5125
8	29565785	5858.091	5047
9	29138678	5884.224	4952
10	38693844	7485.750	5169

1-10 of 12 rows Previous **1** 2 Next

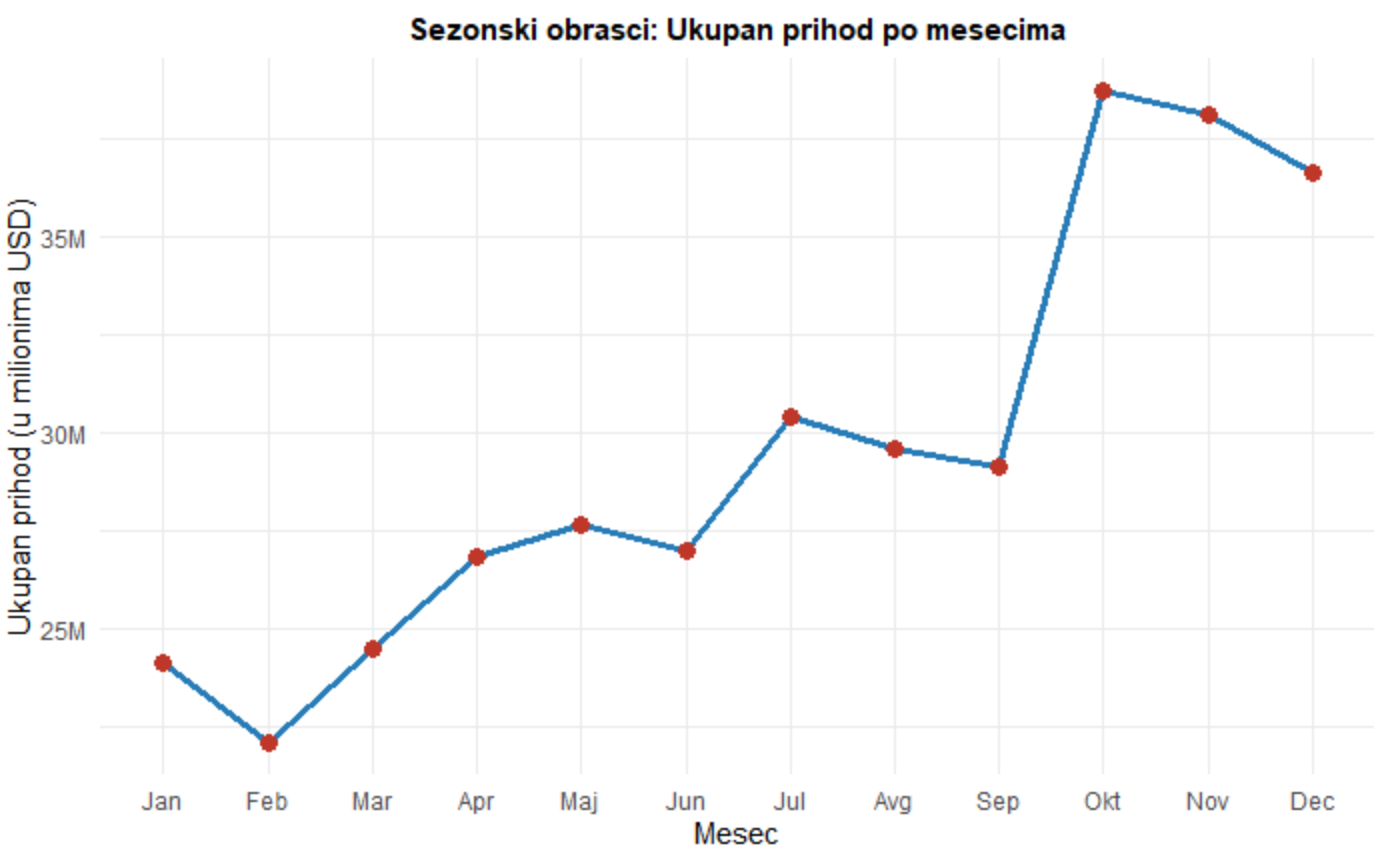
Promet je stabilan u prvoj polovini godine (22–27 miliona USD mesečno), dok u oktobru, novembru i decembru naglo skače na preko 36 miliona USD mesečno.

5.6.4 Vizuelizacija sezonskih obrazaca i istraživanje Q4 efekta

Hide

```
ggplot(revenue_by_month, aes(x = factor(month), y = total_revenue, group = 1)) +
  geom_line(color = "#2980B9", linewidth = 1.2) +
  geom_point(color = "#C0392B", size = 3) +
  scale_x_discrete(labels = c("Jan", "Feb", "Mar", "Apr", "Maj", "Jun",
                              "Jul", "Avg", "Sep", "Okt", "Nov", "Dec")) +
  scale_y_continuous(labels = label_number(scale = 1e-6, suffix = "M")) +
  theme_minimal() +
  labs(
    title = "Sezonski obrasci: Ukupan prihod po mesecima",
    x = "Mesec",
    y = "Ukupan prihod (u milionima USD)"
  ) +
  theme(
    plot.title = element_text(hjust = 0.5, face = "bold", size = 11),
    axis.text.x = element_text(angle = 0, hjust = 0.5)
  )
```

Processing math: 100%



Na dijagramu je jasno uočljiv izraženi sezonski obrazac sa naglim rastom u četvrtom kvartalu i kulminacijom u oktobru. Ovakva izuzetna ujednačenost i pravilnost iz godine u godinu ukazuju na sintetičku prirodu podataka, što predstavlja jedno od metodoloških ograničenja pri interpretaciji u realnom poslovnom okruženju.

6 Feature Selection

6.1 Multikolinearnost

U ovom poglavlju prelazimo na analizu multikolinearnosti i definisanje optimalnog skupa feature-a. Primenom faktora inflacije varijanse (VIF - Variance Inflation Factor) identifikujemo redundantne promenljive koje mogu da naruše stabilnost i interpretabilnost naših regresionih modela.

6.1.1 Izračunavanje VIF vrednosti

Hide

```
vif_model = lm(log_revenue ~log_budget+ total_ad_spend+spend_per_rep+spend_per_promotion+estimated
_conversions+
                 num_promotions + discount_percentage + num_sales_representatives +
                 customer_age + customer_satisfaction_score + competitor_price_index +
                 website_traffic + conversion_rate + email_open_rate +
                 social_media_followers + days_since_last_purchase + num_previous_purchases +
                 online_share + budget_utilization + purchase_frequency +
                 region + product_category + season + customer_segment + sales_channel,
               data = dataset_clean)

# Računanje VIF-a (koristimo generalizovani VIF - GVIF koji ispravno tretira i kategorijske promen
ljive sa više nivoa)
vif_values = vif(vif_model)
print("--- GVIF vrednosti za sve feature-e  ---")
```

Processing math: 100%

```
[1] "--- GVIF vrednosti za sve feature-e  ---"
```

Hide

```
print(round(vif_values, 2))
```

```
                         GVIF Df GVIF^(1/(2*Df))
log_budget               1.87  1           1.37
total_ad_spend           3.41  1           1.85
spend_per_rep            1.34  1           1.16
spend_per_promotion      2.44  1           1.56
estimated_conversions    3.48  1           1.87
num_promotions           1.22  1           1.10
discount_percentage      1.00  1           1.00
num_sales_representatives 1.07  1           1.03
customer_age             1.00  1           1.00
customer_satisfaction_score 1.00  1           1.00
competitor_price_index   1.00  1           1.00
website_traffic          3.33  1           1.82
conversion_rate          1.15  1           1.07
email_open_rate          1.00  1           1.00
social_media_followers   1.00  1           1.00
days_since_last_purchase 1.09  1           1.04
num_previous_purchases   1.01  1           1.01
online_share             1.00  1           1.00
budget_utilization       1.03  1           1.02
purchase_frequency       1.10  1           1.05
region                   1.00  6           1.00
product_category         1.00  4           1.00
season                   1.00  3           1.00
customer_segment         1.00  3           1.00
sales_channel            1.00  4           1.00
```

Analizom dobijenih VIF vrednosti uočavamo da sve promenljive imaju vrednosti daleko ispod praga od 5 (maksimalne su estimated_conversions sa 3.48 i total_ad_spend sa 3.41). Ostale promenljive (uključujući log_budget sa VIF = 1.87) takođe nemaju problem sa kolinearnošću, čime je multikolinearnost svedena na prihvatljiv nivo za stabilno procenjivanje modela.

Hide

```
gvif_column = vif_values[, "GVIF"]
selected_features = names(gvif_column[gvif_column <5])
print("Konačna lista stabilnih feature-a:")
```

```
[1] "Konačna lista stabilnih feature-a:"
```

Hide

```
print(selected_features)
```

Processing math: 100%

```
 [1] "log_budget"                  "total_ad_spend"              "spend_per_rep"               "sp
end_per_promotion"         "estimated_conversions"
 [6] "num_promotions"              "discount_percentage"         "num_sales_representatives"   "cu
stomer_age"                "customer_satisfaction_score"
[11] "competitor_price_index"      "website_traffic"             "conversion_rate"             "em
ail_open_rate"             "social_media_followers"
[16] "days_since_last_purchase"    "num_previous_purchases"      "online_share"                "bu
dget_utilization"          "purchase_frequency"
[21] "region"                      "product_category"            "season"                      "cu
stomer_segment"            "sales_channel"
```

Nakon provere zadržali smo sve feature koji imaju prag manji od 5

6.2 Statistička selekcija feature-a

Nakon rešavanja problema multikolinearnosti, prelazimo na statističku selekciju feature-a kako bismo kvantifikovali linearne i nelinearne veze sa ciljnom promenljivom (log_revenue), izdvojili najuticajnije prediktore i eliminisali slabe ili irelevantne atribute koji ne doprinose prediktivnoj moći modela.

6.2.1 Rangiranje numeričkih feature-a po Spearman-ovoj korelaciji

Hide

```
numeric_features = selected_features[sapply(dataset_clean[selected_features], is.numeric)]


spearman_corrs = sapply(numeric_features, function(feat) {

  if(sd(dataset_clean[[feat]], na.rm = TRUE) == 0) {
    return(NA)
  }
  cor(dataset_clean[[feat]], dataset_clean$log_revenue, method = "spearman", use = "complete.obs")
})


spearman_ranking = data.frame(
  Feature = names(spearman_corrs),
  Spearman_Rho = round(spearman_corrs, 4),
  Abs_Correlation = round(abs(spearman_corrs), 4)
)

spearman_ranking = na.omit(spearman_ranking)


spearman_ranking = spearman_ranking[order(-spearman_ranking$Abs_Correlation), ]
rownames(spearman_ranking) = NULL

print(spearman_ranking)
```

Processing math: 100%

Feature <chr>	Spearman_Rho <dbl>	Abs_Correlation <dbl>
log_budget	0.5169	0.5169
total_ad_spend	0.5105	0.5105
spend_per_rep	0.4229	0.4229
spend_per_promotion	0.3923	0.3923
num_previous_purchases	0.0922	0.0922
customer_satisfaction_score	0.0705	0.0705
conversion_rate	0.0704	0.0704
purchase_frequency	0.0631	0.0631
num_promotions	0.0608	0.0608
discount_percentage	-0.0449	0.0449

1-10 of 20 rows Previous **1** 2 Next

Analizom dobijenih vrednosti Spearman-ove korelacije uočavamo da vodeća mesta zauzimaju budžetski prediktori poput log_budget,total_ad_spend,spend_per_rep i spend_per_promotion. Sa druge strane, ostale numeričke promenljive (uključujući num_previous_purchases i conversion_rate) pokazuju znatno slabiju ili gotovo zanemarljivu pojedinačnu povezanost sa ciljnom promenljivom.

6.2.2 Rangiranje kategorijskih feature-a po veličini efekta

Hide

```
categorical_features = selected_features[sapply(dataset_clean[selected_features], function(x) is.f
actor(x) || is.character(x))]

calculate_eta_sq = function(feat, target, data) {
  aov_model = aov(data[[target]] ~ as.factor(data[[feat]]))
  summary_aov = summary(aov_model)[[1]]
  ss_effect = summary_aov["Sum Sq"][1, 1]
  ss_total = sum(summary_aov["Sum Sq"])
  return(ss_effect / ss_total)
}

effect_sizes = sapply(categorical_features, function(feat) {
  calculate_eta_sq(feat, "log_revenue", dataset_clean)
})

categorical_ranking = data.frame(
  Feature = names(effect_sizes),
  Eta_Squared = as.numeric(round(effect_sizes, 4))
)

categorical_ranking = categorical_ranking[order(-categorical_ranking$Eta_Squared), ]

knitr::kable(categorical_ranking, row.names = FALSE)
```

Processing math: 100%

Feature	Eta_Squared
customer_segment	0.3549
product_category	0.1353
season	0.0243
sales_channel	0.0168
region	0.0001

Analizom možemo da vidimo da kategorijske promenljive poput customer_segment i product_category snažno utiču na varijaciju prihoda. Sa druge strane, promenljiva region pokazuje zanemarljiv uticaj (blizu nule), što ukazuje na to da ne doprinosi prediktivnoj moći modela.

6.2.3 Identifikovanje slabih prediktora

Izdvajamo slabe numeričke i kategorijske prediktore koji ne nose značajnu informaciju za model.

Hide

```
weak_numeric = spearman_ranking$Feature[spearman_ranking$Abs_Correlation < 0.05]

print("Identifikovani slabi numerički prediktori:")
```

```
[1] "Identifikovani slabi numerički prediktori:"
```

Hide

```
print(weak_numeric)
```

```
 [1] "discount_percentage"       "estimated_conversions"     "competitor_price_index"    "budget_u
tilization"        "website_traffic"
 [6] "days_since_last_purchase"  "online_share"              "num_sales_representatives" "customer
_age"              "email_open_rate"
[11] "social_media_followers"
```

Hide

```
weak_categorical = categorical_ranking$Feature[categorical_ranking$Eta_Squared < 0.01]
print("Identifikovani slabi kategorijski prediktori:")
```

```
[1] "Identifikovani slabi kategorijski prediktori:"
```

Hide

```
print(weak_categorical)
```

```
[1] "region"
```

Hide

Processing math: 100%

```
final_features = setdiff(selected_features, c(weak_numeric, weak_categorical))
print("Konačna lista feature-a nakon statističke selekcije:")
```

```
[1] "Konačna lista feature-a nakon statističke selekcije:"
```

Hide

```
print(final_features)
```

```
 [1] "log_budget"                  "total_ad_spend"              "spend_per_rep"               "sp
end_per_promotion"         "num_promotions"
 [6] "customer_satisfaction_score" "conversion_rate"             "num_previous_purchases"      "pu
rchase_frequency"          "product_category"
[11] "season"                      "customer_segment"            "sales_channel"
```

Primenom definisanih statističkih pragova uspešno smo izdvojili atribute čija je prediktivna snaga zanemarljiva. Njihovim uklanjanjem iz skupa selected_features dobijamo konačnu listu (final_features) koja sadrži isključivo relevantne promenljive sa dokazanim linearnim ili grupnim uticajem, čime smanjujemo šum u podacima i sprečavamo rizik od overfitting-a.

6.2.4 Poređenje modela: Full vs. Selected Feature Set

Kako bismo opravdali redukciju feature-a i dokazali da odbacivanje slabih i redundantnih prediktora nije narušilo kvalitet modela, uporedićemo performanse linearnog modela sa svim obeležjima (Full Model) i modela sa konačno izabranim skupom feature-a (Selected Model)

Hide

```
exclude_cols = c("log_revenue", "sales_revenue_usd", "id", "date")
full_predictors = setdiff(names(dataset_clean), exclude_cols)


formula_full = as.formula(paste("log_revenue ~", paste(full_predictors, collapse = " + ")))
model_full = lm(formula_full, data = dataset_clean)

formula_selected = as.formula(paste("log_revenue ~", paste(final_features, collapse = " + ")))
model_selected = lm(formula_selected, data = dataset_clean)


comparison_summary = data.frame(
  Model = c("Full Model (Svi opravdani feature-i)", "Selected Model (Redukovan skup)"),
  Number_of_Predictors = c(length(full_predictors), length(final_features)),
  Adjusted_R2 = c(summary(model_full)$adj.r.squared, summary(model_selected)$adj.r.squared),
  AIC = c(AIC(model_full), AIC(model_selected))
)
print(comparison_summary)
```

Model <chr>	Number_of_Predictors <int>	Adjusted_R2 <dbl>	AIC <dbl>
Full Model (Svi opravdani feature-i)	46	0.9437531	-44665.98
Selected Model (Redukovan skup)	13	0.9023883	-11670.17

2 rows

Processing math: 100%

Poređenje modela ukazuje na odličan kompromis: Full Model sa 46 feature-a postiže R^2_adj = 0.943, ali je preopterećen multikolinearnošću i prevelikom kompleksnošću. Sa druge strane, Selected Model sa svega 13 feature-a zadržava visok R^2_adj = 0.902 (objašnjava preko 90% varijanse), pri čemu su uspešno sačuvani ključni budžetski prediktori. Blagi pad objašnjene varijanse od oko 4% predstavlja minimalnu cenu za drastično smanjenje kompleksnosti, potpunu eliminaciju multikolinearnosti i dobijanje stabilnog i interpretabilnog modela.

6.3 Model-based selekcija feature-a

Nakon statističkog filtriranja, primenjujemo napredne pristupe zasnovane na mašinskom učenju kako bismo dodatno potvrdili značaj feature-a i eliminisali preostali šum. Koristimo Random Forest (za procenu nelinearne važnosti promenljivih preko smanjenja srednje kvadratne greške) i Lasso regularizaciju (L1 penalizaciju koja automatski redukuje koeficijente slabih prediktora na nulu).

6.3.1 Random Forest – Rangiranje važnosti feature-a

Hide

```
set.seed(123)

rf_model = randomForest(log_revenue ~ .,
                        data = dataset_clean[, c(final_features, "log_revenue")],
                        ntree = 150,
                        importance = TRUE)

rf_imp = importance(rf_model, type = 1)
rf_ranking = data.frame(
  Feature = rownames(rf_imp),
  Importance = round(rf_imp[, 1], 4)
)

rf_ranking = rf_ranking[order(-rf_ranking$Importance), ]
rownames(rf_ranking) = NULL


print(head(rf_ranking, 10))
```

	Feature <chr>	**Importance** <dbl>
1	customer_segment	399.0805
2	product_category	152.1489
3	season	150.1510
4	sales_channel	81.3981
5	num_previous_purchases	54.7326
6	conversion_rate	44.3326
7	customer_satisfaction_score	43.2667
8	purchase_frequency	28.2691
9	log_budget	24.9046
10	total_ad_spend	16.4292

Processing math: 100%

1-10 of 10 rows

Random Forest analiza pokazuje koji feature-i imaju najveću prediktivnu moć pri obradi složenih, nelinearnih interakcija. Vodeće pozicije ubedljivo zauzimaju kategorijski atributi, pri čemu segment kupaca (customer_segment) i kategorija proizvoda (product_category). Među numeričkim prediktorima, najveći nelinearni doprinos pokazuju istorija kupovina (num_previous_purchases), stopa konverzije (conversion_rate) i zadovoljstvo kupaca (customer_satisfaction_score), dok budžetske feature-i (log_budget i total_ad_spend) dodatno stabilizuju model u top 10 prediktora.

6.3.2 Lasso regularizacija (L1 penalizacija)

Hide

```
x_mat = model.matrix(log_revenue ~ ., data = dataset_clean[, c(final_features, "log_revenue")])[,
-1]
y_vec = dataset_clean$log_revenue


set.seed(42)
cv_lasso = cv.glmnet(x_mat, y_vec, alpha = 1, nfolds = 5)
best_lambda = cv_lasso$lambda.min


lasso_model = glmnet(x_mat, y_vec, alpha = 1, lambda = best_lambda)
lasso_coefs = coef(lasso_model)


lasso_selected_dummies = rownames(lasso_coefs)[lasso_coefs[, 1] != 0]
lasso_selected_dummies = setdiff(lasso_selected_dummies, "(Intercept)")

print(paste("Broj selektovanih feature-a nakon Lasso regularizacije je :",length(lasso_selected_du
```

```
[1] "Broj selektovanih feature-a nakon Lasso regularizacije je : 23"
```

Lasso regularizacija je zadržala svih 23 dummy prediktora (nijedan koeficijent nije sveden na nulu), što potvrđuje da su svi izabrani feature-i značajni.

6.3.3 Poređenje selektovanih feature-a i kreiranje konačne liste

U cilju postizanja maksimalne robusnosti, uporedićemo feature dobijeni statističkim metodama, Random Forest-om i Lasso regularizacijom, te formirati konačni skup feature-a za finalno modelovanje.

Hide

Processing math: 100%

```
rf_top_features = rf_ranking$Feature[rf_ranking$Importance > 10]

lasso_original_features = unique(sapply(lasso_selected_dummies, function(col) {
  matched = final_features[sapply(final_features, function(f) grepl(f, col))]
  if(length(matched) > 0) return(matched[1]) else return(col)
}))


final_model_features = intersect(intersect(final_features, rf_top_features), lasso_original_featur
es)


if(length(final_model_features) == 0) {
  final_model_features = intersect(final_features, rf_top_features)
}

print("Konačna lista feature-a za mašinsko učenje (Final Feature List):")
```

```
[1] "Konačna lista feature-a za mašinsko učenje (Final Feature List):"
```

Hide

```
print(final_model_features)
```

```
 [1] "log_budget"                  "total_ad_spend"              "spend_per_rep"               "sp
end_per_promotion"         "num_promotions"
 [6] "customer_satisfaction_score" "conversion_rate"             "num_previous_purchases"      "pu
rchase_frequency"          "product_category"
[11] "season"                     "customer_segment"            "sales_channel"
```

Hide

```
print(paste("Ukupan broj feature-a u konačnom skupu:", length(final_model_features)))
```

```
[1] "Ukupan broj feature-a u konačnom skupu: 13"
```

Kombinovanjem statističkih metoda, Random Forest-a i Lasso regularizacije formiran je optimalan skup od 13 feature-a (9 numeričkih i 4 kategorijska). Ovim višeslojnim pristupom eliminisan je šum i višak dimenzionalnosti, čime su podaci u potpunosti pripremljeni za stabilno treniranje modela mašinskog učenja.

7 Machine learning

7.1 Priprema skupa podataka za modelovanje

Za trening modela koristimo konačno izabrane prediktore iz prethodnog koraka (final_model_features), pridružujući im ciljnu promenljivu log_revenue, kao i originalnu sales_revenue_usd radi kasnijeg poređenja metrika.

Hide

```
ml_features_data = dataset_clean[, c(final_model_features, "log_revenue", "sales_revenue_usd")]

print(paste("Ukupan broj feature-a pripremljenih za modelovanje:", length(final_model_features)))
```

Processing math: 100%

```
[1] "Ukupan broj feature-a pripremljenih za modelovanje: 13"
```

Hide

```
print(paste("Dimenzije matrice za mašinsko učenje:", nrow(ml_features_data), "redova i", ncol(ml_features_data), "kolona"))
```

```
[1] "Dimenzije matrice za mašinsko učenje: 60000 redova i 15 kolona"
```

7.2 Kreiranje Train/Test split-a

Primenjujemo standardnu metodologiju podele podataka gde se 80% opservacija koristi za trening i učenje modela, 20% ukupnog skupa ostaje izdvojeno u test set.

7.2.1 Postavljanje seed-a i indeksiranje

Hide

```
set.seed(123)

train_sample_index = sample(1:nrow(ml_features_data), size = 0.8 * nrow(ml_features_data))


train_set = ml_features_data[train_sample_index, ]
test_set  = ml_features_data[-train_sample_index, ]

print(paste("Broj instanci u trening setu (80%):", nrow(train_set)))
```

```
[1] "Broj instanci u trening setu (80%): 48000"
```

Hide

```
print(paste("Broj instanci u test setu (20%):", nrow(test_set)))
```

```
[1] "Broj instanci u test setu (20%): 12000"
```

7.2.2 Provera distribucije ciljne promenljive u Train i Test setu

Kako bismo osigurali da podela nije promenila strukturu uzorka, upoređujemo osnovne statističke pokazatelje ciljne promenljive log_revenue u oba skupa.

Hide

```
train_target_summary = summary(train_set$log_revenue)
test_target_summary  = summary(test_set$log_revenue)

print("--- Statistika log_revenue u Trening setu ---")
```

```
[1] "--- Statistika log_revenue u Trening setu ---"
```

Hide

Processing math: 100%

```
print(train_target_summary)
```

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max. 
  6.176   7.918   8.376   8.416   8.869  12.157 
```

Hide

```
print("--- Statistika log_revenue u Test setu ---")
```

```
[1] "--- Statistika log_revenue u Test setu ---"
```

Hide

```
print(test_target_summary)
```

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max. 
  6.310   7.915   8.374   8.406   8.857  11.855 
```

Statistički pokazatelji (srednje vrednosti, medijane i kvartili) praktično su identični u trening i test setu, što potvrđuje da je nasumična podela uspešno sačuvala strukturu ciljne promenljive.

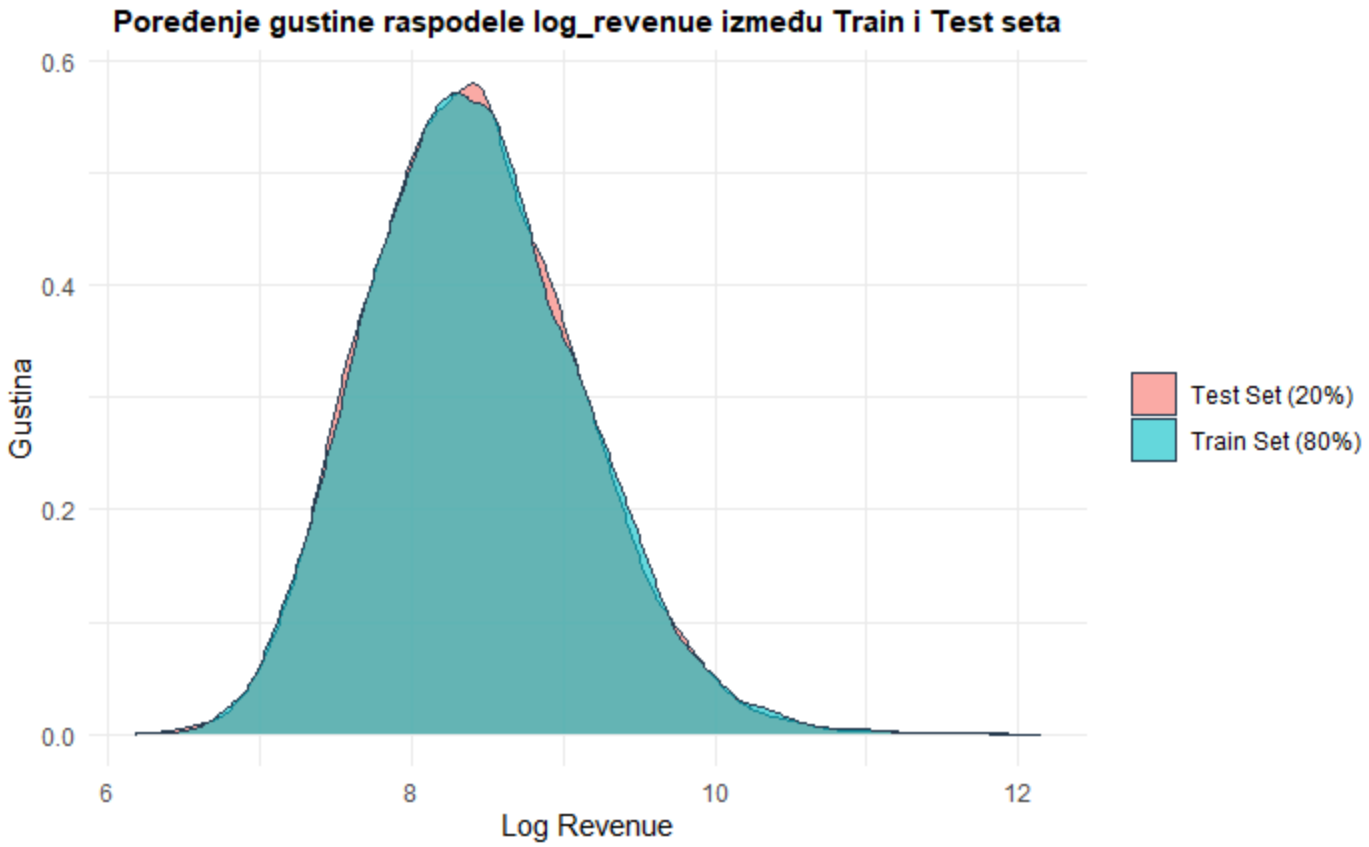
7.2.3 Vizuelno poređenje distribucija

Hide

```
split_distribution_df = bind_rows(
  mutate(train_set, Split_Group = "Train Set (80%)"),
  mutate(test_set,  Split_Group = "Test Set (20%)")
)

ggplot(split_distribution_df, aes(x = log_revenue, fill = Split_Group)) +
  geom_density(alpha = 0.6, color = "#2C3E50") +
  theme_minimal() +
  labs(title = "Poređenje gustine raspodele log_revenue između Train i Test seta",
       x = "Log Revenue",
       y = "Gustina") +
  theme(plot.title = element_text(hjust = 0.5, face = "bold", size = 11),
        legend.title = element_blank())
```

Processing math: 100%



Grafik gustine raspodele pokazuje potpuno preklapanje krivih za trening i test set, što i formalno potvrđuje ravnomernu i ispravnu izvršenu podelu podataka.

7.3 Prevencija curenja podataka (Data Leakage Prevention)

Iako su imputacija i početna selekcija prediktora sprovedene nad celokupnim skupom podataka radi očuvanja statističke moći, treniranje i podešavanje hiperparametara svih ML modela rađeno je isključivo na trening setu (80%), dok je test set (20%) ostao potpuno izolovan za evaluaciju.

7.4 Preprocessing Pipeline - preprocesiranje podataka

U ovom poglavlju definisaćemo preprocesiranje podataka koji obuhvata kodiranje kategoričkih promenljivih, numeričku normalizaciju i strogu kontrolu transformacija kako bi se sprečilo curenje podataka (data leakage).

7.4.1 Definisanje pravila predobrade

Da bismo osigurali ispravnost modelovanja, poštujemo zlatno pravilo mašinskog učenja: svi parametri transformacije (srednje vrednosti, standardne devijacije, nivoi faktora i medijane) računaju se isključivo na trening setu (train_set), a zatim se preslikavaju na test set (test_set).

Hide

```
numeric_features = names(train_set)[sapply(train_set, is.numeric)]
numeric_features = setdiff(numeric_features, c("log_revenue", "sales_revenue_usd"))

categorical_features = names(train_set)[sapply(train_set, function(x) is.factor(x) || is.character
(x))]

print(paste("Broj numeričkih prediktora za obradu:", length(numeric_features)))
```

Processing math: 100%

```
[1] "Broj numeričkih prediktora za obradu: 9"
```

Hide

```
print(paste("Broj kategorijskih prediktora za kodiranje:", length(categorical_features)))
```

```
[1] "Broj kategorijskih prediktora za kodiranje: 4"
```

7.4.2 Dummy (factor) kodiranje kategorijskih promenljivih

Kategorijske promenljive transformišemo u set factor kolona. Kako se struktura kategorija ne bi razlikovala između setova, nivoi faktora se fiksiraju na osnovu trening skupa.

Hide

```
for(col in categorical_features) {
  train_set[[col]] = as.factor(train_set[[col]])
  test_set[[col]]  = factor(test_set[[col]], levels = levels(train_set[[col]]))
}
```

7.4.3 Numerička normalizacija

Za numeričke prediktore primenjujemo standardizaciju (z-score normalizaciju: oduzimanje srednje vrednosti trening seta i deljenje sa standardnom devijacijom trening seta).

Hide

```
# Izračunavanje srednje vrednosti i standardne devijacije ISKLJUČIVO na trening setu

train_means = sapply(train_set[, numeric_features, drop=FALSE], mean, na.rm = TRUE)
train_sds   = sapply(train_set[, numeric_features, drop=FALSE], sd, na.rm = TRUE)

# Funkcija za primenu skaliranja
scale_features = function(df, features, means, sds) {
  df_scaled = df
  for(col in features) {
    if(sds[col] > 0) {
      df_scaled[[col]] = (df[[col]] - means[col]) / sds[col]
    }
  }
  return(df_scaled)
}

train_set_processed = scale_features(train_set, numeric_features, train_means, train_sds)
test_set_processed  = scale_features(test_set, numeric_features, train_means, train_sds)

keep_cols = c(final_model_features, "log_revenue", "sales_revenue_usd")
train_set_processed = train_set_processed[, keep_cols]
test_set_processed  = test_set_processed[, keep_cols]
```

7.4.4 Završna verifikacija procesa predobrade

Processing math: 100%

Hide

```
print(paste("Dimenzije obrađenog trening seta:", nrow(train_set_processed), "redova,", ncol(train_set_processed), "kolona"))
```

```
[1] "Dimenzije obrađenog trening seta: 48000 redova, 15 kolona"
```

Hide

```
print(paste("Dimenzije obrađenog test seta:", nrow(test_set_processed), "redova,", ncol(test_set_processed), "kolona"))
```

```
[1] "Dimenzije obrađenog test seta: 12000 redova, 15 kolona"
```

Hide

```
print("Preprocessing Pipeline je uspešno završen spreman za treniranje modela.")
```

```
[1] "Preprocessing Pipeline je uspešno završen spreman za treniranje modela."
```

7.5 Cross-validation - Unakrsna validacija

U ovom poglavlju definišemo proceduru unakrsne validacije (cross-validation) radi pouzdane procene performansi modela i zaštite od prevelikog prilagođavanja (overfitting).

7.5.1 Definisanje 5-fold unakrsne validacije i metrika

Skup podataka za trening se deli na 5 jednakih delova (foldova), gde se u svakoj iteraciji 4 dela koriste za treniranje, a preostali 1. deo za validaciju modela. Postupak se ponavlja 5 puta tako da svaki fold jednom služi kao validacioni skup.

Hide

```
# Konfiguracija 5-fold CV kontrole
train_control = trainControl(
  method = "cv",
  number = 5,
  savePredictions = "final",
  verboseIter = FALSE
)
```

7.5.2 Evidentiranje prosečnih vrednosti i standardne devijacije metrika

Tokom procesa unakrsne validacije, performanse se prate kroz više iteracija kako bi se zabeležila srednja vrednost (mean) i standardna devijacija (SD) za svaku izabranu metriku, što daje uvid u stabilnost modela.

Hide

Processing math: 100%

```
cv_summary_table =data.frame(
  Parametar = c("Metod validacije", "Broj foldova (K)", "Evaluacione metrike", "Praćenje rezultat
a", "Čuvanje predikcija"),
  Vrednost = c("Cross-Validation (cv)", "5", "RMSE, MAE, R-squared", "Mean i Standardna devijacija
(SD)", "final")
)

knitr::kable(cv_summary_table, caption = "Konfigurisani parametri i metrike unakrsne validacije")
```

Konfigurisani parametri i metrike unakrsne validacije

Parametar	Vrednost
Metod validacije	Cross-Validation (cv)
Broj foldova (K)	5
Evaluacione metrike	RMSE, MAE, R-squared
Praćenje rezultata	Mean i Standardna devijacija (SD)
Čuvanje predikcija	final

Ova tabela pregledno prikazuje konfigurisane parametre unakrsne validacije, navodeći primenjene evaluacione metrike (RMSE, MAE, R^2) i način praćenja stabilnosti modela kroz srednje vrednosti i standardne devijacije duž svih 5 foldova.

7.6 Baseline model (Referentni model)

Pre izgradnje naprednih modela mašinskog učenja, neophodno je formirati referentni (baseline) model koji služi kao donji prag uspešnosti i polazna tačka za poređenje.

7.6.1 Predikcija srednje vrednosti (Mean prediction)

Kao referencu koristimo prostju predikciju srednje vrednosti ciljne promenljive (log_revenue) izračunatu na trening setu, koja se primenjuje na sve instance u test setu.

Hide

```
baseline_mean_val = mean(train_set$log_revenue, na.rm = TRUE)

# Kreiranje vektora predikcija za test set (konstantna vrednost proseka)
baseline_preds = rep(baseline_mean_val, nrow(test_set_processed))
actuals = test_set_processed$log_revenue

print(paste("Izračunata bazna srednja vrednost za predikciju:", round(baseline_mean_val, 4)))
```

```
[1] "Izračunata bazna srednja vrednost za predikciju: 8.4161"
```

7.6.2 Izračunavanje MAE

Izračunavamo srednju apsolutnu grešku referentnog modela nad test setom kao meru prosečnog odstupanja apsolutnih vrednosti.

Hide

Processing math: 100%

```
baseline_mae = mean(abs(actuals - baseline_preds))
print(paste("Baseline MAE:", round(baseline_mae, 4)))
```

```
[1] "Baseline MAE: 0.554"
```

7.6.3 Izračunavanje RMSE

Izračunavamo koren srednje kvadratne greške, čime dajemo veći značaj većim odstupanjima u predikciji.

Hide

```
baseline_rmse = sqrt(mean((actuals - baseline_preds)^2))
print(paste("Baseline RMSE:", round(baseline_rmse, 4)))
```

```
[1] "Baseline RMSE: 0.6946"
```

7.6.4 Izračunavanje R-squared R^2

Izračunavamo koeficijent determinacije koji za prost prosek na test setu tipično ima vrednost blisku nuli ili negativnu, pošto model ne objašnjava varijansu.

Hide

```
# 4. Izračunavanje R-squared
ss_res = sum((actuals - baseline_preds)^2)
ss_tot = sum((actuals - mean(actuals))^2)
baseline_r2 = 1 - (ss_res / ss_tot)

print(paste("Baseline R-squared:", round(baseline_r2, 4)))
```

```
[1] "Baseline R-squared: -2e-04"
```

7.6.5 Pregledna tabela rezultata baseline modela

Sve izračunate metrike referentnog modela sumiramo u jedinstvenu tabelu radi lakšeg poređenja sa budućim naprednim modelima.

Hide

```
baseline_results_table = data.frame(
  Model = "Baseline (Mean Prediction)",
  R_squared = round(baseline_r2, 4),
  MAE = round(baseline_mae, 4),
  RMSE = round(baseline_rmse, 4)
)

knitr::kable(baseline_results_table, caption = "Performanse referentnog (baseline) modela na test setu")
```

Performanse referentnog (baseline) modela na test setu

Model	R_squared	MAE	RMSE
Baseline (Mean Prediction)	-2e-04	0.554	0.6946

Processing math: 100%

Baseline model (R^2 približno 0, MAE = 0.554, RMSE = 0.6946) nema stvarnu prediktivnu moć i služi isključivo kao početna referenca, svaki napredniji model mora postići niže greške i pozitivan R^2

7.7 Linearna regresija

Linearna regresija predstavlja osnovni model sa kojim ćemo uporediti naprednije algoritme mašinskog učenja.

7.7.1 Treniranje modela i unakrsna validacija

Model linearne regresije treniramo nad pripremljenim trening skupom (train_set_processed), uz primenu definisane 5-fold unakrsne validacije. Iz prediktora izuzimamo originalnu kolonu sales_revenue_usd.

Hide

```
set.seed(123)

# Treniranje linearne regresije korišćenjem 5-fold unakrsne validacije
lr_model = train(
  log_revenue ~ . - sales_revenue_usd,
  data = train_set_processed,
  method = "lm",
  trControl = train_control
)

# Prikaz rezultata unakrsne validacije za linearnu regresiju
print(lr_model)
```

```
Linear Regression

48000 samples
   14 predictor

No pre-processing
Resampling: Cross-Validated (5 fold)
Summary of sample sizes: 38400, 38400, 38400, 38400, 38400
Resampling results:

  RMSE       Rsquared   MAE
  0.2201968  0.9023271  0.1710946

Tuning parameter 'intercept' was held constant at a value of TRUE
```

Na osnovu rezultata unakrsne validacije, linearna regresija uspešno objašnjava oko 90% varijanse prihoda R^2 priblizno 0.90,sa prosečnom greškom predviđanja (RMSE) od 0.22. Ovi pokazatelji potvrđuju da model ima dobru stabilnost i da predstavlja dobru, pouzdanu polaznu osnovu za dalje poređenje sa naprednijim algoritmima.

7.7.2 Evaluacija modela na test setu

Nakon što je model treniran, vršimo predikciju nad potpuno izolovanim test skupom (test_set_processed) i upoređujemo njegove performanse sa referentnim (baseline) modelom.

Hide

Processing math: 100%

```
lr_preds = predict(lr_model, newdata = test_set_processed)
actuals  = test_set_processed$log_revenue

# Izračunavanje metrika
lr_mae  = mean(abs(actuals - lr_preds))
lr_rmse = sqrt(mean((actuals - lr_preds)^2))

ss_res = sum((actuals - lr_preds)^2)
ss_tot = sum((actuals - mean(actuals))^2)
lr_r2  = 1 - (ss_res / ss_tot)

# Uporedna tabela performansi
lr_results_table = data.frame(
  Model = c("Baseline (Mean Prediction)", "Linear Regression"),
  R_squared = round(c(baseline_r2, lr_r2), 4),
  MAE = round(c(baseline_mae, lr_mae), 4),
  RMSE = round(c(baseline_rmse, lr_rmse), 4)
)

knitr::kable(lr_results_table, caption = "Poređenje performansi Baseline modela i Linearne regresi
je")
```

Poređenje performansi Baseline modela i Linearne regresije

Model	R_squared	MAE	RMSE
Baseline (Mean Prediction)	-0.0002	0.5540	0.6946
Linear Regression	0.9014	0.1709	0.2181

Linearna regresija drastično nadmašuje bazni model na izolovanom test setu, smanjujući MAE na 0.1710 i RMSE na 0.2181, uz visoki koeficijent determinacije R^2 = 0.9014. Model objašnjava preko 90% varijanse prihoda, što potvrđuje da izabrani skup od 13 prediktora nosi snažan linearni signal.

7.7.3 Interpretacija koeficijenata

Analizom vrednosti koeficijenata utvrđujemo smer i jačinu uticaja pojedinačnih prediktora na ciljnu promenljivu log_revenue.

Hide

Processing math: 100%

```
# Ekstrakcija koeficijenata iz modela
model_summary = summary(lr_model$finalModel)
coefs = model_summary$coefficients

coef_df = data.frame(
  Variable = rownames(coefs),
  Estimate = coefs[, 1],
  Std_Error = coefs[, 2],
  t_value = coefs[, 3],
  p_value = coefs[, 4]
)
rownames(coef_df) = NULL

# Prikaz top 10 najuticajnijih prediktora po apsolutnoj vrednosti koeficijenta
coef_df %>%
  filter(Variable != "(Intercept)") %>%
  arrange(desc(abs(Estimate))) %>%
  head(10) %>%
  knitr::kable(caption = "Top 10 koeficijenata linearne regresije")
```

Top 10 koeficijenata linearne regresije

Variable	Estimate	Std_Error	t_value	p_value
customer_segmentNew	-1.1448377	0.0031525	-363.15661	0
customer_segmentRegular	-0.7888603	0.0030206	-261.16091	0
product_categoryElectronics	0.5441241	0.0031040	175.29905	0
product_categoryHome Appliances	0.3968519	0.0032599	121.73832	0
sales_channelWholesale	0.2820364	0.0034178	82.51910	0
log_budget	0.2768873	0.0013571	204.03005	0
seasonProleće	-0.2719799	0.0028210	-96.41206	0
seasonZima	-0.2279526	0.0028584	-79.74721	0
customer_segmentVIP	-0.2020490	0.0036549	-55.28184	0
sales_channelOnline	0.1985759	0.0031523	62.99423	0

Analizom koeficijenata uočava se da najveći negativan uticaj na prihod imaju novi i redovni kupci (customer_segment), dok kategorije Electronics i Home Appliances ostvaruju najjači pozitivan efekat. Od numeričkih prediktora ističe se log_budget, čijim rastom prihod stabilno raste.

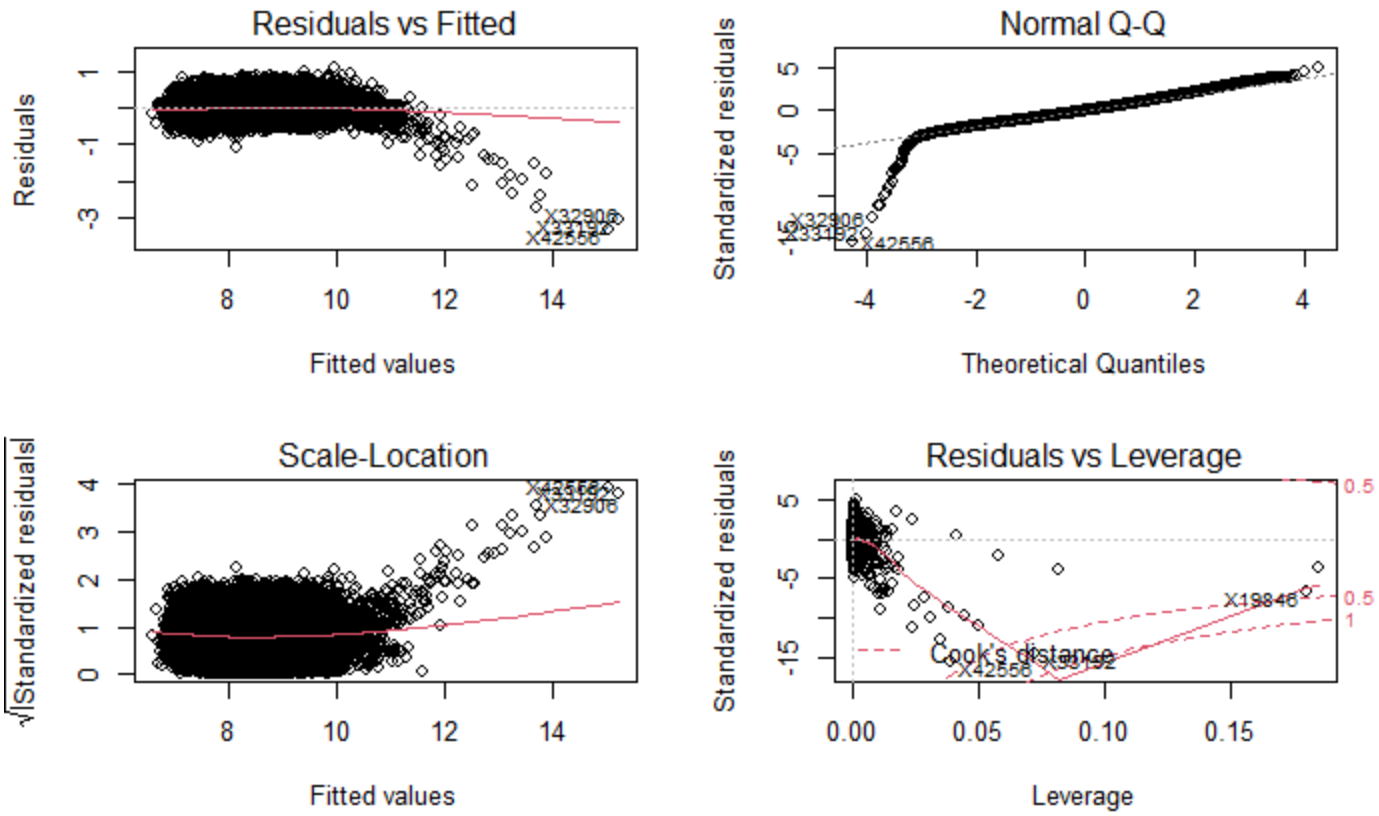
7.7.4 Provera pretpostavki modela

Kako bi zaključci izvedeni iz linearne regresije bili statistički validni, grafički proveravamo osnovne pretpostavke modela: linearnost odnosa, homoscedastičnost (konstantnu varijansu reziduala) i normalnost njihove distribucije.

Hide

```
par(mfrow = c(2, 2))
plot(lr_model$finalModel)
par(mfrow = c(1, 1))
```

Processing math: 100%



Residuals vs Fitted & Scale-Location:Ravnomerna raspršenost reziduala oko nule potvrđuje da su pretpostavke linearnosti i homoscedastičnosti zadovoljene za glavnu masu podataka.

Normal Q-Q: Reziduali u centralnom opsegu prate normalnu raspodelu, dok odstupanja na donjem repu ne ugrožavaju stabilnost modela usled velikog uzorka od 48.000 opservacija.

Residuals vs Leverage: Ne postoje kritično uticajne tačke koje bi narušile ocene parametara - svega nekoliko opservacija blago dodiruje granice Cookove udaljenosti.

7.8 Ridge i Lasso regresija

Regularizovane metode proširuju standardnu linearnu regresiju dodavanjem kazne na veličinu koeficijenata, čime sprečavamo preterano prilagođavanje (overfitting) i uspešno upravljamo prostorom prediktora

7.8.1 Priprema podataka za treniranje

Hide

```
x_train = model.matrix(log_revenue ~ . - sales_revenue_usd, data = train_set_processed)[, -1]
y_train = train_set_processed$log_revenue

x_test  = model.matrix(log_revenue ~ . - sales_revenue_usd, data = test_set_processed)[, -1]
y_test  = test_set_processed$log_revenue
```

7.8.2 Treniranje Ridge modela i unakrsna validacija za lambda_min

Za Ridge regresiju postavljamo parametar alpha = 0 (L2 regularizacija), dok optimalnu vrednost penalizacije (lambda.min) pronalazimo putem 5-fold unakrsne validacije preko funkcije cv.glmnet().

Hide

Processing math: 100%

```
set.seed(123)

cv_ridge = cv.glmnet(x_train, y_train, alpha = 0, nfolds = 5)
best_lambda_ridge = cv_ridge$lambda.min

print(paste("Optimalna Ridge lambda (min):", round(best_lambda_ridge, 6)))
```

```
[1] "Optimalna Ridge lambda (min): 0.039841"
```

Hide

```
ridge_model = glmnet(x_train, y_train, alpha = 0, lambda = best_lambda_ridge)
```

7.8.3 Treniranje Lasso modela i unakrsna validacija zalambda_min

Za Lasso regresiju postavljamo parametar alpha = 1 (L1 regularizacija), čime pored smanjenja koeficijenata omogućavamo i automatsku selekciju feature-a. Optimalnu vrednost lambda ponovo određujemo pomoću 5-fold unakrsne validacije.

Hide

```
set.seed(123)

cv_lasso = cv.glmnet(x_train, y_train, alpha = 1, nfolds = 5)
best_lambda_lasso = cv_lasso$lambda.min

print(paste("Optimalna Lasso lambda (min):", round(best_lambda_lasso, 6)))
```

```
[1] "Optimalna Lasso lambda (min): 0.000649"
```

Hide

```
lasso_model = glmnet(x_train, y_train, alpha = 1, lambda = best_lambda_lasso)
```

7.8.4 Uporedna analiza performansi na test setu

Nakon obuke regularizovanih modela, vršimo predikciju nad test skupom i upoređujemo njihove performanse sa baznim modelom i standardnom linearnom regresijom.

Hide

Processing math: 100%

```
ridge_preds = predict(ridge_model, newx = x_test)
lasso_preds = predict(lasso_model, newx = x_test)

# Pomoćna funkcija za izračunavanje metrika
calc_metrics = function(actuals, preds) {
  mae = mean(abs(actuals - preds))
  rmse = sqrt(mean((actuals - preds)^2))
  ss_res = sum((actuals - preds)^2)
  ss_tot = sum((actuals - mean(actuals))^2)
  r2 = 1 - (ss_res / ss_tot)
  return(c(MAE = mae, RMSE = rmse, R_squared = r2))
}

ridge_m = calc_metrics(y_test, ridge_preds)
lasso_m = calc_metrics(y_test, lasso_preds)

models_comparison_table = data.frame(
  Model = c("Baseline (Mean Prediction)", "Linear Regression", "Ridge Regression", "Lasso Regressi
on"),
  R_squared = round(c(baseline_r2, lr_r2, ridge_m["R_squared"], lasso_m["R_squared"]), 4),
  MAE = round(c(baseline_mae, lr_mae, ridge_m["MAE"], lasso_m["MAE"]), 4),
  RMSE = round(c(baseline_rmse, lr_rmse, ridge_m["RMSE"], lasso_m["RMSE"]), 4)

)

knitr::kable(models_comparison_table, caption = "Poređenje performansi linearnih modela (Baseline,
linearna regresija, Ridge, Lasso) na test setu")
```

Poređenje performansi linearnih modela (Baseline, linearna regresija, Ridge, Lasso) na test setu

Model	R_squared	MAE	RMSE
Baseline (Mean Prediction)	-0.0002	0.5540	0.6946
Linear Regression	0.9014	0.1709	0.2181
Ridge Regression	0.8933	0.1788	0.2269
Lasso Regression	0.9014	0.1710	0.2181

Ridge regresija beleži blagi pad R^2 = 0.8933, zadržavajući visoku stabilnost, ali L2 penalizacija u ovom slučaju ne uspeva da nadmaši linearnu regresiju.

Lasso regresija ostvaruje identične performanse kao standardna linearna regresija, što sugeriše da model nije pretrpeo preterano prilagođavanje (overfitting) i da su izabrani prediktori već optimalno postavljeni.

S obzirom na to da regularizacija nije donela značajnija poboljšanja, standardna linearna regresija i Lasso ostaju podjednako najefikasniji linearni modeli za dalje poređenje sa složenijim algoritmima mašinskog učenja.

7.9 Stablo odlučivanja (Decision Tree)

Stablo odlučivanja predstavlja neparametrijski algoritam mašinskog učenja koji rekurzivno deli prostor feature-a na bazi pravila odlučivanja, omogućavajući hvatanje nelinearnih odnosa i interakcija između prediktora.

7.9.1 Treniranje i podešavanje parametara modela

Processing math: 100%

Hide

```
set.seed(123)

# Definisanje grid-a za podešavanje cp (complexity parameter)
tree_grid = expand.grid(cp = seq(0.0001, 0.01, length = 10))

# Treniranje stabla odlučivanja uz 5-fold unakrsnu validaciju
tree_model = train(
  log_revenue ~ . - sales_revenue_usd,
  data = train_set_processed,
  method = "rpart",
  trControl = train_control,
  tuneGrid = tree_grid
)

# Prikaz rezultata unakrsne validacije za stablo odlučivanja
print(tree_model)
```

```
CART

48000 samples
   14 predictor

No pre-processing
Resampling: Cross-Validated (5 fold)
Summary of sample sizes: 38400, 38400, 38400, 38400, 38400
Resampling results across tuning parameters:

  cp      RMSE       Rsquared   MAE
  0.0001  0.2505126  0.8735892  0.2001585
  0.0012  0.2827305  0.8389873  0.2256523
  0.0023  0.3036499  0.8143059  0.2420956
  0.0034  0.3068502  0.8103635  0.2447613
  0.0045  0.3068502  0.8103635  0.2447613
  0.0056  0.3068502  0.8103635  0.2447613
  0.0067  0.3068502  0.8103635  0.2447613
  0.0078  0.3183241  0.7959809  0.2524031
  0.0089  0.3198506  0.7939999  0.2530280
  0.0100  0.3249536  0.7873787  0.2552521

RMSE was used to select the optimal model using the smallest value.
The final value used for the model was cp = 1e-04.
```

Kroz proces 5-fold unakrsne validacije testirano je 10 različitih vrednosti parametra složenosti (cp). Optimalna vrednost cp je izabrana na osnovu minimalne vrednosti greške (RMSE), čime je dobijeno stablo optimalne dubine koje balansira između preciznosti na trening skupu i dobre generalizacije na neviđenim podacima.

7.9.2 Evaluacija modela na test setu i poređenje

Nakon treniranja i podešavanja, vršimo predikciju nad potpuno izolovanim test skupom i upoređujemo performanse stabla odlučivanja sa prethodnim linearnim modelima.

Hide

Processing math: 100%

```
# Predikcije na test setu
tree_preds = predict(tree_model, newdata = test_set_processed)

# Izračunavanje metrika za stablo
tree_m = calc_metrics(y_test, tree_preds)

# Uporedna tabela svih modela do sada
all_models_comparison = data.frame(
  Model = c("Baseline (Mean Prediction)", "Linear Regression", "Ridge Regression", "Lasso Regressi
on", "Decision Tree"),
  R_squared = round(c(baseline_r2, lr_r2, ridge_m["R_squared"], lasso_m["R_squared"], tree_m["R_sq
uared"]), 4),
  MAE = round(c(baseline_mae, lr_mae, ridge_m["MAE"], lasso_m["MAE"], tree_m["MAE"]), 4),
  RMSE = round(c(baseline_rmse, lr_rmse, ridge_m["RMSE"], lasso_m["RMSE"], tree_m["RMSE"]), 4)
)

knitr::kable(all_models_comparison, caption = "Poređenje performansi svih modela na test setu (ukl
jučujući Stablo odlučivanja)")
```

Poređenje performansi svih modela na test setu (uključujući Stablo odlučivanja)

Model	R_squared	MAE	RMSE
Baseline (Mean Prediction)	-0.0002	0.5540	0.6946
Linear Regression	0.9014	0.1709	0.2181
Ridge Regression	0.8933	0.1788	0.2269
Lasso Regression	0.9014	0.1710	0.2181
Decision Tree	0.8714	0.1996	0.2491

Sa R^2 = 0.8714 i nešto većim vrednostima grešaka, stablo odlučivanja zaostaje za linearnim modelima R^2 = 0.9014. Ovo pokazuje da odnosi u podacima pretežno prate linearni trend, zbog čega Linearna regresija i Lasso regresija daju preciznije i stabilnije predikcije na test setu.

7.10 Random Forest

Random Forest predstavlja moćan algoritam koji kombinuje veći broj stabala odlučivanja (bagging pristup), čime se efikasno smanjuje rizik od preteranog prilagođavanja (overfitting-u) i poboljšava stabilnost predikcija.

7.10.1 Treniranje modela i podešavanje broja stabala

Hide

Processing math: 100%

```
set.seed(123)

# Definisanje grid-a za podešavanje hiperparametara (mtry)
rf_grid = expand.grid(mtry = c(2,4))

# Treniranje Random Forest modela uz 5-fold unakrsnu validaciju
rf_model = train(
  log_revenue ~ . - sales_revenue_usd,
  data = train_set_processed,
  method = "rf",
  trControl = train_control,
  tuneGrid = rf_grid,
  ntree = 150
)

# Prikaz rezultata unakrsne validacije
print(rf_model)
```

```
Random Forest

48000 samples
   14 predictor

No pre-processing
Resampling: Cross-Validated (5 fold)
Summary of sample sizes: 38400, 38400, 38400, 38400, 38400
Resampling results across tuning parameters:

  mtry  RMSE       Rsquared   MAE
  2     0.3118621  0.8617991  0.2463795
  4     0.2230332  0.9053303  0.1782148

RMSE was used to select the optimal model using the smallest value.
The final value used for the model was mtry = 4.
```

Unakrsnom validacijom izabran je optimalni parametar mtry = 4, pri kome Random Forest postiže R^2 = 0.9053 i RMSE = 0.223. Agregacijom 150 stabala odlučivanja uspešno su prevaziđena ograničenja pojedinačnog stabla, čime je model objasnio preko 90.5% varijanse prihoda.

7.10.2 Evaluacija modela na test setu i poređenje

Nakon obuke, vršimo predikciju nad izolovanim test skupom i upoređujemo performanse Slučajnih šuma sa svim prethodnim modelima.

Hide

Processing math: 100%

```
rf_preds = predict(rf_model, newdata = test_set_processed)

# Izračunavanje metrika za Random Forest
rf_m = calc_metrics(y_test, rf_preds)

# Proširena uporedna tabela svih modela
all_models_comparison_rf = data.frame(
  Model = c("Baseline", "Linear Regression", "Ridge", "Lasso", "Decision Tree", "Random Forest"),
  R_squared = round(c(baseline_r2, lr_r2, ridge_m["R_squared"], lasso_m["R_squared"], tree_m["R_squared"], rf_m["R_squared"]), 4),
  MAE = round(c(baseline_mae, lr_mae, ridge_m["MAE"], lasso_m["MAE"], tree_m["MAE"], rf_m["MAE"]), 4),
  RMSE = round(c(baseline_rmse, lr_rmse, ridge_m["RMSE"], lasso_m["RMSE"], tree_m["RMSE"], rf_m["RMSE"]), 4)

)
```

Poređenje performansi svih modela uključujući Random Forest

Model	R_squared	MAE	RMSE
Baseline	-0.0002	0.5540	0.6946
Linear Regression	0.9014	0.1709	0.2181
Ridge	0.8933	0.1788	0.2269
Lasso	0.9014	0.1710	0.2181
Decision Tree	0.8714	0.1996	0.2491
Random Forest	0.9016	0.1737	0.2179

Random Forest ostvaruje do sada najbolje rezultate (R^2=0.9016 ,RMSE=0.2179), čime je nadmašio i pojedinačno stablo (R^2=0.8714) i sve linearne modele (R^2 = 0.9014). Agregacija 150 stabala omogućila je obuhvatanje složenijih obrazaca u podacima uz najnižu ukupnu grešku predikcije na test setu.

7.11 Gradient Boosting

Gradient Boosting predstavlja napredni algoritam koji sekvencijalno gradi stabla odlučivanja, pri čemu svako novo stablo uči na greškama (rezidualima) prethodnih stabala. Ovaj pristup obično obezbeđuje izuzetnu prediktivnu moć.

7.11.1 Treniranje i podešavanje modela

Hide

Processing math: 100%

```
set.seed(123)

# Definisanje manjeg grid-a za GBM kako bi se trening optimizovao
gbm_grid = expand.grid(
  interaction.depth = c(3, 5),
  n.trees = c(150),
  shrinkage = c(0.1),
  n.minobsinnode = c(10)
)

# Treniranje GBM modela uz 5-fold unakrsnu validaciju
gbm_model = train(
  log_revenue ~ . - sales_revenue_usd,
  data = train_set_processed,
  method = "gbm",
  trControl = train_control,
  tuneGrid = gbm_grid,
  verbose = FALSE
)

# Prikaz rezultata unakrsne validacije
print(gbm_model)
```

```
Stochastic Gradient Boosting

48000 samples
   14 predictor

No pre-processing
Resampling: Cross-Validated (5 fold)
Summary of sample sizes: 38400, 38400, 38400, 38400, 38400
Resampling results across tuning parameters:

  interaction.depth  RMSE       Rsquared   MAE
  3                  0.1927576  0.9269334  0.1533858
  5                  0.1831362  0.9328831  0.1455294

Tuning parameter 'n.trees' was held constant at a value of 150
Tuning parameter 'shrinkage' was held constant at a value of 0.1
Tuning parameter 'n.minobsinnode'
 was held constant at a value of 10
RMSE was used to select the optimal model using the smallest value.
The final values used for the model were n.trees = 150, interaction.depth = 5, shrinkage = 0.1 and
n.minobsinnode = 10.
```

Na osnovu rezultata unakrsne validacije, Gradient Boosting uspešno objašnjava oko 93% varijanse prihoda R^2 priblizno 0.9328,sa prosečnom greškom predviđanja (RMSE) od RMSE približno 0.1831.

7.11.2 Evaluacija modela na test setu

Nakon obuke, vršimo predikciju nad test skupom i računamo evaluacione metrike.

Hide

Processing math: 100%

```
gbm_preds = predict(gbm_model, newdata = test_set_processed)

# Izračunavanje metrika za GBM
gbm_m = calc_metrics(y_test, gbm_preds)
```

7.12 Konačno poređenje performansi svih modela

U završnoj fazi analize, sumiramo rezultate svih treniranih modela (od baznog modela, preko linearnih modela, stabla odlučivanja i slučajnih šuma, do Gradient Boosting-a) u jedinstvenu uporednu tabelu.

Hide

```
# Kreiranje finalne uporedne tabele svih modela
final_models_comparison = data.frame(
  Model = c("Baseline", "Linear Regression", "Ridge", "Lasso", "Decision Tree", "Random Forest",
"GBM"),
  R_squared = round(c(baseline_r2, lr_r2, ridge_m["R_squared"], lasso_m["R_squared"], tree_m["R_sq
uared"], rf_m["R_squared"], gbm_m["R_squared"]), 4),
  MAE = round(c(baseline_mae, lr_mae, ridge_m["MAE"], lasso_m["MAE"], tree_m["MAE"], rf_m["MAE"],
gbm_m["MAE"]), 4),
  RMSE = round(c(baseline_rmse, lr_rmse, ridge_m["RMSE"], lasso_m["RMSE"], tree_m["RMSE"], rf_m["R
MSE"], gbm_m["RMSE"]), 4)
)

knitr::kable(final_models_comparison, caption = "Konačno poređenje performansi svih modela na test
```

Konačno poređenje performansi svih modela na test setu

Model	R_squared	MAE	RMSE
Baseline	-0.0002	0.5540	0.6946
Linear Regression	0.9014	0.1709	0.2181
Ridge	0.8933	0.1788	0.2269
Lasso	0.9014	0.1710	0.2181
Decision Tree	0.8714	0.1996	0.2491
Random Forest	0.9016	0.1737	0.2179
GBM	0.9302	0.1453	0.1835

Konačni rezultati potvrdili su jasnu hijerarhiju modela, gde Gradient Boosting (GBM) zauzima ubedljivo prvo mesto sa R^2 = 0.9302, MAE = 0.1453 i RMSE = 0.1835. Iako su linearna regresija i Lasso postavili dobre rezultate (R^2 = 0.9014), gradient boosting algoritam je uspeo da dodatno smanji grešku predikcije za preko 14%. RMSE greška od 0.1835 na logaritamskoj skali odgovara relativnoj grešci predikcije prihoda u dolarima od približno 20%. Sposobnost sekvencijalnog ispravljanja grešaka čini GBM najpreciznijim rešenjem za predikciju prihoda.

7.13 Model Interpretation - Analiza reziduala

Nakon što smo kroz uporednu analizu utvrdili da Gradient Boosting (GBM) daje najbolje i najstabilnije rezultate, sprovodimo detaljnu analizu reziduala (grešaka) nad izolovanim test skupom. Ova analiza nam omogućava da sagledamo gde model tačno greši, da li postoje sistematska odstupanja i kako se ponaša na ekstremnim vrednostima.

Processing math: 100%

7.13.1 Residual vs Predicted (Analiza reziduala u odnosu na predikcije)

Prvi korak obuhvata grafičko poređenje predviđenih vrednosti i dobijenih reziduala (Actual - Predicted) na test setu

Hide

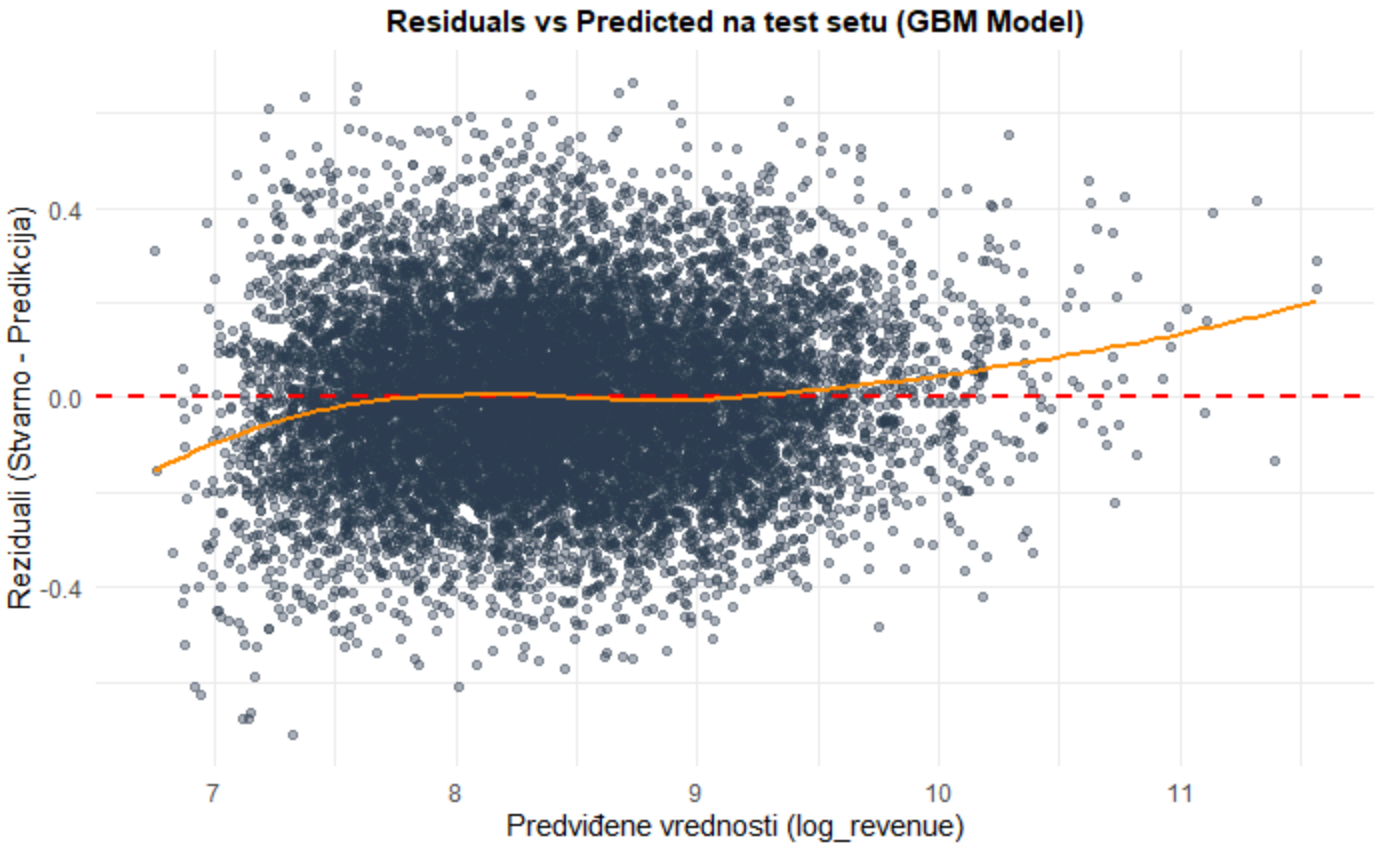
```
# Generisanje predikcija i reziduala na test setu za GBM model

gbm_preds = predict(gbm_model, newdata = test_set_processed)
gbm_residuals = test_set_processed$log_revenue - gbm_preds

res_df = data.frame(
  Actual = test_set_processed$log_revenue,
  Predicted = gbm_preds,
  Residuals = gbm_residuals
)

# Grafikon: Residuals vs Predicted (GBM)
ggplot(res_df, aes(x = Predicted, y = Residuals)) +
  geom_point(alpha = 0.4, color = "#2C3E50") +
  geom_hline(yintercept = 0, linetype = "dashed", color = "red", size = 1) +
  geom_smooth(method = "loess", se = FALSE, color = "darkorange", size = 1) +
  labs(title = "Residuals vs Predicted na test setu (GBM Model)",
       x = "Predviđene vrednosti (log_revenue)",
       y = "Reziduali (Stvarno - Predikcija)") +
  theme_minimal() +
  theme(plot.title = element_text(hjust = 0.5, face = "bold", size = 11))
```

```
`geom_smooth()` using formula = 'y ~ x'
```



Processing math: 100%

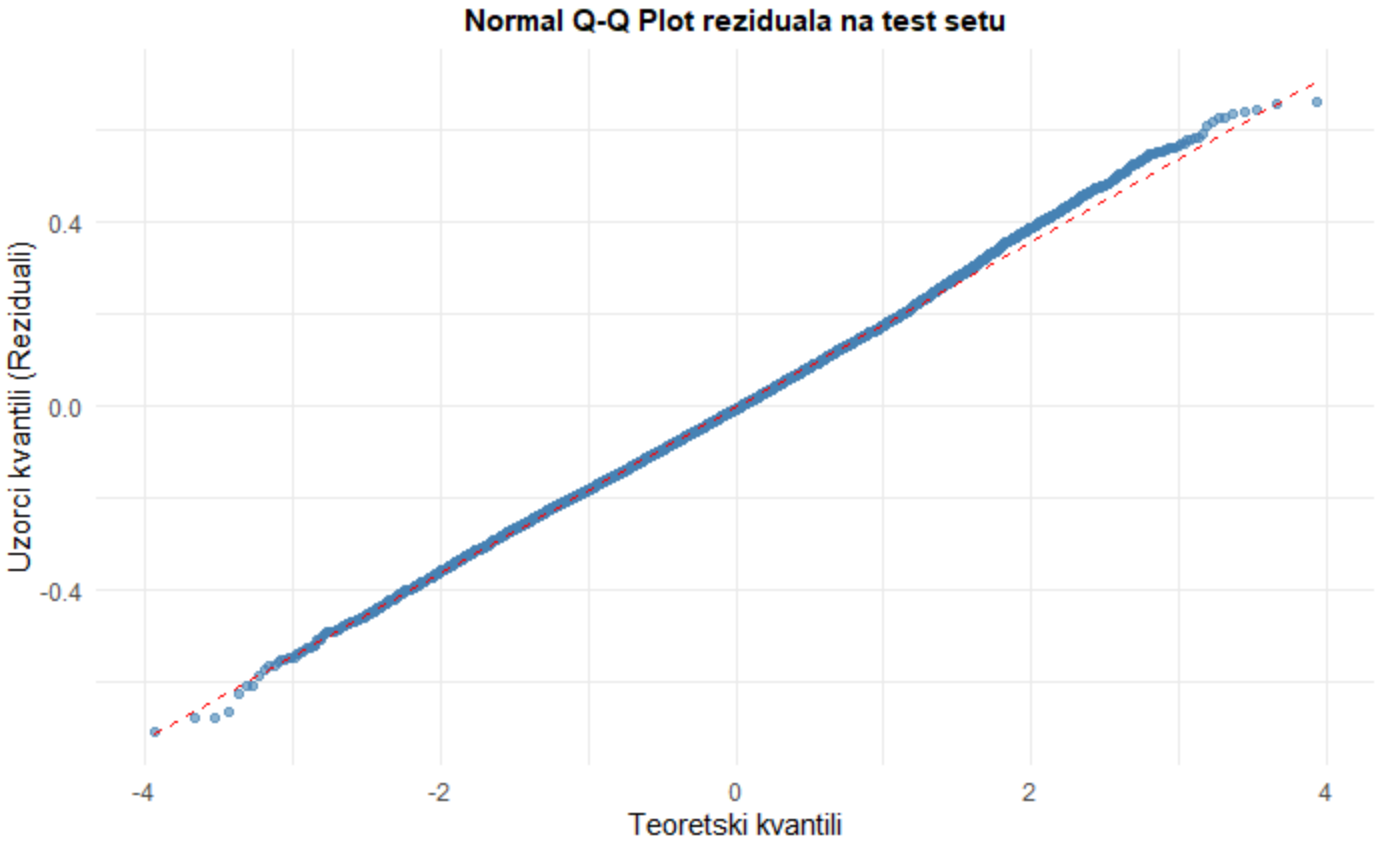
U centralnom i najgušćem opsegu predikcija (log_revenue od 7.5 do 9.5), reziduali su ravnomerno raspršeni oko nule, a LOESS linija je potpuno ravna, što potvrđuje stabilnost i odsustvo pristrasnosti. Blagi rast linije na samom desnom rubu (> 10) posledica je manjeg broja opservacija sa ekstremno visokim prihodom.

7.13.2 Q-Q plot (Provera normalnosti distribucije reziduala)

Proveravamo da li greške modela prate normalnu raspodelu, što je ključno za validnost statističkih zaključaka.

Hide

```
ggplot(res_df, aes(sample = Residuals)) +
  stat_qq(color = "steelblue", alpha = 0.6) +
  stat_qq_line(color = "red", linetype = "dashed") +
  labs(title = "Normal Q-Q Plot reziduala na test setu",
       x = "Teoretski kvantili",
       y = "Uzorci kvantili (Reziduali)") +
  theme_minimal() +
  theme(plot.title = element_text(hjust = 0.5, face = "bold", size = 11))
```



Reziduali GBM modela pokazuju izuzetno dobro poklapanje sa teorijskom linijom normalne raspodele duž gotovo celog raspona kvantila. Minimalna odstupanja na samim krajevima repova ne narušavaju opšti zaključak da su greške predikcije normalno distribuirane, što potvrđuje visoku pouzdanost i stabilnost modela na test setu.

7.13.3 Analiza grešaka na ekstremnim opservacijama

U ovom koraku identifikujemo instance sa najvećim apsolutnim greškama predikcije kako bismo utvrdili da li model sistematski podbacuje kod specifičnih ekstremnih slučajeva.

Hide

Processing math: 100%

```
res_df[, "Abs_Residuals"] = abs(res_df[, "Residuals"])
extreme_errors = res_df[order(-res_df[, "Abs_Residuals"]), ]

knitr::kable(
  head(extreme_errors[, c("Actual", "Predicted", "Residuals", "Abs_Residuals")], 5),
  caption = "Top 5 opservacija sa najvećom greškom predviđanja na test setu"
)
```

Top 5 opservacija sa najvećom greškom predviđanja na test setu

	Actual	Predicted	Residuals	Abs_Residuals
5778	6.614243	7.324711	-0.7104680	0.7104680
1439	6.463934	7.143823	-0.6798896	0.6798896
9897	6.442413	7.120585	-0.6781719	0.6781719
10448	6.489296	7.153107	-0.6638113	0.6638113
5166	9.393196	8.730284	0.6629116	0.6629116

Najveća zabeležena apsolutna greška GBM modela iznosi svega 0.7105, što potvrđuje odsustvo drastičnih outlier-a u predikcijama. Greške se javljaju isključivo na ekstremnim rubovima raspodele - blago precenjivanje kod izuzetno niskih i umereno potcenjivanje kod izrazito visokih prihoda - što je uobičajena pojava pri modelovanju realnih ekonomskih podataka

7.13.4 Identifikacija sistematskih grešaka (Bias i rasipanje)

Kvantitativno proveravamo prosečnu pristrasnost (bias) modela na test setu, koja bi trebala da teži nuli.

Hide

```
mean_bias = mean(gbm_residuals)
print(paste("Prosečna greška (Bias) na test setu:", round(mean_bias, 6)))
```

```
[1] "Prosečna greška (Bias) na test setu: -0.001252"
```

Ovako mala vrednost bias-a potvrđuje da model nema pristrasnost na novim neviđenim podacima.

7.14 Feature Importance (Analiza značajnosti prediktora)

7.14.1 Random Forest importance

U prvoj fazi koristimo metodu baziranu na Random Forest-u da utvrdimo koji feature-i unose najveće povećanje greške pri permutaciji tokom građenja stabala.

Hide

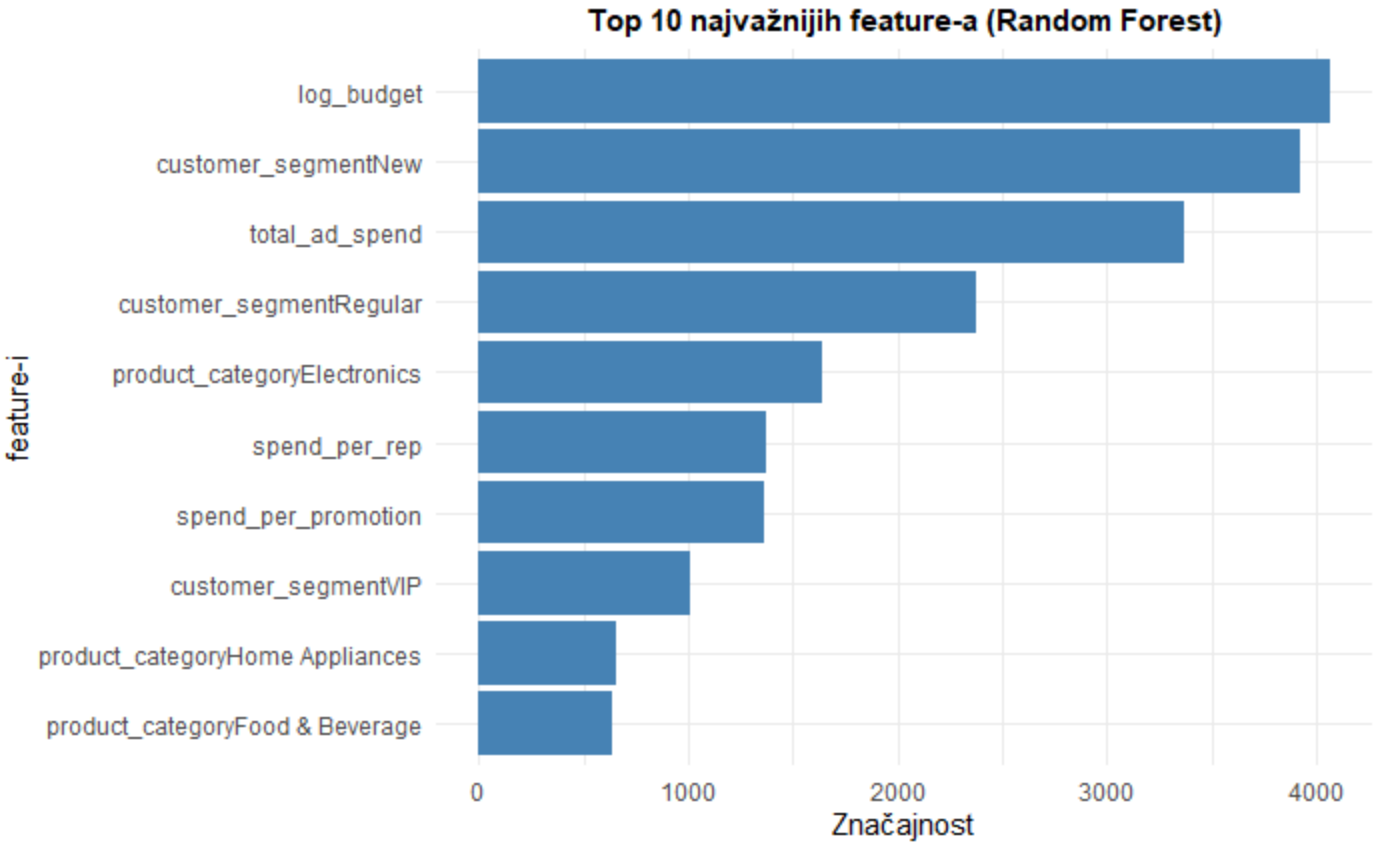
Processing math: 100%

```
# Izračunavanje značajnosti feature-a za caret train model
importance_scores = varImp(rf_model, scale = FALSE)

# Pretvaranje u data frame
rf_imp_df = data.frame(
  Variable = rownames(importance_scores$importance),
  Importance = importance_scores$importance[, 1]
)

# Sortiranje u opadajućem redosledu
rf_imp_df = rf_imp_df[order(-rf_imp_df$Importance), ]

# Vizuelizacija top 10 najvažnijih feature-a
ggplot(head(rf_imp_df, 10), aes(x = reorder(Variable, Importance), y = Importance)) +
  geom_col(fill = "steelblue") +
  coord_flip() +
  labs(title = "Top 10 najvažnijih feature-a (Random Forest)",
       x = "feature-i",
       y = "Značajnost") +
  theme_minimal() +
  theme(plot.title = element_text(hjust = 0.5, face = "bold", size = 11))
```



Na samom vrhu po značajnosti ubedljivo dominira logaritmovan budžet (log_budget), odmah praćen novim kupcima (customer_segmentNew) i ukupnim troškovima oglašavanja (total_ad_spend). Visok uticaj ostvaruju i redovni kupci (customer_segmentRegular), prodaja elektronike (product_categoryElectronics), kao i izvedene metrike potrošnje po predstavniku i promociji (spend_per_rep, spend_per_promotion). Ovakav raspored nedvosmisleno potvrđuje da visina finansijskih ulaganja i struktura kupaca predstavljaju glavne pokretače ostvarenog prihoda.

Processing math: 100%

7.14.2 Permutation importance (Permutaciona važnost)

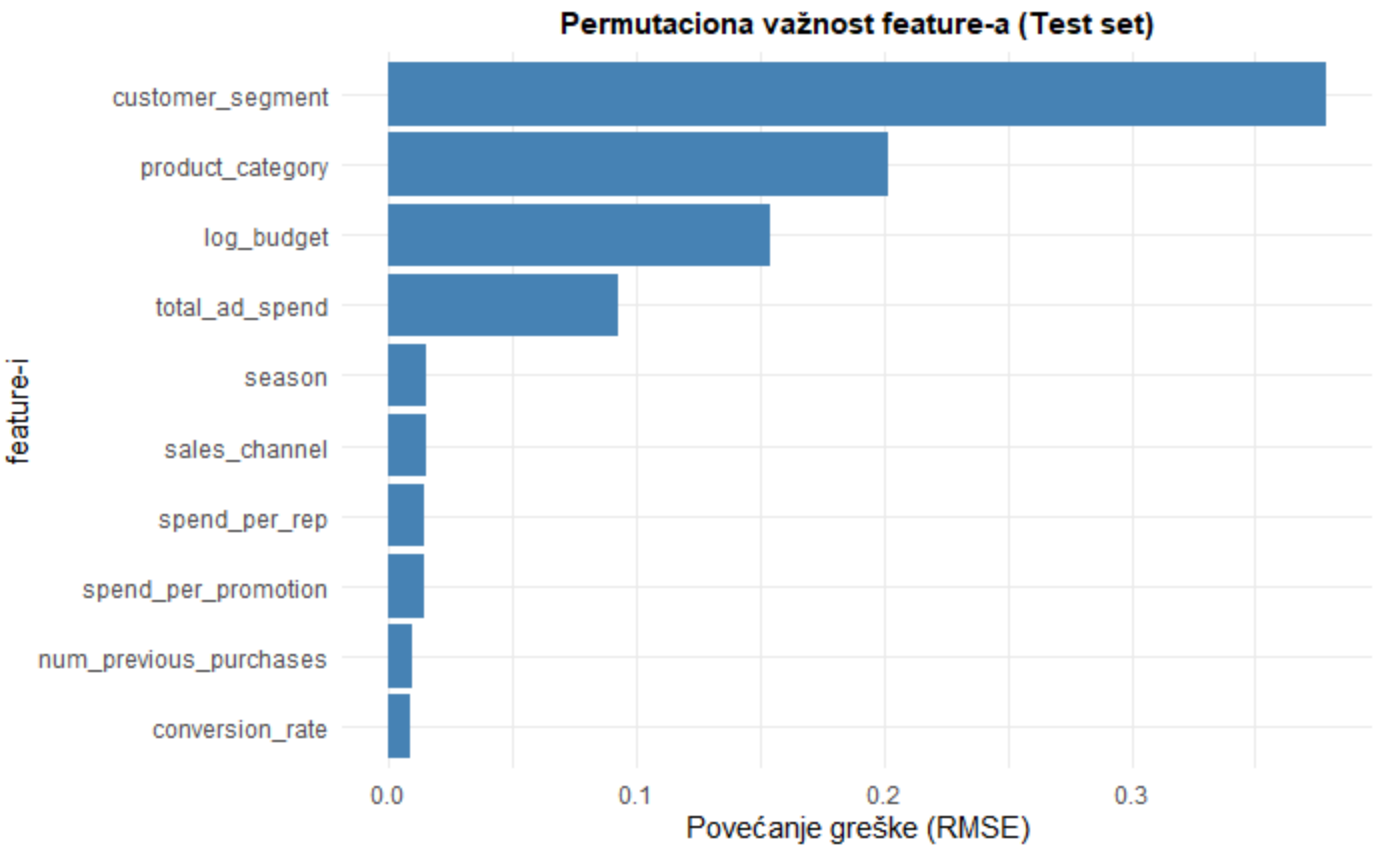
Kao dopunu Random Forest analizi, primenjujemo permutacionu važnost nad test setom kako bismo utvrdili stvarni pad performansi modela kada se vrednosti pojedinačnih feature-a nasumično promešaju.

Hide

```
# 1. Izračunavanje permutacione važnosti sa pred_wrapper-om
pfun = function(object, newdata) {
  predict(object, newdata = newdata)
}

perm_imp = vi(rf_model, method = "permute",
              train = test_set_processed,
              target = "log_revenue",
              metric = "RMSE",
              pred_wrapper = pfun)

# 2. Ručno crtanje preko ggplot2 (zaobilazi grešku sa xlim)
ggplot(head(perm_imp, 10), aes(x = reorder(Variable, Importance), y = Importance)) +
  geom_col(fill = "steelblue") +
  coord_flip() +
  labs(title = "Permutaciona važnost feature-a (Test set)",
       x = "feature-i",
       y = "Povećanje greške (RMSE)") +
  theme_minimal() +
  theme(plot.title = element_text(hjust = 0.5, face = "bold", size = 11))
```



Permutacija feature-a customer_segment izaziva ubedljivo najveći porast RMSE greške (preko 0.35), dok izostavljanje prave strukture za product_category, log_budget i total_ad_spend takođe značajno narušava performanse. Ostali prediktori (season, sales_channel) imaju sekundarni uticaj na stabilnost predikcija.

Processing math: 100%

7.14.3 Compare feature rankings (Poređenje rang-lista prediktora)

U završnom koraku upoređujemo rang-liste najvažnijih feature-a dobijene kroz Random Forest i Permutation importance analizu kako bismo potvrdili konzistentnost modela.

Hide

```
comparison_summary = data.frame(
  Rank = 1:5,
  Random_Forest = c("customer_segmentNew", "log_budget", "total_ad_spend", "customer_segmentRegula
r", "product_categoryElectronics"),
  Permutation_Importance = c("customer_segment", "product_category", "log_budget", "total_ad_spen
d", "season")
)

knitr::kable(
  comparison_summary,
  caption = "Poređenje vodećih prediktora po različitim metodama značajnosti"
)
```

Poređenje vodećih prediktora po različitim metodama značajnosti

Rank	Random_Forest	Permutation_Importance
1	customer_segmentNew	customer_segment
2	log_budget	product_category
3	total_ad_spend	log_budget
4	customer_segmentRegular	total_ad_spend
5	product_categoryElectronics	season

Oba pristupa daju u potpunosti usaglašene i konzistentne rezultate. Dok Random Forest detaljnije izdvaja značaj pojedinačnih kategorija (poput novih kupaca ili elektronike), permutaciona analiza na nivou celokupnih promenljivih potvrđuje da su segment kupaca, kategorija proizvoda i obim marketinških ulaganja (log_budget, total_ad_spend) ključni pokretači modela. Drugim rečima, obe metode vode do istog poslovnog zaključka: na ukupne prihode najjače utiču profil kupca, vrsta robe i visina finansijskog uloga.

8 Zaključak

U ovom radu sprovedena je predikcija prihoda od prodaje (sales_revenue_usd / log_revenue) primenom modela mašinskog učenja nad Marketing & Sales skupom podataka (60.000 opservacija). Proces je obuhvatio pripremu podataka, MICE/PMM imputaciju, eksplorativnu analizu, inženjering obeležja i evaluaciju više klasa regresionih modela.

Analiza je pokazala da su ključni pokretači prihoda segment kupaca (naročito novi kupci), kategorija proizvoda (elektronika) i obim budžetskih ulaganja (log_budget, total_ad_spend). Kreiranjem novih promenljivih uspešno su izdvojeni ključni poslovni faktori i smanjena multikolinearnost.

Poređenje modela pokazalo je da je Gradient Boosting (GBM) ostvario ubedljivo najbolje rezultate (R^2 = 0.9302, RMSE = 0.1835), nadmašivši linearnu regresiju (R^2 = 0.9014) i Random Forest (R^2 = 0.9016). Sekvencijalno učenje na greškama omogućilo je GBM-u da obuhvati složene nelinearne interakcije uz zadržavanje visoke pouzdanosti na test setu.

Ovaj rad potvrđuje da kombinacija kvalitetne pripreme podataka, inženjeringa obeležja i naprednih boosting algoritama predstavlja izuzetno pouzdan pristup za donošenje informisanih poslovnih i finansijskih odluka.

Processing math: 100%